



SEGMENTATION OF LUNG LOBES AND LESIONS FOR SEVERITY CLASSIFICATION OF COVID-19 CT SCANS

MR.PONGPAT PHUAUDOMCHAROEN

MR.PRACHAYA KHOMEUAN

MR.TOTSAPORN BOONCHU

A PROJECT SUBMITTED IN PARTIAL FULFILLMENT
OF THE REQUIREMENTS FOR
THE DEGREE OF BACHELOR OF SCIENCE (COMPUTER ENGINEERING)
FACULTY OF ENGINEERING
KING MONGKUT'S UNIVERSITY OF TECHNOLOGY THONBURI
2021

Segmentation of Lung Lobes and Lesions for Severity Classification of COVID-19 CT Scans

Mr.Pongpat Phuaudomcharoen

Mr.Prachaya Khomduean

Mr.Totsaporn Boonchu

A Project Submitted in Partial Fulfillment
of the Requirements for
the Degree of Bachelor of Science (Computer Engineering)
Faculty of Engineering
King Mongkut's University of Technology Thonburi
2021

Project Committee

.....

(Unchalisra Taetragool, Ph.D.)

Project Advisor

.....

(Kamonwan Chamchoy, Ph.D.)

Project Co-Advisor

.....
(Assoc.Prof. Naruemon Wattanapongsakorn, Ph.D.)

Committee Member

.....
(Asst.Prof.Peerut Chienwichai, D.V.M., Ph.D.)

Committee Member

Project Title	Segmentation of Lung Lobes and Lesions for Severity Classification of COVID-19 CT Scans
Credits	3
Member(s)	Mr.Pongpat Phuaudomcharoen Mr.Prachaya Khomduean Mr.Totsaporn Boonchu
Project Advisor	Unchalisa Taetragool, Ph.D.
Co-advisor	Kamonwan Chamchoy, Ph.D.
Program	Bachelor of Science
Field of Study	Health Data Science
Department	Computer Engineering
Faculty	Engineering
Academic Year	2021

Abstract

COVID-19 is a viral respiratory infection that has spread across the world, including Thailand. Manifestations of COVID-19 vary ranging from mild to severe and mortality, depending on the degree of lung involvement. Computed tomography (CT) is an effective tool to determine the severity score of lung injury, which is helpful for the treatment planning and monitoring of patients with COVID-19. In this regard, we aimed to develop a deep learning model for lung lobes and COVID-19 lesion segmentation using the combination of 3D-UNet and pre-trained models, DenseNet and ResNet. An axial lung CT volume from 32 COVID-19 patients with different disease severity were used to train the segmentation model. Next, the segmented masks were used to calculate the Total Severity Score (TSS) of infected lung, which was then used for classifying clinical severity of COVID-19.

The model was evaluated on a dataset of 8 infected patients, and the results demonstrated that 3D-UNet + DenseNet169 achieved the best performance, yielding Dice Similarity Coefficient (DSC) of 92.89% and 84.22% for lung lobe and lesion segmentation, respectively. The proposed model can reliably segment lesions on CT scans of severe cases, but the model performed less accurately in segmenting lung lesions of mild and moderate cases. However, the TSS calculated by the proposed model were comparable to those assigned by radiologists. Using CT scans of 62 COVID-19 patients for evaluation, the correlation coefficient (r) was 0.9125, indicating a very strong correlation.

These findings suggest that the proposed model would help radiologists assess the lung involvement and classify the severity of disease, facilitating effective management of patients with COVID-19.

Keywords: COVID-19, Lung Computed Tomography Scans, Severity, Deep Learning, Semantic Segmentation, 3D-UNet, DenseNet

หัวข้อปริญญาบัณฑิต	การแบ่งส่วนกลีบปอดและรอยโรคเพื่อการจำแนกระดับความรุนแรงของภาพถ่ายรังสีคอมพิวเตอร์ปอดผู้ป่วยโควิด-19
หน่วยกิต	3
ผู้เขียน	นายพงษ์พัฒน์ พวลดุมเจริญ นายปรัชญา โคมเดือน นายทศพร บุญชู
อาจารย์ที่ปรึกษา	ดร.อัญชลิสา แต้ตระกูล ดร.กมลวรรณ แซมช่อ
หลักสูตร	วิทยาศาสตรบัณฑิต
สาขาวิชา	วิทยาศาสตร์ข้อมูลสุขภาพ
ภาควิชา	วิศวกรรมคอมพิวเตอร์
คณนะ	วิศวกรรมศาสตร์
ปีการศึกษา	2564

บทคัดย่อ

โควิด-19 คือ โรคติดเชื้อไวรัสในระบบทางเดินหายใจที่มีการแพร่ระบาดไปทั่วโลกรวมถึงประเทศไทย อาการของโรคมีตั้งแต่ระดับความรุนแรงน้อยไปจนถึงรุนแรงมาก และถึงขั้นเสียชีวิต ขึ้นอยู่กับระดับความเสียหายที่เกิดขึ้นกับปอดของผู้ติดเชื้อการถ่ายภาพรังสีคอมพิวเตอร์ (Computed Tomography; CT) เป็นเครื่องมือทางการแพทย์ที่มีประสิทธิภาพที่ใช้ในการตรวจประเมินระดับปอดอักเสบเพื่อวางแผนการรักษาและติดตามการดำเนินของโรคในผู้ป่วยโควิด-19 โครงการนี้จึงมีวัตถุประสงค์ที่จะประยุกต์ใช้เทคโนโลยีการเรียนรู้เชิงลึกโดยใช้แบบจำลอง 3D-UNet ร่วมกับแบบจำลองประเกต DenseNet และ ResNet เพื่อพัฒนาแบบจำลองสำหรับการแบ่งส่วนกลีบปอดและรอยโรค โดยแบบจำลองถูกพัฒนาโดยใช้ชุดข้อมูลภาพ CT ปอดชนิดภาพตัดขวางของผู้ติดเชื้อโควิด-19 ที่มีความรุนแรงของอาการที่ระดับต่าง ๆ จำนวน 32 ราย จากนั้นภาพที่ได้จากการแบ่งส่วนจะถูกนำไปใช้ในการคำนวณหาคะแนนความรุนแรง (Total Severity Score; TSS) ของการติดเชื้อที่ปอด และค่า TSS จะถูกนำไปใช้สำหรับการจำแนกระดับความรุนแรงของผู้ป่วยโควิด-19

ผลการทดสอบประสิทธิภาพของแบบจำลองโดยใช้ภาพ CT ปอดของผู้ติดเชื้อจำนวน 8 ราย พบร่วมแบบจำลอง 3D-UNet + DenseNet169 มีประสิทธิภาพสูงสุดในการแบ่งส่วนกลีบปอดและรอยโรค โดยให้ค่าตัดขั้นความเหมือน (Dice Similarity Coefficient; DSC) เท่ากับ 92.89% และ 84.22% ตามลำดับ แบบจำลองสามารถแยกรอยโรคในปอดของผู้ป่วยที่มีอาการระดับ Severe ได้อย่างแม่นยำ แต่ความแม่นยำจะลดลงในกลุ่มผู้ป่วยที่มีความรุนแรงลดลงมาในระดับ Mild และ Moderate อย่างไรก็ตามแบบจำลองที่นำเสนอให้ผลการประเมิน TSS ได้เทียบเคียงกับการประเมินโดยรังสีแพทย์ จากการเปรียบเทียบค่า TSS ของภาพ CT ปอดของผู้ป่วยโควิด-19 จำนวน 62 ราย พบร่วมค่าสัมประสิทธิ์สัมพันธ์ (Correlation Coefficient; r) เท่ากับ 0.9125 แสดงถึงความสัมพันธ์กันระดับสูง ผลการศึกษานี้แสดงให้เห็นว่าแบบจำลองที่พัฒนาขึ้นสามารถช่วยรังสีแพทย์ในการตรวจประเมินระดับการติดเชื้อในปอดและจำแนกผู้ป่วยตามความรุนแรงของโรคได้ ซึ่งจะทำให้การบริหารจัดการผู้ติดเชื้อโควิด-19 เกิดขึ้นอย่างมีประสิทธิภาพมากยิ่งขึ้น

คำสำคัญ: โควิด-19, ภาพถ่ายรังสีคอมพิวเตอร์ปอด, ความรุนแรง, การเรียนรู้เชิงลึก, การแบ่งส่วนภาพ, 3D-UNet, DenseNet

กิตติกรรมประกาศ

คณบดีคณะมนุษย์ศาสตร์ ดร.อัญชลิสา แต้ระบากุล อาจารย์ที่ปรึกษาโครงการ และดร.กมลวรรณ แซ่เมี้ยงช้อย, แพทย์หญิงน้ำฝน สินธัย และนายแพทย์อัมรุทธ์ เชื้อจักร อาจารย์ที่ปรึกษาอวam ที่ค่อยช่วยเหลือให้คำแนะนำขั้นตอนแนวทาง และค่อยช่วยแก้ปัญหาต่าง ๆ รวมถึงค่อยดูแลพากເຮາດลอดการทำโครงการในครั้งนี้

ขอขอบคุณคุณพ่อคุณแม่ที่สนับสนุนในทุก ๆ ด้าน และเป็นกำลังใจที่ยิ่งใหญ่ตลอดระยะเวลาในการศึกษาที่ผ่านมา

ขอขอบคุณเพื่อน ๆ พี่ ๆ น้อง ๆ ภาควิชาศิลปกรรมคอมพิวเตอร์ที่ให้คำปรึกษา และชี้แนะแนวทางที่ทำให้โครงงานสำเร็จลุล่วง อีกทั้งค่อยให้กำลังใจ และอยู่เคียงข้างกันตลอดระยะเวลาจัดทำโครงการ

สุดท้ายนี้ขอขอบคุณคณบดีที่ร่วมมือในการจัดทำโครงการในครั้งนี้จนประสบความสำเร็จลุล่วงตามวัตถุประสงค์

สารบัญ

หน้า

ABSTRACT	ii
บทคัดย่อ	iii
กิตติกรรมประกาศ	iv
สารบัญ	v
สารบัญตาราง	viii
สารบัญรูปภาพ	ix
บทที่ 1 บทนำ	1
1.1 ความสำคัญของปัญหา	1
1.2 ประเภทของโครงงาน	1
1.3 วิธีการที่นำมาเสนอ	1
1.3.1 วิธีการที่ใช้	1
1.3.2 วัตถุประสงค์	1
1.3.3 เทคโนโลยีที่ใช้	1
1.3.4 ขอบเขตของโครงงาน	2
1.4 เนื้อหาทางวิศวกรรมที่เน้นต้นฉบับ	2
1.4.1 Semantic Segmentation	2
1.5 การแยกย่อยงาน และแผนการดำเนินงาน	2
1.5.1 ภาคเรียนที่ 1	2
1.5.2 ภาคเรียนที่ 2	3
1.6 ผลการดำเนินงานใน	5
บทที่ 2 ที่มา ทฤษฎี และงานวิจัยที่เกี่ยวข้อง	6
2.1 ที่มาและความสำคัญ	6
2.2 ทฤษฎีและแนวคิดหลัก	7
2.2.1 กายวิภาคของปอด (Lung Anatomy)	7
2.2.1.1 ตำแหน่งของปอด	7
2.2.1.2 โครงสร้างของปอด	7
2.2.1.3 หน้าที่ของปอด	8
2.2.2 การแบ่งส่วนภาพ (Semantic Segmentation)	8
2.2.3 โครงข่ายประสาทเทียม (Artificial Neural Network: ANN)	8
2.2.4 โครงข่ายประสาทคอนโวลูชัน (Convolutional Neural Network: CNN)	9
2.2.5 โครงข่ายประสาทคอนโวลูชันเต็มรูป (Fully Convolutional Network: FCN)	10
2.2.6 U-Net	10
2.2.7 3D-UNet	11
2.2.8 ResNet	12
2.2.9 DenseNet	13
2.2.10 Loss Function	14
2.2.10.1 Dice Loss	14
2.2.10.2 Focal Loss	15
2.2.10.3 Hybrid Loss	15
2.2.11 Evaluation	16

2.3 งานวิจัยที่เกี่ยวข้อง	17
2.3.1 Segmentation of Lung Nodules Using Improved 3D-UNET Neural Network	17
2.3.2 COVID-19 Patients' Severity Grading by Lung and Lesion Segmentation	17
2.3.3 LOBENET: A Global Position Reservation and Fissure-Aware Convolutional Neural Network for Pulmonary Lobe Segmentation	18
2.3.4 Automatic Pulmonary Lobe Segmentation using Deep Learning	18
2.3.5 Assessing Lobe-wise Burden of COVID-19 Infection in Computed Tomography of Lungs using Knowledge Fusion from Multiple Datasets	19
2.4 ภาษาคอมพิวเตอร์และเทคโนโลยี	20
2.4.1 ภาษาไพทอน (Python Programming Language: Python)	20
2.4.2 LabelME	20
2.4.3 Google Colaboratory	20
2.4.4 Sever(TensorFlow-Docker)	20
2.4.5 Streamlit	21
2.4.6 Github	21
2.4.7 Git Large File Storage (LFS)	21
บทที่ 3 การออกแบบ และระบบวิธีวิจัย	22
3.1 ภาพรวมของโครงงาน	22
3.2 ชุดข้อมูล	22
3.3 การเตรียมข้อมูล	24
3.4 การพัฒนาแบบจำลอง	24
3.4.1 การเตรียมข้อมูลสำหรับการฝึกฝนและทดสอบแบบจำลอง (Data Preprocessing)	25
3.4.2 การปรับไฮเปอร์พารามิเตอร์ (Hyperparameter Tuning)	26
3.4.3 Lung Lobe Segmentation	26
3.4.4 Lesion Segmentation	26
3.5 การคำนวนเปอร์เซ็นต์การติดเชื้อ (Percentage of Infection)	27
3.6 การคำนวนค่าระดับความรุนแรง Total Severity Score (TSS)	27
3.7 การสร้างหน้าต่างผู้ใช้งาน	27
3.8 รายละเอียดเชิงเทคนิค	28
3.8.1 Requirements	28
3.8.2 Use Case Diagram	28
3.8.3 Use Case Narrative	29
3.8.4 Activity Diagram	30
3.8.4.1 การทำนายผลของผู้ป่วยยืนยันโรคโควิด-19	30
3.9 การประเมินผล (Evaluation)	31
3.9.1 การประเมินผลแบบจำลอง	31
3.9.2 การประเมินผลการคำนวนค่าระดับความรุนแรง (Total Severity Score)	31
3.9.3 การประเมินผลโดยผู้ใช้งาน (User Evaluation)	31
3.9.4 การประเมินผลหน้าต่างผู้ใช้งาน	31
บทที่ 4 ผลการวิจัย และอภิปรายผล	32
4.1 ข้อมูลติบ	32
4.2 การเตรียมข้อมูล	32
4.2.1 การระบุตำแหน่งกลีบปอดและรอยโรค	33
4.2.2 ความแตกต่างของภาพถ่ายรังสีคอมพิวเตอร์ปอด	34
4.2.3 การเตรียมไฟล์สำหรับการฝึกฝนแบบจำลอง	35
4.3 การตรวจสอบผลการระบุตำแหน่งกลีบปอดและรอยโรค	37

4.4 การพัฒนาแบบจำลอง	37
4.4.1 ผลการปรับไฮเปอร์พารามิเตอร์ (Hyperparameter Tuning)	37
4.4.1.1 Loss Function	37
4.4.1.2 Regularizer	38
4.4.1.3 Dropout	38
4.4.2 ผลการทดสอบแบบจำลองสำหรับการแบ่งส่วนกลีบปอด	39
4.4.3 ผลการทดสอบแบบจำลองสำหรับการแบ่งส่วนรอยโรค	43
4.5 ผลการทดสอบการคำนวณค่าระดับความรุนแรง Total Severity Score (TSS)	47
4.6 อภิปรายผล	47
4.6.1 อภิปรายผลแบบจำลองแบ่งแยกกลีบปอด	47
4.6.2 อภิปรายผลแบบจำลองทำนายพื้นที่รอยโรค	48
4.6.3 อภิปรายผลการคำนวณค่าระดับความรุนแรง Total Severity Score (TSS)	49
4.7 หน้าต่างผู้ใช้งาน	50
4.8 ผลการประเมินหน้าต่างผู้ใช้งาน	53
บทที่ 5 สรุปผลการดำเนินงาน	55
5.1 สรุปการดำเนินงาน	55
5.2 บัญญาที่เพิ่มและภารกิจ	55
5.2.1 การเตรียมข้อมูล (Data Preparation)	55
5.2.2 การฝึกฝนแบบจำลอง (Model Training)	55
5.2.3 หน้าต่างผู้ใช้งาน (User Interface)	55
5.3 แนวทางการพัฒนา	56
5.3.1 ชุดข้อมูล	56
5.3.2 แนวทางการพัฒนาแบบจำลอง	56
5.3.3 แนวทางการพัฒนาหน้าต่างผู้ใช้งาน	56
หนังสืออ้างอิง	57
APPENDIX	59
A	60
B	64

สารบัญตาราง

ตารางที่	หน้า
2.1 เกณฑ์การประเมินความผิดปกติจากภาพ CT Lung สำหรับการวินิจฉัยภาวะปอดอักเสบในผู้ป่วยโรคโควิด-19	6
2.2 เกณฑ์การแบ่งระดับความรุนแรงของการจาก Total Severity Score (TSS)	6
2.3 ค่า Dice Similarity Coefficient (DSC) ของแบบจำลองแบบต่าง ๆ ในการศึกษาของ Xiao et al.	17
2.4 เกณฑ์การประเมินความผิดปกติจากภาพ CT lung ในการศึกษาของ Qiblawey et al.	18
2.5 ค่า Dice Similarity Coefficient (DSC) ของแบบจำลองในการศึกษาของ Chen et al.	18
2.6 ค่า Dice Similarity Coefficient (DSC) ในการศึกษาของ Tang et al.	19
3.1 ตารางแสดงจำนวนข้อมูลในแต่ละประเภท	23
3.2 ตารางแสดงข้อมูลของชุดข้อมูล Training Set	23
3.3 ตารางแสดงข้อมูลของชุดข้อมูล Test Set 1	23
3.4 ตารางแสดงข้อมูลของชุดข้อมูล Test Set 2	24
3.5 รายละเอียดพารามิเตอร์ของการปรับสีแบบ CLAHE	25
3.6 รายละเอียดการปรับพารามิเตอร์	26
3.7 รายละเอียดพารามิเตอร์ของแบบจำลอง (Lung Lobe Model Training Parameters)	26
3.8 รายละเอียดพารามิเตอร์ของแบบจำลอง (Lesion Model Training Parameters)	27
4.1 ตารางเปรียบเทียบผลการปรับ Loss Function	38
4.2 ตารางเปรียบเทียบผลการปรับ Regularizer	38
4.3 ตารางเปรียบเทียบผลการตั้งค่า L2 Regularizer	38
4.4 ตารางเปรียบเทียบการปรับค่า Dropout ของแบบจำลองแบ่งส่วนกลีบปอด	38
4.5 ตารางเปรียบเทียบการปรับค่า Dropout ของแบบจำลองแบ่งส่วนรอยโรค	38
4.6 ผลการทดสอบแบบจำลองกับชุดข้อมูล Test Set 1 โดยใช้ภาพต้นฉบับ Raw Image	39
4.7 ผลการทดสอบแบบจำลองกับชุดข้อมูล Test Set 1 โดยใช้วิธีปรับสีภาพ CLAHE	39
4.8 ผลการแบ่งแยกกลีบปอดของแบบจำลอง 3D-UNet + DenseNet169 กับชุดข้อมูล Test Set 1 ในแต่ละระดับความรุนแรงของโรค	40
4.9 ผลการทดสอบแบบจำลองกับชุดข้อมูล Test Set 1 โดยใช้ภาพต้นฉบับ Raw Image	43
4.10 ผลการทดสอบแบบจำลองกับชุดข้อมูล Test Set 1 โดยใช้วิธีปรับสีภาพ CLAHE	43
4.11 ผลการทำนายพื้นที่รอยโรคของแบบจำลอง 3D-UNet + DenseNet169 กับชุดข้อมูล Test Set 1 แต่ละระดับความรุนแรงของโรค	44
4.12 ผลการวิเคราะห์ค่าทางสถิติ (Regression Statistic)	47
4.13 ผลการวิเคราะห์ค่าทางสถิติ (Regression Statistic) ของค่า TSS ของทั้ง 3 วิธี	49
A.1 คำถานสำหรับการประเมินหน้าต่างผู้ป่วย	62

สารบัญ

รูปที่	หน้า
1.1 ตารางการดำเนินงาน ภาคการศึกษาที่ 1/2564	3
1.2 ตารางการดำเนินงาน ภาคการศึกษาที่ 2/2564	4
2.1 กายวิภาคของปอด	7
2.2 โครงสร้างของปอด	7
2.3 การแบ่งส่วนภาพแบบ Semantic Segmentation	8
2.4 โครงข่ายประสาทเทียม	9
2.5 โครงข่ายประสาทคอนโวลูชัน	9
2.6 ตัวอย่างการทำ Feature Map	9
2.7 ตัวอย่างการทำ Max Pooling ขนาด 2×2	10
2.8 โครงข่ายประสาทคอนโวลูชันเต็มรูปแบบ	10
2.9 โครงสร้างแบบจำลอง U-Net	11
2.10 โครงสร้างแบบจำลอง 3D-UNet	11
2.11 แนวคิดพื้นฐานของ ResNet	12
2.12 โครงสร้างโดยรวมของ ResNet	12
2.13 โครงสร้างพื้นฐานของ ResNet	13
2.14 โครงสร้าง Dense Block	13
2.15 โครงสร้าง DenseNet ที่มี 3 Dense Blocks	14
2.16 โครงสร้างแต่ละแบบจำลองของ DenseNet	14
2.17 กราฟเปรียบเทียบความแตกต่างของค่า Loss ต่อตัวแปร γ ที่เปลี่ยนไป	15
2.18 ตารางเปรียบเทียบประสิทธิภาพผลการศึกษาของงานวิจัยที่เกี่ยวข้อง	20
3.1 ภาพรวมของการดำเนินงาน	22
3.2 การระบุตำแหน่งรอยโรคและกลับปอดโดยโปรแกรม LabelME	24
3.3 แผนภาพการทำงานของแบบจำลอง	25
3.4 ตัวอย่างหน้าต่างผู้ใช้งานที่สร้างโดย Streamlit Library	28
3.5 Use Case Diagram	29
3.6 Sequence Diagram ของการทำงานและบันทึกผลของผู้ป่วยโรค covid-19	30
3.7 Activity Diagram	30
4.1 ตัวอย่างข้อมูลดิบ (Raw Data) ในประเทศไทยของกลุ่มความรุนแรง	32
4.2 ภาพเปรียบเทียบข้อมูลดิบและข้อมูลที่มีการระบุรายละเอียด	32
4.3 กายวิภาคของภาพถ่ายรังสีคอมพิวเตอร์ปอดปกติ และปอดที่ติดเชื้อ covid-19	33
4.4 ภาพเปรียบเทียบก่อน-หลังการระบุพื้นที่กีบปอด	33
4.5 ภาพเปรียบเทียบก่อน-หลังการระบุพื้นที่รอยโรค	34
4.6 ภาพที่ผ่านการระบุตำแหน่งกลับปอดและรอยโรคในแต่ละประเภทความรุนแรง	35
4.7 ตัวอย่างไฟล์ JSON ที่ได้จากการทำงานโปรแกรม LabelME	35
4.8 ภาพของการเตรียมไฟล์ JSON บางส่วนของเคส Mild 04	36
4.9 ตัวอย่างภาพต้นฉบับ (Raw Image) และภาพที่ผ่านการปรับสี (CLAHE)	37
4.10 ภาพตัวอย่างผลการแบ่งส่วนกลับปอดของแต่ละแบบจำลองกับภาพต้นฉบับ	41
4.11 ภาพตัวอย่างผลการแบ่งส่วนกลับปอดของแต่ละแบบจำลองกับภาพปรับสีแบบ CLAHE	42
4.12 ภาพตัวอย่างผลการแบ่งส่วนรอยโรคของแต่ละแบบจำลองกับภาพต้นฉบับ	45
4.13 ภาพตัวอย่างผลการแบ่งส่วนรอยโรคของแต่ละแบบจำลองกับภาพปรับสีแบบ CLAHE	46
4.14 ภาพแผนภูมิจุดแสดงการกระจายตัวของค่า TSS ระหว่างค่าที่ประเมินโดยรังสีแพทย์ (Radiologist) และค่าที่ได้จากการคำนวนแบบจำลอง (Predictions)	47
4.15 ตารางเปรียบเทียบประสิทธิภาพแบบจำลองแบ่งส่วนกลับปอดของโครงงานนี้กับงานวิจัยที่เกี่ยวข้อง	48
4.16 ตารางเปรียบเทียบประสิทธิภาพแบบจำลองแบ่งส่วนรอยโรคของโครงงานนี้กับงานวิจัยที่เกี่ยวข้อง	49

4.17	ภาพแผนภูมิจุดแสดงการกระจายตัวของค่า TSS (A) คือค่า TSS (GT) เทียบกับค่า TSS (Radiologist), (B) คือค่า TSS (GT) เทียบกับ TSS (Prediction) และ (C) คือค่า TSS (Prediction) เทียบกับ TSS (Radiologist)	50
4.18	หน้าต่างปุ่มใช้งาน	50
4.19	หน้าต่างปุ่มใช้งานขณะนำข้อมูลเข้า	51
4.20	หน้าต่างปุ่มใช้งานแสดงผลการวิเคราะห์ชุดภาพ CT Scans	51
4.21	ตัวอย่างรูปแบบไฟล์ PDF ของผู้ป่วยโควิด-19	52
4.22	ตัวอย่างรูปแบบไฟล์ CSV	53
4.23	ตัวอย่างรูปแบบไฟล์ CSV ที่เปิดใน Microsoft Excel	53
4.24	ผลการประมวลผลหน้าต่างปุ่มใช้งานในด้านต่าง ๆ	54
A.1	ภาพเบรี่ยบเทียบการปรับสีภาพด้วยวิธีการ CLAHE (OpenCV)	60
A.2	ภาพเบรี่ยบเทียบการปรับสีภาพด้วยวิธีการ Histograms Equalization (OpenCV)	61
A.3	ภาพเบรี่ยบเทียบการปรับสีภาพด้วยวิธีการปรับ Contrast และ Brightness	62
B.4	หน้าเรียบไซต์แสดงไฟล์ Source Code ของโครงงาน	64

บทที่ 1 บทนำ

1.1 ความสำคัญของปัญหา

ความรุนแรงของภาวะปอดอักเสบที่ติดเชื้อรหัส CT ถูกนำมาใช้เพื่อการคัดแยกและดูแลรักษาผู้ป่วยโรคโควิด-19 ซึ่งโดยทั่วไปรังสีแพทย์หรือแพทย์ผู้เชี่ยวชาญด้านภาพถ่ายรังสีจะทำการคัดแยกระดับความรุนแรงของผู้ป่วยจากการประเมินค่าระดับความรุนแรง Total Severity Score (TSS) โดยพิจารณาร้อยละของรอยโรคที่พบในแต่ละกลีบปอด อย่างไรก็ตามรังสีแพทย์นั้นเป็นสาขางานที่ขาดแคลน ในขณะที่สถานการณ์ปัจจุบันการแพร่ระบาดขยายเป็นวงกว้างและมีจำนวนผู้ติดเชื้อเพิ่มขึ้นอย่างต่อเนื่อง จึงทำให้เกิดปัญหาความล่าช้าในการรายงานผลความรุนแรงของภาวะปอดอักเสบ นอกจากนี้จำนวนภาระงานที่เพิ่มมากขึ้นยังอาจส่งผลต่อความแม่นยำในการแปลผลของรังสีแพทย์อีกด้วย

เทคโนโลยีคอมพิวเตอร์วิศวกรรม (Computer Vision) ได้ถูกพัฒนามาอย่างต่อเนื่อง และมีการนำมาใช้เพื่อวิเคราะห์รูปถ่ายทางการแพทย์ได้อย่างมีประสิทธิภาพ ทางคณะผู้จัดทำเชิงมีความเห็นว่า องค์ความรู้ดังกล่าวสามารถนำมาประยุกต์ใช้ในการแบ่งส่วนกลีบปอด และแบ่งส่วนรอยโรคในภาพถ่าย Lung CT ได้ ดังนั้นโครงการนี้จึงมีวัตถุประสงค์ที่จะประยุกต์ใช้เทคโนโลยีการเรียนรู้เชิงลึก (Deep Learning) เพื่อใช้ในการวินิจฉัยรอยโรคจากภาพ Lung CT โดยแบบจำลองจะถูกออกแบบให้สามารถทำการระบุพื้นที่รอยโรคและกลีบปอด พร้อมทั้งคำนวณร้อยละของรอยโรคที่เกิดขึ้นแบบอัตโนมัติ เพื่อช่วยลดภาระและระยะเวลาการแปลผลภาพถ่ายของรังสีแพทย์ ทำให้การรายงานผลมีความแม่นยำและรวดเร็วมากยิ่งขึ้น

1.2 ประเภทของโครงการ

งานวิจัย

1.3 วิธีการที่นำเสนอด้วย

1.3.1 วิธีการที่ใช้

- หน่วงวนรวมและทฤษฎีที่เกี่ยวข้องกับการแบ่งส่วนภาพ (Image Segmentation) และการประเมินความรุนแรงของภาวะปอดอักเสบในผู้ป่วยโรคโควิด-19 จากค่าระดับความรุนแรง Total Severity Score (TSS)
- ติดต่อหน่วยงานของโรงพยาบาลจุฬาภรณ์เพื่อขอสิทธิการเข้าถึงข้อมูลการตรวจ Lung CT Scan ของผู้ป่วยที่ได้รับการตรวจวินิจฉัยการติดเชื้อโรคโควิด-19
- ศึกษาและระบุรอยโรคจากภาพด้วยเครื่องมือสร้างคำอธิบายประกอบ
- ศึกษาและประยุกต์ใช้เทคนิคการแบ่งส่วนภาพ (Semantic Segmentation) ในการแบ่งส่วนกลีบปอดและแบ่งส่วนรอยโรค
- แบ่งกลุ่มความรุนแรงของอาการโดยการคำนวณร้อยละการติดเชื้อของเนื้อปอด ซึ่งสามารถนำไปได้จากพื้นที่รอยโรคและพื้นที่แหล่งกลีบปอด
- สร้างหน้าต่างผู้ใช้งาน (User Interface: UI) เพื่ออำนวยความสะดวกในการทำงาน

1.3.2 วัตถุประสงค์

- เพื่อประยุกต์ใช้เทคโนโลยีการเรียนรู้เชิงลึกในการแบ่งส่วนกลีบปอด และแบ่งส่วนรอยโรคจากภาพถ่ายรังสีคอมพิวเตอร์ปอด
- เพื่อสร้างหน้าต่างโปรแกรมที่จะช่วยเหลือบุคลากรทางการแพทย์ให้สามารถวินิจฉัยพื้นที่รอยโรคให้เกิดความแม่นยำ และรวดเร็วมากยิ่งขึ้น

1.3.3 เทคโนโลยีที่ใช้

การเตรียมข้อมูล

- LabelME เป็นเครื่องมือสร้างคำอธิบายประกอบ (Annotation Tool)

ส่วนการวิเคราะห์ข้อมูล

- ใช้แบบจำลองโครงสร้างแบบ 3D-UNet สำหรับการทำ Semantic Segmentation
- Backbone ที่ใช้คือแบบจำลองที่ผ่านการฝึกฝน (Pre-Trained Model) เช่น DenseNet, ResNet
- Lesion Area Calculation (Pixel Aspect Ratio)

การแสดงผล

- Streamlit (Open Source Python Library)

1.3.4 ขอบเขตของโครงงาน

ชุดข้อมูลที่ใช้ในโครงการนี้เป็นภาพถ่ายรังสีคอมพิวเตอร์ปอดชนิดภาพตัดขวางของผู้ป่วยโรคโควิด-19 ทั้งพบรอยโรค และไม่พบรอยโรคในปอด คณานุจัดทำจะประยุกต์ใช้การเรียนรู้เชิงลึกเพื่อสร้างแบบจำลองที่สามารถแบ่งส่วนกลับปอด และแบ่งส่วนรอยโรคที่พบรอยในแต่ละแผ่นสำหรับของภาพ Lung CT และให้ผลลัพธ์เป็นร้อยละของพื้นที่เกิดพยาธิสภาพ จากนั้นจะพัฒนาหน้าต่างผู้ใช้งาน (User Interface) เพื่อสร้างเป็นหน้าต่างโปรแกรมที่สามารถใช้งานได้สะดวก

1.4 เนื้อหาทางวิศวกรรมที่เป็นต้นฉบับ

1.4.1 Semantic Segmentation

การแบ่งส่วนภาพในระดับพิกเซล โดยจำแนกแต่ละพิกเซลในภาพว่าเป็นพิเกชลของวัตถุใดในภาพ โดยผลลัพธ์ที่ได้จะเป็นภาพที่มีการระบุค่าชนิดในแต่ละพิกเซล และมีขนาดความละเอียดเท่ากับขนาดของภาพนำเข้า

1.5 การแยกย่อยงาน และแผนการดำเนินงาน

1.5.1 ภาคเรียนที่ 1

ศึกษาค้นหัวข้อที่สนใจ (Project Idea)

- เสนอหัวข้อโครงการกับอาจารย์ที่ปรึกษา

ข้อเสนอโครงการ (Project Proposal)

- ศึกษางานวิจัยที่เกี่ยวข้อง
- จัดทำข้อเสนอโครงการ
- Annotation Tools Review
- นำเสนอข้อเสนอโครงการ

เตรียมข้อมูล (Data Preparation)

- ศึกษาการระบุรอยโรคของปอด
- Image Annotation

พัฒนาแบบจำลอง (Model Development)

- ศึกษาการทำ Image Segmentation
- Lung Lobe Model
- Lesion Model

รายงานโครงการ (Term 1 Report)

- จัดทำรายงานโครงการบทที่ 1, 2 และ 3
- นำเสนอโครงการ 3 บท

ตารางการดำเนินงาน ภาคการศึกษาที่ 1/2564

หัวข้อ	สิงหาคม				กันยายน				ตุลาคม				พฤศจิกายน				ธันวาคม			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
ศึกษาหัวข้อที่สนใจ		■	■																	
ข้อเสนอโครงการ																				
- ศึกษาเรื่องวิจัยที่เกี่ยวข้อง					■	■	■	■												
- จัดทำข้อเสนอโครงการ						■	■	■	■	■										
- Annotation Tools Review																				
- นำเสนอข้อเสนอโครงการ									■	■										
การเตรียมข้อมูล										■										
- Lung Lesion Study											■									
- Training Data Annotation											■	■	■	■	■	■	■	■	■	
- Testing Data Annotation												■	■	■	■	■	■	■	■	■
การพัฒนาแบบจำลอง																	■	■	■	■
- ศึกษาการทำ Image Segmentation																	■	■	■	■
- Lung Lobe Model																	■	■	■	■
- Lesion Model																	■	■	■	■
จัดทำรายงานโครงการบทที่ 1, 2, 3											■	■	■	■	■	■				
นำเสนอโครงการ 3 บท																		■		

รูปที่ 1.1: ตารางการดำเนินงาน ภาคการศึกษาที่ 1/2564

1.5.2 ภาคเรียนที่ 2

เตรียมข้อมูลชุดทดสอบ

- Test Set 1 Image Annotation

การพัฒนาแบบจำลอง (ต่อ)

- Lung Lobe Model

- Lesion Model

ปรับปรุงและทดสอบแบบจำลองกับชุดข้อมูล Test Set 1

- Lung Lobe Model Testing and Tuning
- Lesion Model Testing and Tuning

พัฒนาหน้าต่างผู้ใช้งาน (User Interface Development)

- จัดทำหน้าต่างผู้ใช้งาน
- ประยุกต์แบบจำลองมาใช้ทำงานการติดเชื้อ (Model Implementation)
- ทดสอบการทำนายค่าระดับความรุนแรงกับชุดข้อมูล Test Set 2

รายงานโครงการ (Term 2 Report)

- จัดทำรายงานโครงการฉบับสมบูรณ์ และไปสเตอร์
- นำเสนอโครงการ

ตารางการดำเนินงาน ภาคการศึกษาที่ 2/2564

■ ทุกคน ■ พนักพันธ์ ■ ปรัชญา ■ กศกร

หัวข้อ	มกราคม				กุมภาพันธ์				มีนาคม				เมษายน				พฤษภาคม			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
เตรียมข้อมูลชุดทดสอบ																				
Test Set 1 Image Annotation																				
การพัฒนาแบบจำลอง (ต่อ)																				
- Lung Lobe Model																				
- Lesion Model																				
ปรับปรุงและทดสอบแบบจำลอง																				
- Lung Lobe Model Testing/Tuning																				
- Lesion Model Testing/Tuning																				
การพัฒนาหน้าต่างผู้ใช้งาน																				
- พัฒนาหน้าต่างผู้ใช้งาน																				
- Model Implementation																				
- ทดสอบการทำนายค่าระดับความรุนแรงกับชุดข้อมูล Test Set 2																				
จัดทำรายงานโครงการฉบับสมบูรณ์ และไปสเตอร์																				
นำเสนอโครงการ																				

รูปที่ 1.2: ตารางการดำเนินงาน ภาคการศึกษาที่ 2/2564

1.6 ผลการดำเนินงานใน

ภาคการศึกษาที่ 1

1. รายงานวิจัยบทที่ 1, 2 และ 3
2. ภาพถ่ายรังสีคอมพิวเตอร์ปอดที่มีการระบุแบ่งส่วนกลีบปอดและรอยโรค

ภาคการศึกษาที่ 2

1. รายงานวิจัยฉบับสมบูรณ์
2. แบบจำลองสำหรับการแบ่งส่วนกลีบปอดและรอยโรค
3. หน้าต่างผู้ใช้งานที่สามารถแสดงผลการวิเคราะห์รอยโรคในภาพ Lung CT

บทที่ 2 ที่มา ทฤษฎี และงานวิจัยที่เกี่ยวข้อง

2.1 ที่มาและความสำคัญ

โรคโควิด-19 มีสาเหตุมาจากการติดเชื้อไวรัสโคโรนา โดยการแพร่ระบาดเริ่มต้นเมื่อเดือนธันวาคม พ.ศ. 2562 และแพร่ขยายเป็นวงกว้างทั่วโลกอย่างรวดเร็ว จากข้อมูลของกระทรวงสาธารณสุขพบว่าในขณะนี้ประเทศไทยมีผู้ติดเชื้อรายใหม่มากถึง 23,584 คน (ข้อมูลณ วันที่ 13 มีนาคม 2565) [1] และแนวโน้มการระบาดของโรคโควิด-19 ยังคงพบผู้ติดเชื้อรายใหม่อีกอย่างต่อเนื่อง

ผู้ติดเชื้อโรคโควิด-19 ส่วนใหญ่มักมีอาการทางเดินระบบหายใจ เช่น ไอ หายใจลำบาก โดยในผู้ป่วยบางรายอาจเกิดอาการปอดอักเสบรุนแรงจนต้องใช้เครื่องช่วยหายใจ และมีความเสี่ยงที่จะเสียชีวิตจากการทางเดินหายใจล้มเหลว [2] ภาพถ่ายรังสีคอมพิวเตอร์ปอดจึงมีบทบาทสำคัญในการตรวจประเมินความรุนแรงของโรค เพื่อการรักษาที่ทันถ้วนทันใจ

นอกจากนี้จากสถานการณ์การแพร่ระบาดที่รุนแรง ทำให้มีผู้ติดเชื้อสะสมเป็นจำนวนมาก จนเกิดปัญหาการรับมือที่เกินกำลังของสถานพยาบาล กรรมการแพทย์จึงออกแนวทางเวชปฏิบัติ การวินิจฉัย ดูแลรักษา และบ่องกันการติดเชื้อในโรงพยาบาล กรณีโรคติดเชื้อโควิด-19 โดยให้แพทย์อาศัยข้อมูลอาการร่วมกับผลตรวจจากภาพถ่ายรังสีคอมพิวเตอร์ปอดในการบริหารจัดการผู้ป่วยโรคโควิด-19 [3]

การถ่ายภาพรังสีคอมพิวเตอร์ปอด (Lung CT) โดยเครื่องถ่ายรังสีคอมพิวเตอร์เป็นเครื่องมือวินิจฉัยภาพถ่ายรังสีที่ถูกแนะนำให้ใช้ในการตรวจวินิจฉัยโรคโควิด-19 ลักษณะความผิดปกติที่พบได้บ่อยในภาพถ่ายคือ พื้นที่ฝ้าขาว (Ground Glass Opacity: GGO) และແຄบปั้นขาว (Consolidation) โดยสามารถพับได้ในปอดทั้งสองข้าง [2] การประเมินความรุนแรงของภาวะปอดอักเสบในผู้ป่วยโรคโควิด-19 สามารถทำได้หลายวิธี โดยวิธีที่นิยมใช้คือ Total Severity Score (TSS) ซึ่งเป็นการประเมินเชิงปริมาณ โดยพิจารณาร้อยละของรอยโรคที่เกิดขึ้นในปอดด้วยสายตา จำนวนให้คะแนนพาริธิสภาพ หรือสภาพรอยโรค ที่เกิดขึ้นในปอดแต่ละกลีบปอด (บนขวา กลางขวา ล่างขวา บนซ้าย และล่างซ้าย) ตามตารางที่ 2.1 และคิดคะแนนรวมของปอดทุกกลีบ ซึ่งจะมีค่าอยู่ระหว่าง 0 ถึง 25 [4, 5, 6]

จากรายงานของ Francone et al. พบว่า CT Score ของผู้ป่วยโรคโควิด-19 ที่อยู่ในกลุ่มอาการรุนแรงและอาการวิกฤติสูงขึ้นอย่างมีนัยสำคัญทางสถิติ เมื่อเปรียบเทียบกับผู้ป่วยที่ไม่มีอาการหรือมีอาการน้อย (Mild Disease) โดยค่าเฉลี่ยของ CT Score ในผู้ป่วยกลุ่ม Mild, Severe และ Critical มีค่าเท่ากับ 8, 18 และ 20 ตามลำดับ นอกจากนี้ Francone et al. ยังแนะนำว่าผู้ป่วยที่มี CT Score ระดับ 18 คะแนนขึ้นไปควรได้รับการเฝ้าระวังอาการอย่างใกล้ชิด เนื่องจากมีความเสี่ยงสูงที่จะเสียชีวิตภายในระยะเวลาอันสั้นหลังจากตรวจพบ [5] ในอีกรายงานของ Guan X et al. มีการประเมินร้อยละของพื้นที่รอยโรคในแต่ละกลีบปอดตามตารางที่ 2.1 และนำผลคะแนนรวม TSS มาใช้แบ่งความรุนแรงของภาวะปอดอักเสบในผู้ป่วยโรคโควิด-19 ออกเป็น 3 ระดับ คือ Mild, Moderate และ Severe โดยเกณฑ์การแบ่งระดับความรุนแรงแสดงดังตารางที่ 2.2 [6]

จากรายงานทั้งสองฉบับจะเห็นได้ว่าข้อมูลความรุนแรงของพาริธิสภาพในปอดนั้นมีความสำคัญต่อการประเมินอาการผู้ติดเชื้อ ดังนั้นผลการตรวจภาพถ่ายรังสีคอมพิวเตอร์ปอดที่แม่นยำจึงเป็นปัจจัยหนึ่งที่จะนำไปสู่การจัดการปัญหาโรคติดเชื้อโควิดที่มีประสิทธิภาพ

ตารางที่ 2.1 เกณฑ์การประเมินความผิดปกติจากภาพ CT Lung สำหรับการวินิจฉัยภาวะปอดอักเสบในผู้ป่วยโรคโควิด-19

รอยโรคที่พบใน CT	คะแนน
ไม่พบ	0
น้อยกว่าร้อยละ 5	1
ร้อยละ 6-25	2
ร้อยละ 26-50	3
ร้อยละ 51-75	4
มากกว่าร้อยละ 75	5

ตารางที่ 2.2 เกณฑ์การแบ่งระดับความรุนแรงของอาการจาก Total Severity Score (TSS)

คะแนน	ประเภทความรุนแรง
≤ 7	Mild
8-17	Moderate
≥ 18	Severe

2.2 ทฤษฎีและแนวคิดหลัก

2.2.1 กายวิภาคของปอด (Lung Anatomy)

2.2.1.1 ตำแหน่งของปอด

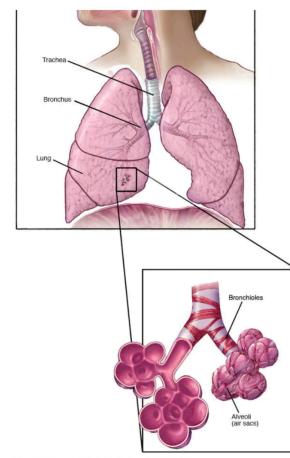
ปอด (Lung) มีทั้งหมด 2 ข้าง คือ ข้างซ้ายและข้างขวา โดยจะอยู่ในช่องทรวงอกตั้งแต่ระดับกระดูกใหญ่ไปถึงกระดูกชาย โครงของร่างกาย โดยมีกระดูกซี่โครงและกล้ามเนื้อระหว่างซี่โครงล้อมอยู่เพื่อทำหน้าที่ป้องกันไม่ให้ปอดเสียหาย และมีกล้ามเนื้อของกลุ่ม (Diaphragm) กันด้านล่างของปอดทั้งสองข้างกับช่องท้อง ซึ่งระหว่างปอดทั้งสองข้างจะเป็นที่ตั้งของหัวใจและต่อมไทรอยด์



รูปที่ 2.1: กายวิภาคของปอด
(ที่มา: <https://theconversation.com> อ้างอิง ณ วันที่ 15/03/2022)

2.2.1.2 โครงสร้างของปอด

ปอดเป็นอวัยวะในร่างกายที่มีลักษณะคล้ายกับฟองน้ำ เพราะมีถุงลมขนาดเล็ก (Alveoli) อยู่มาก โดยปอดข้างขวาจะแบ่งออกเป็น 3 กลีบ (Lobe) และปอดข้างซ้ายจะแบ่งออกเป็น 2 กลีบ (Lobe) รวมทั้งหมด 5 กลีบ ได้แก่ กลีบบน (Right/Left Upper Lobe) กลีบกลาง (Right Middle Lobe) และกลีบล่าง (Right/Left Lower Lobe) โดยภายในปอดจะมีท่อนำอากาศหลักหลายขนาด ตั้งแต่ขนาดใหญ่ที่สุดที่ชื่อปอดที่เรียกว่า Main Bronchus ซึ่งแตกออกเป็นสองขั้วซ้ายและขวาจากหลอดลม (Trachea) เพื่อนำอากาศเข้าสู่ปอดทั้งสองข้าง และแตกย่อยออกเป็นบรรจงคัศขนาดเล็ก (Small Bronchus) ก่อนจะแยกย่อยออกเป็นหลอดลมฟอย (Bronchiole) เพื่อกระจายอากาศเข้าสู่ถุงลมขนาดเล็ก เพื่อแลกเปลี่ยนก๊าซ [7]



รูปที่ 2.2: โครงสร้างของปอด

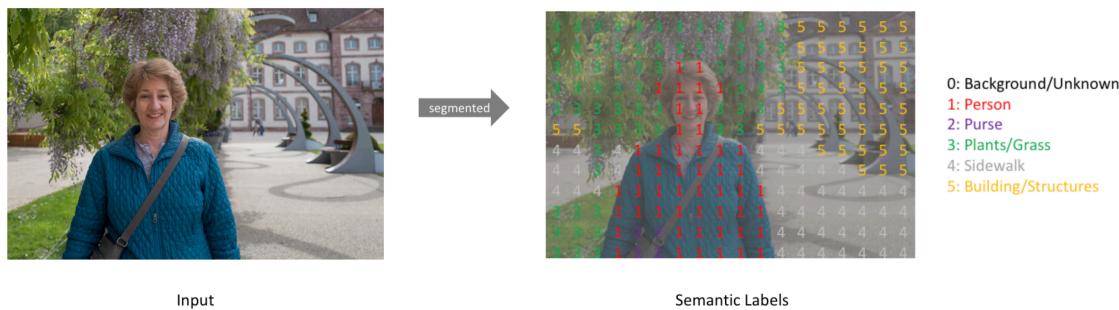
2.2.1.3 หน้าที่ของปอด

ปอดถือเป็นอวัยวะหลักของระบบทางเดินหายใจ (Respiratory System) ในร่างกายมนุษย์ ซึ่งมีหน้าที่หลักอยู่ 3 ประการ ได้แก่

- นำก๊าซเข้าและออก เมื่อร่างกายนำอากาศเข้าผ่านทางจมูก และหลอดลมไปถึงปอดแล้ว อากาศจะถูกทำให้ชื้นขึ้นจากการเติมไอน้ำ และถูกเก็บไว้ในถุงลม ปอดจะทำการแลกเปลี่ยนก๊าซออกซิเจน (O_2) ให้เข้าหลอดเลือดฝอยผ่านผนังถุงลมกับอาเก้าชาร์บอนไดออกไซด์ (CO_2) ในหลอดเลือดฝอยเข้าถุงลม จากนั้นปอดจะนำก๊าชาร์บอนไดออกไซด์ออกจากร่างกายทางจมูก โดยผ่านระบบทางเดินหายใจ
- เปลี่ยนเลือดที่มีออกซิเจนต่ำให้เป็นเลือดที่มีออกซิเจนสูง หน้าที่นี้ปอดจะทำงานร่วมกับหัวใจในระบบหมุนเวียนโลหิต (Circulatory System) โดยหัวใจจะส่งเลือดที่มีออกซิเจนต่ำจากหัวใจห้องล่างข้ามมาที่ปอดโดยหลอดเลือด และทำการแลกเปลี่ยนก๊าซออกซิเจน กับก๊าชาร์บอนไดออกไซด์ให้เป็นเลือดที่มีออกซิเจนสูงแล้วส่งกลับไปยังหัวใจห้องบนท้ายโดยผ่านหลอดเลือดเช่นเดียวกัน
- การปรับสมดุลกรด-ด่างภายในร่างกาย หน้าที่นี้ปอดจะทำงานร่วมกับไต เพื่อคงความสมดุลของร่างกายให้มีค่าพีโอช (Potential of Hydrogen Ion : pH) อยู่ที่ 7.4 [8]

2.2.2 การแบ่งส่วนภาพ (Semantic Segmentation)

การแบ่งส่วนภาพ (Semantic Segmentation) เป็นการแบ่งภาพในระดับพิกเซล โดยการจำแนกในแต่ละพิกเซลว่าเป็นพิกเซลของวัตถุใดในภาพ ซึ่งผลลัพธ์ที่ได้จะเป็นภาพที่มีการระบุค่าชนิด (Class) ในแต่ละพิกเซลโดยที่ขนาดความละเอียดของข้อมูลจะเท่ากับขนาดของภาพนั้นๆ [9] ซึ่งการทำ Semantic Segmentation นั้น สามารถแบ่งออกได้เป็น Binary Semantic Segmentation และ Multiclass Semantic Segmentation ซึ่งเป็นกระบวนการพิเศษจากภาพ โดยที่แต่ละภาพมีคลาสเป้าหมายได้ตั้งแต่ 2 คลาสขึ้นไป ดังรูปที่ 2.3 แสดงตัวอย่าง Multiclass Semantic Segmentation ซึ่งมีคลาสเป้าหมายทั้งหมด 6 คลาส รวมคลาสพื้นหลัง (Background)

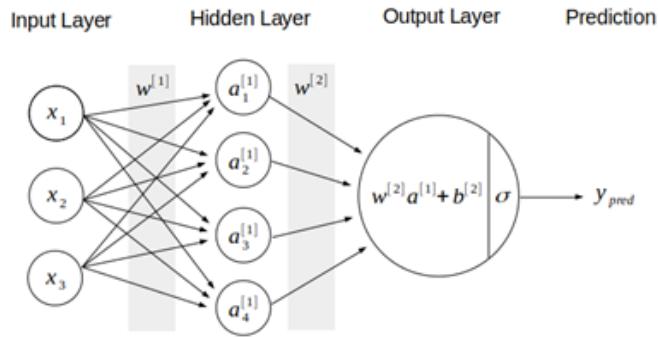


รูปที่ 2.3: การแบ่งส่วนภาพแบบ Semantic Segmentation
(ที่มา: <https://www.jeremyjordan.me/semantic-segmentation/> อ้างอิง ณ วันที่ 21/03/2022)

2.2.3 โครงข่ายประสาทเทียม (Artificial Neural Network: ANN)

โครงสร้างของโครงข่ายประสาทเทียม คือ โครงข่ายที่ได้รับแรงบันดาลใจจากโครงสร้างเซลล์ประสาทของมนุษย์ โดยเซลล์จะรับข้อมูลจากเดนไดร์ตแล้วส่งข้อมูลผ่านแอகชันไปย์เซลล์คัตติไป ซึ่งเซลล์รับและส่งข้อมูลไปเรื่อยๆ จนเป็นโครงข่ายระบบประสาท

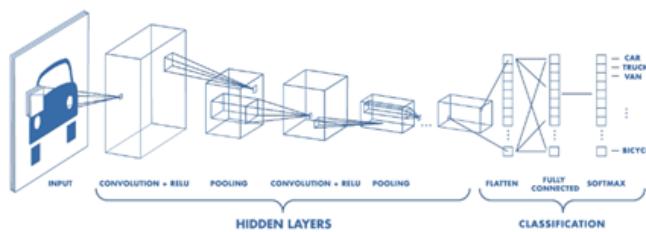
โครงสร้างของ ANN สามารถแบ่งลักษณะของขึ้นได้เป็น 3 รูปแบบคือ Input Layer, Hidden Layer และ Output Layer (รูปที่ 2.4) ในแต่ละชั้นจะมีหน่วยประมวลผลที่เรียกว่า нeuron (Neuron) ซึ่งมีหน้าที่คำนวณข้อมูลที่เข้ามาแล้วส่งค่าไปยังนิวรอนตัวถัดไป การคำนวณของนิวรอนนั้นจะมีพีซ์ก์ชันที่ใช้คำนวณเรียกว่า Activation Function และในการส่งข้อมูลไปในแต่ละนิวรอนจะมีการกำหนดค่าถ่วงน้ำหนัก (Weight) เมื่อส่งข้อมูลจากนิวรอนในชั้น Input Layer ไปยังชั้น Output Layer จะเรียกกระบวนการนี้ว่า Feed Forward การส่งข้อมูลแบบย้อนกลับเพื่อไปเปลี่ยนแปลงค่าถ่วงน้ำหนักจะเรียกว่า Backpropagation ซึ่งค่าที่ส่งกลับคือผลต่างของลักษณะที่แท้จริงกับผลลัพธ์ที่ แบบจำลองเกิดการเรียนรู้ [10]



รูปที่ 2.4: โครงข่ายประสาทเทียม
(ที่มา: <https://guopai.github.io/ml-blog14.html> อ้างอิง ณ วันที่ 10/09/2021)

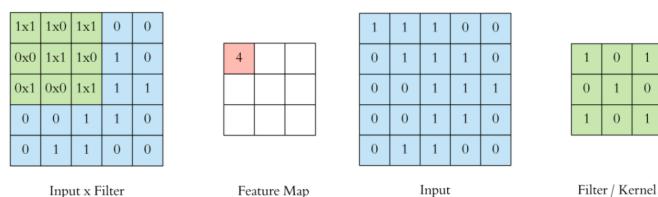
2.2.4 โครงข่ายประสาทคอนโวลูชัน (Convolutional Neural Network: CNN)

โครงข่ายประสาทคอนโวลูชัน คือ โครงข่ายที่จะจำลองลักษณะการมองเห็นโดยมีองค์ประกอบพื้นที่ส่วนย่อยก่อนที่จะทำการประมวลผลร่วมกันระหว่างแต่ละหน่วยทำงาน (Node) ในแต่ละชั้น (Layer) เพื่อประมวลผลว่าสิ่งที่สนใจนั้นคืออะไร โดยการทำงานจะแบ่งออกเป็น 3 ชั้น คือ Input Layer, Hidden Layer และ Output Layer โดยทั่วไปจะมีองค์ประกอบหลัก 3 ประการ ได้แก่ Convolutional Layer, Pooling Layer และ Fully-Connected Layer [11]



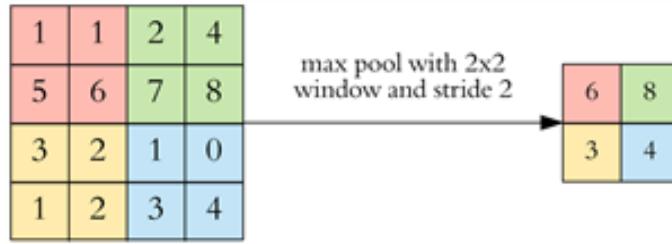
รูปที่ 2.5: โครงข่ายประสาทคอนโวลูชัน
(ที่มา: <https://towardsdatascience.com/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53> อ้างอิง ณ วันที่ 10/09/2021)

Convolutional Layer คือ การลดรูปของข้อมูลโดยอิงจากหลักการการดำเนินการทางคณิตศาสตร์ระหว่างข้อมูลสองชุด (Input กับ Filter/Kernel) ซึ่งผลลัพธ์ที่ได้มาจะส่งผลให้ขนาดของข้อมูลลดลง และเหลือเพียงข้อมูลที่เป็นประโยชน์แก่การวิเคราะห์ ซึ่งการทำ Convolution นั้นก็จะมีเทคนิคให้เลือกยกตัวอย่างเช่นการทำ Stride และ Padding



รูปที่ 2.6: ตัวอย่างการทำ Feature Map
(ที่มา: <https://towardsdatascience.com/applied-deep-learning-part-4-convolutional-neural-networks-584bc134c1e2#a86a> อ้างอิง ณ วันที่ 10/09/2021)

Pooling Layer คือ การย่อรูปแบบหนึ่ง ซึ่งมี 2 ประเภทหลักที่นิยมกันคือ Max Pooling และ Mean Pooling โดยการหาค่าสูงสุดหรือค่าเฉลี่ยตามขนาด Pool Size ของพิกเซลภาพ (รูปที่ 2.7)

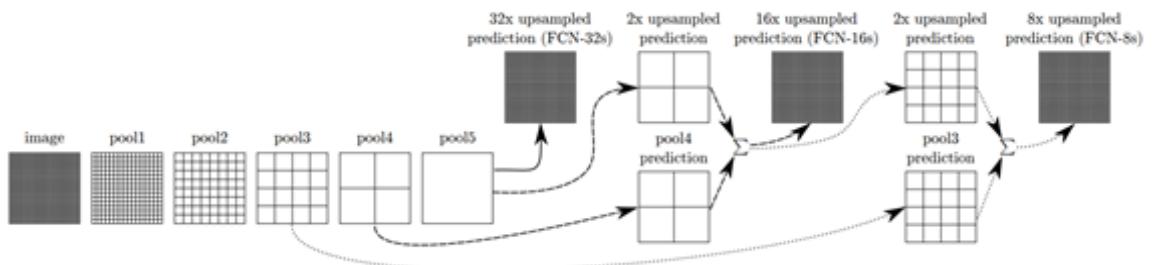


รูปที่ 2.7: ตัวอย่างการทำ Max Pooling ขนาด 2×2
(ที่มา: <https://towardsdatascience.com/applied-deep-learning-part-4-convolutional-neural-networks-584bc134c1e2#a86a> อ้างอิง ณ วันที่ 10/09/2021)

Fully-Connected Layer มีชั้นประมวลผล Convolutional Layer ที่สกัดข้อมูลจากภาพเป็นส่วนประกอบในชั้น Hidden Layer แต่ในบางครั้ง CNN ไม่ได้ถูกใช้กับภาพเสมอไป มีการนำไปประยุกต์กับข้อมูลที่มีเพียง 1 มิติด้วยเช่นกัน เช่น ข้อมูลประเภทข้อความ

2.2.5 โครงข่ายประสาทคอนโวลูชันเต็มรูป (Fully Convolutional Network: FCN)

Fully Convolutional Network (FCN) เป็นหนึ่งในวิธีการทำ Convolutional Neural Network ที่ถูกนำเสนอโดย Shelhamer et al. [12] โดย FCN จะมีเพียงการทำ Down-Sampling กับ Up-Sampling เท่านั้น (รูปที่ 2.8) ซึ่งจากการออกแบบโครงสร้างดังกล่าว ทำให้ FCN สามารถทำงานได้เร็วกว่าเดิม แนวคิดของ FCN ได้ถูกนำไปใช้ในวิธีการดำเนินการของหลาย ๆ แบบจำลอง เช่น U-Net, SegNet และ DeepLab



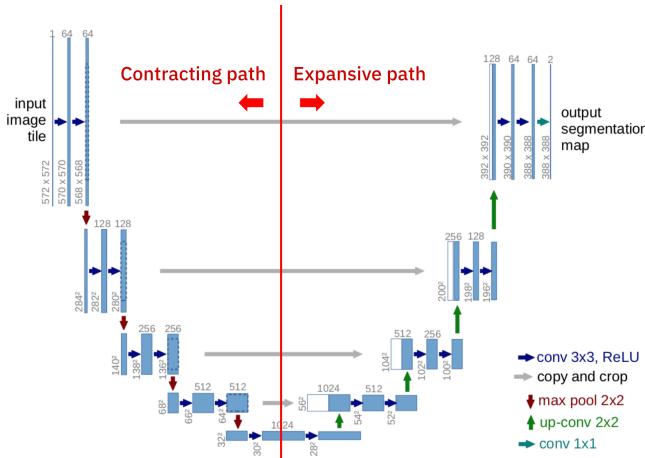
รูปที่ 2.8: โครงข่ายประสาทคอนโวลูชันเต็มรูปแบบ
(ที่มา: <https://www.mygreatlearning.com/blog/fcn-fully-convolutional-network-segmentation/> อ้างอิง ณ วันที่ 18/09/2021)

2.2.6 U-Net

U-Net คือ แบบจำลองโครงข่ายประสาทเทียมแบบ CNN ที่พัฒนาต่อจาก FCN โดยถูกนำเสนอเมื่อปี 2015 สำหรับการแบ่งส่วนภาพทางการแพทย์ (Biomedical Image Segmentation) ในการแบ่งส่วนภาพแบบ Semantic Segmentation [13] โดยผลลัพธ์ที่ได้จะมีขนาดเท่ากับภาพต้นฉบับที่ใส่เข้าไปในแบบจำลอง และค่าในแต่ละพิกเซลจะเป็น Label เพื่อบ่งบอกว่าพิกเซลนั้นเป็น Class อะไรในภาพ โครงสร้างแบบจำลอง U-Net มีลักษณะคล้ายตัว U และดังตัวอย่างที่ 2.9 ซึ่งประกอบด้วย 2 ส่วนหลัก ๆ ดังต่อไปนี้

Contracting Path (Encoder) คือ ส่วนที่รับภาพ (Input) เข้ามา ประกอบด้วย Convolutional Layer (Conv 3x3) และ Max-Pooling Layer สำหรับการทำ Down-Sampling เพื่อทำการตีกรอบออกจากภาพ (Feature Extraction) [14]

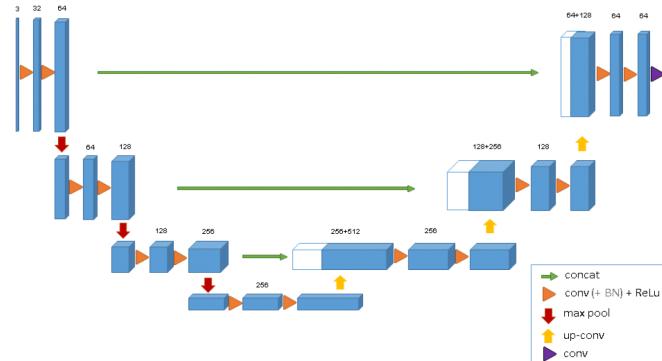
Expansive Path (Decoder) คือ ส่วนที่นำฟีเจอร์ที่ได้จากการสกัดภาพที่ได้รับการแบ่งส่วนโดยการทำ Transposed Convolution เพื่อขยายขนาด หรือที่เรียกว่า Up-Sampling (Up-Conv 2x2) ซึ่งยังมีการนำฟีเจอร์ที่รีดบันเดิมกัน (ลูกศรสีเทา รูปที่ 2.9) มาร่วมคำนวนด้วย ทำให้เรียนรู้แล้วขยายขนาดในแต่ละระดับได้ดียิ่งขึ้น และขั้นสุดท้าย (Conv 1x1) เพื่อแปลงขนาดของฟีเจอร์ให้เท่ากับจำนวน Class ที่ต้องการจะแบ่งส่วนในภาพ [14]



รูปที่ 2.9: โครงสร้างแบบจำลอง U-Net
(ที่มา: <https://arxiv.org/abs/1505.04597> ข้างอิง ณ วันที่ 10/09/2021)

2.2.7 3D-UNet

จากการวิจัยเมื่อปี 2016 ของมหาวิทยาลัย Greiburg [15] มหาวิทยาลัยเดียวกับผู้นำเสนอแบบจำลอง U-Net ได้นำเสนอวิธีการที่เป็นการต่อยอดจากเดิม ที่ใช้ลักษณะของ Input ที่เป็นเมทริกซ์ขนาดสองมิติที่แปลงเป็นเมทริกซ์ขนาดสามมิติแทน โดยชื่อแบบจำลองดังกล่าวคือ “3D-UNet”



รูปที่ 2.10: โครงสร้างแบบจำลอง 3D-UNet
(ที่มา: <https://towardsdatascience.com/review-3d-u-net-volumetric-segmentation-medical-image-segmentation-8b592560fac1> ข้างอิง ณ วันที่ 15/09/2021)

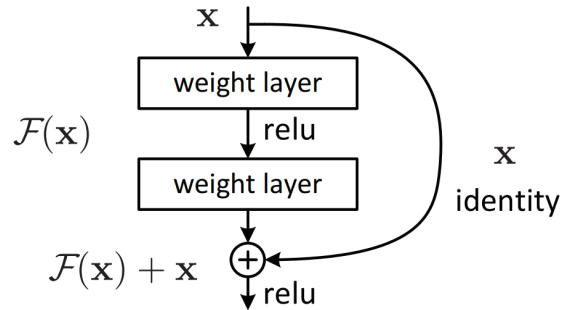
จากรูปที่ 2.10 จะสังเกตได้ว่าลักษณะโครงสร้างของ 3D-UNet ไม่ได้ต่างจากแบบจำลองเดิมมากนัก เนื่องจากยังคงใช้แนวคิดคล้ายกับลักษณะเดิม โดยที่แบบจำลอง 3D-UNet นั้นได้มีคำอธิบายใหม่ที่ต่างจากเดิมคือการแปลงลักษณะการทำงานเป็นสองส่วนหลัก ๆ ได้แก่ Analysis Path และ Synthesis Path

Analysis Path คือ ส่วนที่รับภาพ (Input) เข้ามา จะมีส่วนประกอบคือ Convolution Layer (3x3x3), Batch Normalization (BN) และนำໄປคำนวนด้วย Activation Function อย่าง ReLU หลังจากนั้นจะถูกดึงข้อมูลแบบ Max Pooling (2x2x2) โดยตั้งค่า Strides = 2 ในแต่ละมิติ

Synthesis Path เป็นขั้นตอนที่แต่ละ Layer จะถูกขยายขนาดด้วยวิธีที่เรียกว่า Up-Convolution (2x2x2) โดยตั้งค่า Strides = 2 ในแต่ละมิติ และนำมาคำนวนด้วยวิธีการ Convolution, BN และ ReLU ตามลำดับ โดยในขั้นสุดท้ายของการวิเคราะห์แบบจำลองจะปรับขนาด Conv ให้เท่ากับ Class Output ที่ต้องการ

2.2.8 ResNet

Residual Network (ResNet) ถูกนำเสนอครั้งแรกโดย He et al. 2015 [16] โดยงานวิจัยนี้นำเสนอวิธีการแก้ไขปัญหา Vanishing Gradient ด้วยการเพิ่ม Residual Block ดังรูปที่ 2.11 (การส่งค่า X ข้ามレイเยอร์เพื่อที่จะนำมาร่วมกับレイเยอร์ต่อไป) ซึ่ง ResNet นั้นมีทั้งหมด 5 รูปแบบ ได้แก่ ResNet18, ResNet34, ResNet50, ResNet101 และ ResNet152 โดยแต่ละแบบจำลองจะมีความแตกต่างที่จำนวนความลึกของจำนวนชั้น Layer ดังรูปที่ 2.12

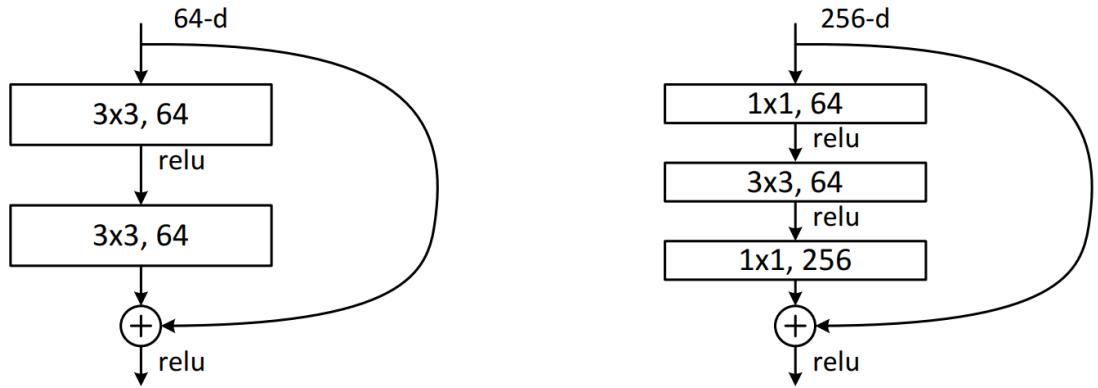


รูปที่ 2.11: แนวคิดพื้นฐานของ ResNet
(ที่มา: He et al. 2015 [16] อ้างอิง ณ วันที่ 10/03/2022)

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112			7×7, 64, stride 2		
				3×3 max pool, stride 2		
conv2_x	56×56	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1			average pool, 1000-d fc, softmax		
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

รูปที่ 2.12: โครงสร้างโดยรวมของ ResNet
(ที่มา: He et al. 2015 [16] อ้างอิง ณ วันที่ 10/03/2022)

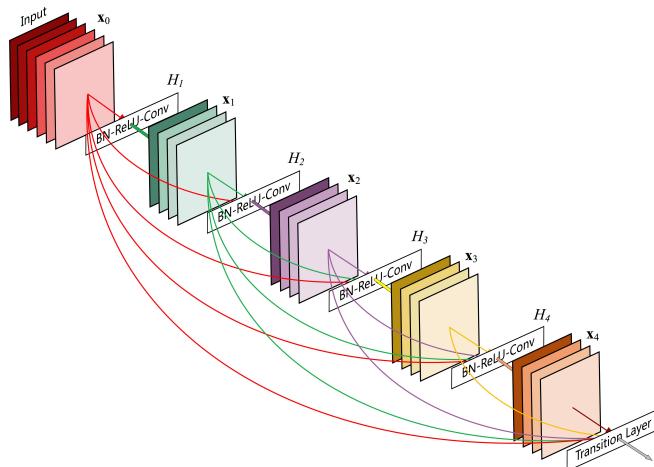
โครงสร้างพื้นฐานของ ResNet สามารถแบ่งได้เป็น 2 ประเภทดังรูปที่ 2.13 โดยสองประเภทดังกล่าวแตกต่างในส่วนของการเพิ่มมาของレイเยอร์ขนาด 1×1 ซึ่งในงานวิจัยได้กล่าวไว้ว่า เลยเยอร์ดังกล่าวทำหน้าที่ในการปรับขนาดของข้อมูลให้อยู่ในขนาดที่เหมาะสม (เรียกวิธีตั้งกล่าวว่า Bottleneck Building Block)



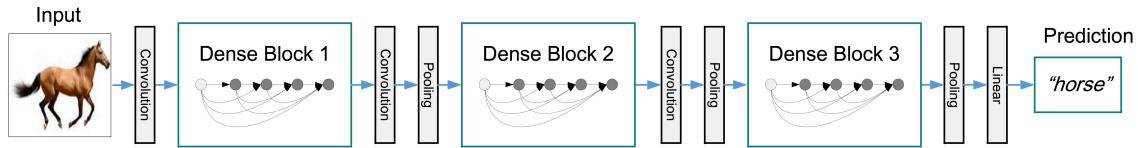
รูปที่ 2.13: โครงสร้างพื้นฐานของ ResNet18, ResNet34 และ
รูปข้ามคือโครงสร้างพื้นฐานของ ResNet50, ResNet101, ResNet152
(ที่มา: He et al. 2015 [16] อ้างอิง ณ วันที่ 10/03/2022)

2.2.9 DenseNet

DenseNet เป็นหนึ่งในชนิดของแบบจำลองโครงข่ายประสาทเทียม CNN ถูกพัฒนาโดย Huang et al. 2017 [17, 18] โครงสร้างของแบบจำลองประกอบด้วย Dense Block ซึ่งแต่ละกล่องจะมี Convolutional Layer ที่เรียกว่ากันตั้งรูปที่ 2.14 และนำแต่ละกล่องมาเรียงต่อ กันตั้งรูปที่ 2.15 ซึ่งแต่ละเลเยอร์จะรับข้อมูลเพิ่มเติมจากเลเยอร์ก่อนหน้าทั้งหมด และส่ง Feature-Maps ไปยังเลเยอร์ถัดไปที่เหลือ ซึ่งโครงสร้างแบบนี้ทำให้แบบจำลองสามารถเรียนรู้ลักษณะของข้อมูลที่หลากหลาย หรือได้รับความรู้ภาพรวม (Collective Knowledge) ทำให้มีแนวโน้มที่ผลลัพธ์ของการทำงานจะมีรูปแบบที่สมบูรณ์มากขึ้น



รูปที่ 2.14: โครงสร้าง Dense Block
(ที่มา: Huang et al. 2017 [17] อ้างอิง ณ วันที่ 10/03/2022)



รูปที่ 2.15: โครงสร้าง DenseNet ที่มี 3 Dense Blocks
(ที่มา: Huang et al. 2017 [17] อ้างอิง ณ วันที่ 10/03/2022)

แบบจำลองที่ผ่านการฝึกฝนกับชุดข้อมูล ImageNet แล้ว (Pretrained DenseNet Models) คือ DenseNet121, DenseNet169 และ DenseNet201 [19] โดยแต่ละแบบจำลองจะมีความแตกต่างที่จำนวนความลึกของจำนวนชั้น Layer ดังรูปที่ 2.16

Layers	Output Size	DenseNet-121($k = 32$)	DenseNet-169($k = 32$)	DenseNet-201($k = 32$)
Convolution	112×112			7×7 conv, stride 2
Pooling	56×56			3×3 max pool, stride 2
Dense Block (1)	56×56	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$
Transition Layer (1)	56×56			1×1 conv
	28×28			2×2 average pool, stride 2
Dense Block (2)	28×28	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$
Transition Layer (2)	28×28			1×1 conv
	14×14			2×2 average pool, stride 2
Dense Block (3)	14×14	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 24$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 48$
Transition Layer (3)	14×14			1×1 conv
	7×7			2×2 average pool, stride 2
Dense Block (4)	7×7	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 16$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$
Classification Layer	1×1			7×7 global average pool
				1000D fully-connected, softmax

รูปที่ 2.16: โครงสร้างแต่ละแบบจำลองของ DenseNet
(ที่มา: Huang et al. 2017 [17] อ้างอิง ณ วันที่ 10/03/2022)

2.2.10 Loss Function

Loss Function คือวิธีการคำนวณค่าระหว่างผลลัพธ์ที่แท้จริงกับผลลัพธ์จากการทำนายของแบบจำลอง โดยวิธีการคำนวณ ดังกล่าวจะส่งผลต่อแบบจำลองในด้านการเรียนรู้ของแบบจำลองโดยการเปลี่ยนแปลงค่าตั้งต้นหนัก ซึ่งในปัจจุบันสามารถเลือกวิธีคำนวณ ได้หลากหลายวิธี เช่น Cross Entropy, Exponential Loss, Mean Squared Error, Dice Loss และ Focal Loss ซึ่งควรเลือกรูปแบบการคำนวณให้เหมาะสมกับแบบรูปแบบของข้อมูลที่ใช้งานเพื่อเพิ่มประสิทธิภาพการทำนายของแบบจำลองให้สามารถทำนายผลลัพธ์ได้ดีที่สุด

2.2.10.1 Dice Loss

Dice Loss ถูกนำมาใช้ในการฝึกฝนแบบจำลองแบบ Semantic Segmentation ซึ่งจากการศึกษาของ Jadon et al. 2020 [20] พบว่าการใช้ Dice Loss มีประสิทธิภาพในการแก้ปัญหา Class Imbalance ซึ่งคือปัญหาความไม่สมดุลของพื้นที่ในภาพแต่ละคลาสยกตัวอย่างเช่น ฉากหน้า (Foreground) มีพื้นที่ร้อยละ 20 ในขณะที่พื้นหลัง (Background) มีพื้นที่ร้อยละ 80 ทำให้แบบจำลองเรียนรู้พื้นหลังได้มากกว่าพื้นที่จากหน้า ซึ่งสามารถแก้ปัญหาโดยการคำนวณแบบ Dice Loss คือคำนวณความผิดพลาดของการหับซ้อนของพื้นที่ผลลัพธ์ที่แบบจำลองทำนายได้ และพื้นที่จริงที่เรียกว่า Ground Truth ซึ่งค่าจะเริ่งที่รับข้อมูลเพื่อใช้ฝึกให้แบบจำลองสามารถเรียนรู้จากค่าจริงที่ถูกต้องได้ สมการการคำนวณ Dice Loss แสดงในสมการต่อไปนี้ โดย p คือ ผลลัพธ์ที่ได้จากแบบจำลอง (Prediction) และ y คือพื้นที่จริงที่ได้จากการระบุนิodicคลาสของข้อมูล (Ground Truth)

$$\text{Dice Loss}(y, p) = 1 - \frac{2yp + 1}{y + p + 1} \quad (2.1)$$

2.2.10.2 Focal Loss

Focal Loss ถูกนำเสนอครั้งแรกโดย Lin et al. [21] เมื่อปี 2017 ซึ่งมีวัตถุประสงค์เพื่อแก้ไขปัญหาความไม่สมดุลของคลาสในชุดข้อมูล (Class Imbalance) ด้วยการนำหลักการ Cross Entropy (CE) มาประยุกต์ใช้ โดยบทความนี้ p และ p_t หมายถึงโอกาสความน่าจะเป็นของคลาสนั้น ๆ (Probability for the Class)

ถ้า $y = 1$

$$CE(p, y) = -\log(p) \quad (2.2)$$

ถ้า $y \neq 1$

$$CE(p, y) = -\log(1 - p) \quad (2.3)$$

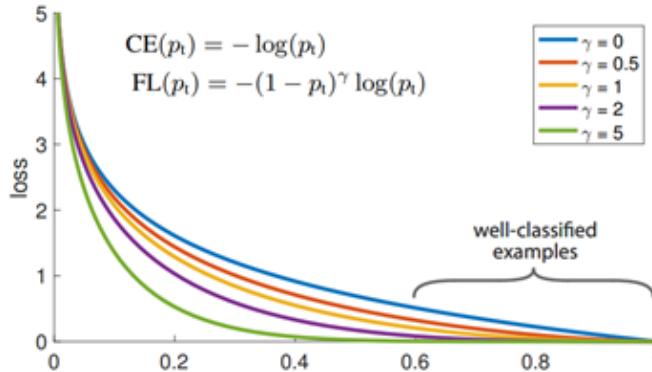
ซึ่งวิธีการที่นำไปของ CE เพื่อแก้ไขปัญหา Class Imbalance คือการเพิ่มสัมประสิทธิ์ (α) เพื่อที่จะให้ค่าความสำเร็จของชุดข้อมูลประเภทหนึ่น ๆ เพิ่มขึ้นหรือลดลงโดยอิงจากสูตร CE ข้างต้น

$$CE(p_t) = -\alpha_t \log(p_t) \quad (2.4)$$

ในส่วนของวิธีการ Focal Loss (FL) นำเสนอรูปแบบการเพิ่มสัมประสิทธิ์สองรูปแบบ รูปแบบที่หนึ่งคือคูณด้วย $(1 - p)^\gamma$ โดยที่ $\gamma \geq 0$ และรูปแบบที่สองคือคูณด้วย $\alpha (1 - p)^\gamma$ โดยที่ $\gamma, \alpha \geq 0$ ด้วย γ, α เป็นตัวแปรเพื่อควบคุมการเปลี่ยนแปลงของความชันของค่า Loss ตั้งแสดงในสมการต่อไปนี้

$$FL(p_t) = -(1 - p_t)^\gamma \log(p_t) \quad (2.5)$$

$$FL(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t) \quad (2.6)$$



รูปที่ 2.17: กราฟเปรียบเทียบความแตกต่างของค่า Loss ต่อตัวแปร γ ที่เปลี่ยนไป
(ที่มา: Lin et al. [21] อ้างอิง ณ วันที่ 11/03/2022)

รูปที่ 2.17 แสดงให้เห็นว่าการคำนวณ Loss ด้วยวิธี FL จะทำให้ค่า Loss มีค่าลดลง (ยกเว้น $\gamma = 0$ เพราะว่าผลจะเท่ากับการคำนวณด้วย CE) ซึ่งการคำนวณในรูปแบบดังกล่าวจะส่งผลให้แบบจำลองมีแนวโน้มในการเรียนรู้คำตอบที่ยังตอบผิดมากขึ้น (p_t ที่มีค่าน้อย) โดยในงานวิจัยที่ศึกษาได้ใช้ข้อมูลปีร์ว่าตัวแปรที่ดีที่สุดคือการใช้ $\gamma = 2$ และ $\alpha = 0.25$

2.2.10.3 Hybrid Loss

จากการวิจัยของ Tang et al. 2019 [22] ได้นำเสนอการฝึกอบรมแบบจำลองโดยการใช้เทคนิคในการคำนวณค่า Loss ประเภทผสม (Hybrid Loss) โดยวิธีดังกล่าวสามารถนำมาประยุกต์ใช้กับโจทย์ของแบบจำลองกลีบปอดและรอยโรคได้ Loss Function ดังกล่าวเป็นการรวมกันของค่า Dice Loss กับ Focal Loss สามารถเขียนเป็นสมการได้ดังต่อไปนี้

$$Loss = Dice Loss + Focal Loss \quad (2.7)$$

2.2.11 Evaluation

การประเมินประสิทธิภาพของแบบจำลองสามารถทำได้โดยพิจารณาค่าต่าง ๆ จาก Confusion Matrix ดังนี้ True Positive (TP) คือผลรวมของจำนวนครั้งที่แบบจำลองทำนายว่าจริงและมีค่าเป็นจริง, True Negative (TN) คือผลรวมของจำนวนครั้งที่แบบจำลองทำนายว่าไม่จริงและมีค่าเป็นจริง, False Positive (FP) คือผลรวมของจำนวนครั้งที่แบบจำลองทำนายว่าจริงแต่มีค่าเป็นไม่จริง และ False Negative (FN) คือผลรวมของจำนวนครั้งที่แบบจำลองทำนายว่าไม่จริงแต่มีค่าเป็นจริง ซึ่งค่าดังกล่าวสามารถคำนวณได้โดยใช้สมการค่าความถูกต้อง (Accuracy), ความเที่ยง (Precision), ความໄວ (Recall or Sensitivity) และความจำเพาะ (Specificity) โดยใช้สมการดังต่อไปนี้

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.8)$$

$$Precision = \frac{TP}{TP + FP} \quad (2.9)$$

$$Recall \text{ or } Sensitivity = \frac{TP}{TP + FN} \quad (2.10)$$

$$Specificity = \frac{TN}{TN + FP} \quad (2.11)$$

นอกจากนี้การประเมินประสิทธิภาพของแบบจำลองในการทำ Semantic Segmentation สามารถประเมินได้จากการคำนวณค่า Intersection over Union (IoU) หรือเรียกว่า Jaccard Index และ Dice Similarity Coefficient (DSC) เพื่อประเมินผลเชิงคุณภาพของการทับซ้อนของพื้นที่ระหว่างบริเวณรอยโรคจริง (Ground Truth) และบริเวณพื้นที่รอยโรคที่แบบจำลองทำนายได้ (Prediction) โดยคำนวณจากค่า True Positive (TP), True Negative (TN), False Positive (FP) และ False Negative (FN) ซึ่งความแตกต่างระหว่าง IoU กับ DSC ที่สำคัญคือ DSC จะพิจารณาหนักสองเท่าสำหรับพื้นที่พิกเซลที่เป็น True Positive [23]

$$IoU = \frac{TP}{TP + FP + FN} \quad (2.12)$$

$$F1 \text{ or } DSC = \frac{2TP}{2TP + FP + FN} \quad (2.13)$$

การประเมินผลการทำนาย Total Severity Score (TSS) จากการทำนายของแบบจำลองเทียบกับการประเมินผลจากรังสีแพทย์โดยใช้การคำนวณค่า Correlation และ R-Square (R^2)

Correlation คือการศึกษาความสัมพันธ์ของข้อมูล ซึ่งสามารถพิจารณาได้จากการคำนวณประสิทธิ์สัมพันธ์ (Correlation of Coefficient) หรือค่า R ซึ่งสามารถใช้บ่งบอกว่าความสัมพันธ์ระหว่างชุดข้อมูลว่ามีความแข็งแรงของความสัมพันธ์อย่างไร โดยจะมีค่าอยู่ระหว่าง -1 ถึง +1 ซึ่งสามารถบอกให้ทางของความสัมพันธ์โดยถ้าค่าติดลบจะหมายถึงความสัมพันธ์เชิงลบ (Negative Correlation) และถ้าค่าเป็นบวกจะหมายถึงความสัมพันธ์เชิงบวก (Positive Correlation) โดยถ้าค่าเข้าใกล้ -1 หรือ 1 แสดงว่าข้อมูลทั้งสองชุดนั้นมีความสัมพันธ์กันมาก (Strong Correlation) ตัวอย่างเช่นค่า 1 หมายถึงความสัมพันธ์เชิงบวกที่สมบูรณ์แบบ และค่าศูนย์หมายความว่าไม่มีความสัมพันธ์เลย [24]

R-Square คือค่าสถิติที่ใช้วัดว่าตัวแบบคณิตศาสตร์ที่ได้มีความสมรู้รักษ์ข้อมูลอย่างไร หรือเรียกว่า Coefficient of Determination ที่ใช้วัดค่าความผันแปรของตัวแปรตอบสนองที่สามารถอธิบายได้มีอยู่ในตัวแบบเชิงเส้น โดยค่า R^2 จะมีค่าอยู่ระหว่าง 0-1 ถ้าค่า R^2 เข้าใกล้ 0 แสดงว่าตัวแบบคณิตศาสตร์ที่ได้มานั้นไม่สามารถอธิบายความผันแปรของค่าตัวแปรตอบสนองที่กระจายรอบค่าเฉลี่ยได้เลย และถ้าค่า R^2 เข้าใกล้ 1 แสดงว่าตัวแบบคณิตศาสตร์ที่ได้มานั้นสามารถอธิบายความผันแปรของค่าตัวแปรตอบสนองต่างที่กระจายรอบค่าเฉลี่ยได้เป็นอย่างดี [25]

2.3 งานวิจัยที่เกี่ยวข้อง

2.3.1 Segmentation of Lung Nodules Using Improved 3D-UNet Neural Network

Xiao et al. 2020 [26] ได้นำเสนองานวิจัยโดยมีวัตถุประสงค์ที่จะพัฒนาแบบจำลองการวิเคราะห์ภาพถ่ายสามมิติให้มีประสิทธิภาพมากขึ้นกว่าเดิม งานวิจัยดังกล่าวใช้ชุดข้อมูลภาพถ่าย Lung CT จาก LUNA16 (Public Dataset) จำนวน 888 CT Scans โดยมีร้อยละ จำนวน 1,186 รอยโรค เพื่อการจำแนกรอยโรคกับเนื้อปอดปกติ

โดยที่นำไปแบบจำลองสองมิติกีสามารถทำนายผลลัพธ์ได้ แต่สำหรับภาพถ่าย CT นั้นสามารถแสดงผลข้อมูลได้ถึงสามมิติ คณะผู้ทำวิจัยในรายงานนี้จึงเลือกแบบจำลองสามมิติอย่าง 3D-UNet แทนการใช้งาน U-Net ที่เป็นสองมิติ อย่างไรก็ตามด้วยลักษณะโครงสร้างแบบจำลองของ 3D-UNet ที่มีลักษณะการทำงานหลัก ๆ คือ Up-Sampling และ Down-Sampling ทำให้ข้อมูลที่ผ่านการวิเคราะห์มีการสูญเสียข้อมูลบางส่วนไป คณะผู้ทำวิจัยในรายงานนี้จึงได้นำเสนอวิธีการแก้ไขข้อบกพร่องดังกล่าวด้วยการบูรณาการแบบจำลอง Res2Net มาปรับแต่งในโครงสร้างของ 3D-UNet โดยถูกนำมาเสนอในชื่อของ “3D-Res2UNet Network” และพัฒนาแบบจำลอง 3D-Res2UNet Network ให้ผลประเมินเชิงคุณภาพของการทับซ้อนของพื้นที่ระหว่างบริเวณรอยโรคจริง (Ground-Truth Mask) และบริเวณพื้นที่รอยโรคที่แบบจำลองทำนายได้ (Predicted Segmentation Mask) กล่าวคือ Dice Similarity Coefficient (DSC) ร้อยละ 95.30 ซึ่งมากกว่าแบบจำลองอื่น ๆ ดังแสดงในตารางที่ 2.3 นอกจากนี้ค่า DSC ที่ได้อ้างอิงถึงการศึกษาของ Mansoor et al. [27] ที่แนะนำว่าการแยกพื้นที่ปอดก่อนการแยกรอยโรคในเนื้อปอดจะทำให้ค่าความแม่นยำในการแบ่งส่วนภาพเพิ่มขึ้น

แบบจำลอง 3D-Res2UNet Network ที่งานวิจัยดังกล่าวได้นำมาใช้ให้ผลลัพธ์ที่ดี สามารถใช้เพื่อแก้ไขโจทย์การแยกรอยโรคด้วยภาพถ่ายสามมิติได้ แต่คณะผู้ทำวิจัยในรายงานนี้ได้ให้ ข้อจำกัดว่าอาจมีการทํานายที่ผิดพลาดในรอยโรคที่แยกต่างหากกับรอยโรคที่ถูกฝึกฝนมาจากแบบจำลอง อย่างไรก็ตามความผิดพลาดนั้นเกิดขึ้นในระดับไม่กี่พิกเซลเท่านั้น

ตารางที่ 2.3 ค่า Dice Similarity Coefficient (DSC) ของแบบจำลองแบบต่าง ๆ ในการศึกษาของ Xiao et al.

แบบจำลอง	DSC (%)
U-Net	81.32
3D-UNet	89.12
3D-UNet+fully CRF	93.25
3D-Res2UNet	95.30

2.3.2 COVID-19 Patients’ Severity Grading by Lung and Lesion Segmentation

Qiblawey et al. 2021 [28] ได้นำเสนอระบบที่ใช้จำแนกระดับความรุนแรงของ Lung CT ในผู้ป่วยโรคโควิด-19 โดยใช้การเรียนรู้เชิงลึกในการวิเคราะห์พื้นที่รอยโรคบริเวณที่ติดเชื้อเทียบกับพื้นที่ปอดในภาพ Lung CT เพื่อคำนวณร้อยละของการติดเชื้อของเนื้อปอด (Percentage of Infection: PI) Adolfsson [29] ได้ทำการฝึกสอนแบบแบ่งออกเป็น 3 กลุ่ม คือ ผู้ป่วยโรคโควิด-19 20 ราย (3,520 Slices) ผู้ป่วยโรคโควิด-19 9 ราย (829 Slices) และคนปกติ 267 Slices

สำหรับชุดข้อมูลที่ใช้ทดสอบประสิทธิภาพของแบบจำลองในการแยกระดับความรุนแรงของรอยโรคบนประกอบด้วยภาพ Lung CT จากคนปกติ 254 ราย และผู้ป่วยโรคโควิด-19 856 ราย โดยชุดข้อมูลของผู้ป่วยโรคโควิด-19 มีการประเมินระดับความรุนแรงของรอยโรคโดยรั้งสีแพทเทอร์มตามเกณฑ์ของ MosMedData (CT1-CT4) ซึ่งการเตรียมข้อมูลเริ่มจากการแปลงไฟล์ประเภท National Issues Forums Institute (NIFTI) ให้เป็นไฟล์ Portable Network Graphics (PNG) ขนาด 256x256 พิกเซล จากนั้นทำการปรับสีภาพในแต่ละพิกเซลให้อยู่ในช่วง 0-255 และเพิ่มความหลากหลายของภาพ (Augmentation) สำหรับการนำไปใช้ในการเรียนรู้ของแบบจำลอง

งานวิจัยนี้ใช้โครงสร้างแบบจำลอง U-Net และ Feature Pyramid Networks (FPN) ร่วมกับ Backbone (Encoder) ชนิดต่าง ๆ คือ DenseNet และ ResNet โดยผลการศึกษารายงานว่าแบบจำลองที่มีประสิทธิภาพในการแบ่งส่วนภาพของพื้นที่ปอด (Lung Segmentation) คือ DenseNet161 U-Net โดยมีค่า DSC เท่ากับร้อยละ 97.19 และ Accuracy เท่ากับร้อยละ 99.69 แบบจำลองที่มีประสิทธิภาพในการแบ่งส่วนภาพของพื้นที่รอยโรค (Lesion Segmentation) คือ DenseNet201 FPN โดยมีค่า DSC เท่ากับร้อยละ 94.13 และ Accuracy เท่ากับร้อยละ 99.81

ภาพที่ได้จากการแบ่งส่วนโดยแบบจำลอง DenseNet161 U-Net และ DenseNet201 FPN จะถูกนำมาใช้ในการคำนวณค่า PI ซึ่งเป็นร้อยละของการติดเชื้อของเนื้อปอดของแต่ละ Slice โดยการเทียบจำนวนพิกเซลของรอยโรคกับจำนวนพิกเซลของเนื้อปอด จากนั้นจึงนำค่า PI ของทุก Slice มาหาค่าเฉลี่ยเพื่อหาค่า PI ของผู้ป่วยแต่ละราย งานวิจัยนี้จำแนกระดับความรุนแรงของปอดอักเสบ (Severity Classification) ออกเป็น 5 ระดับตามเกณฑ์ของ MosMedData ดังแสดงในตารางที่ 2.4

ตารางที่ 2.4 เกณฑ์การประเมินความผิดปกติจากภาพ CT lung ในการศึกษาของ Qiblawey et al.

ร้อยละของพื้นที่ติดเชื้อ (PI)	ระดับคะแนน	ระดับความรุนแรง
ไม่พบ	CT0	Healthy
ร้อยละ 1-25	CT1	Mild
ร้อยละ 26-49	CT2	Moderate
ร้อยละ 50-75	CT3	Severe
มากกว่าร้อยละ 75	CT4	Critical

ผลการทดสอบพบว่าแบบจำลองมีค่าความแม่นยำ ความไว และความจำเพาะในการจำแนกระดับความรุนแรงของรอยโรคในปอด เท่ากับร้อยละ 97.05, ร้อยละ 94.05 และร้อยละ 95.53 ตามลำดับ นอกจากนี้ในงานวิจัยนี้ยังมีการสร้างภาพสามมิติของปอดกับบริเวณที่ติดเชื้อโดยใช้ภาพที่ผ่านการแบ่งส่วนโดยแบบจำลองที่กล่าวไปข้างต้นเพื่อช่วยอำนวยความสะดวกในการวินิจฉัยระดับความรุนแรงของรอยโรคแก้รังสีแพทย์

2.3.3 LOBENET: A Global Position Reservation and Fissure-Aware Convolutional Neural Network for Pulmonary Lobe Segmentation

Chen et al. 2020 [29] นำเสนอแบบจำลองที่มีชื่อว่า LobeNet ซึ่งใช้สำหรับการแบ่งส่วนภาพลีบปอดจากภาพ Lung CT โดยใช้ชุดข้อมูล LUNA16 ซึ่งประกอบด้วยชุดข้อมูลสำหรับใช้ในการฝึกฝนแบบจำลอง 40 ชุด และชุดข้อมูลสำหรับการทดสอบ 10 ชุด โดยจำนวนภาพในแต่ละชุด (1 คน) มีจำนวนภาพอยู่ระหว่าง 113 ถึง 516 ภาพ แต่ละภาพมีความละเอียด 512×512 พิกเซล การเตรียมข้อมูลเริ่มด้วยการปรับสีภาพ CT Scan ให้มีค่า Hounsfield Unit อยู่ในช่วง -1000 ถึง 600 จากนั้นทำการ Normalize ให้อยู่ในช่วง [0,1] และตัดแบ่งภาพด้วยวิธี Sliding Window โดยใช้ Window ขนาด $32 \times 224 \times 224$ และ Sliding Stride ขนาด [8,56,56] ซึ่งสามารถช่วยลดการใช้หน่วยความจำของหน่วยประมวลผลกราฟิกส์ (Graphics Processing Unit: GPU) ได้อย่างมาก

แบบจำลอง LobeNet ใน การศึกษาของ Chen et al. คือแบบจำลองที่ถูกปรับแต่งมาจากแบบจำลอง 3D-UNet โดยเพิ่มวิธีการทำ Global Position Reservation (GP) และ Fissure-Aware Strategy (FA) เนื่องจากจากการตัดแบ่งภาพ CT Scan ทำให้แบบจำลองมองเห็นภาพ Lung CT บางส่วนเจ็บทำให้จำแนกพื้นที่กลีบปอดได้ยาก การศึกษานี้จึงได้ทำการ Concatenation ระหว่างตำแหน่งคู่พิกเซลของแต่ละพิกเซล (Global Position) เข้ากับชั้นสุดท้ายในส่วน Expansive Path ของแบบจำลอง รวมทั้งเพิ่มโครงสร้างของ Fissure-Aware Path เพื่อฝึกฝนให้แบบจำลองสามารถทำงานอย่างแยกของกลีบปอด (Fissure) ซึ่งช่วยให้แบบจำลองแยกพื้นที่กลีบปอดได้ดีขึ้น โดยผลการทดสอบแบบจำลองกับชุดข้อมูลทดสอบ LUNA16 แบบจำลอง LobeNet มีค่า Dice Similarity Coefficient (DSC) ที่ร้อยละ 93.35 สำหรับการทำนายพื้นที่กลีบปอดดังแสดงในตารางที่ 2.5

ตารางที่ 2.5 ค่า Dice Similarity Coefficient (DSC) ของแบบจำลองในการศึกษาของ Chen et al.

วิธีการ	DSC (%)
LobeNet without GP&FA	87.67
LobeNet without FA	92.44
LobeNet	93.35

2.3.4 Automatic Pulmonary Lobe Segmentation using Deep Learning

Tang et al. 2019 [22] ได้ทำการศึกษาวิธีการแบ่งส่วนภาพของกลีบปอดแต่ละกลีบจากภาพ Lung CT โดยใช้ชุดข้อมูล LUNA16 ซึ่งแบ่งเป็นชุดข้อมูลสำหรับฝึกฝนแบบจำลอง 40 ชุด ข้อมูลทดสอบ 10 ชุด และใช้ชุดข้อมูล Tianchi สำหรับเป็นชุดทดสอบที่สองจำนวน 10 ชุด ผู้วิจัยได้เตรียมข้อมูลโดยการปรับภาพ CT Scan ให้มีช่วงสี Hounsfield Unit (HU) อยู่ในช่วง -1000 ถึง 600 เพื่อให้สีภาพอยู่ในช่วงมาตรฐานเดียวกันทั้งชุดข้อมูล จากนั้นทำการปรับภาพเป็นสีขาว-ดำโดยวิธี Otsu's Method ซึ่งเป็นวิธีการคำนวณค่า Threshold ของความเข้มสีที่เหมาะสมในการปรับสีภาพ และทำการครอบอาณาเขตพื้นที่ปอดโดยใช้อัลกอริทึม Convex Hull ซึ่งเป็นวิธีการหาเส้นขอบในภาพ โดยใช้ขนาดของ Kernel เท่ากับ 5×5 ในการศึกษาของ Tang et al. นี้ใช้แบบจำลองโครงสร้างแบบ V-Net ที่มีการทำ Down-Sampling 4 ครั้ง แต่นำมาปรับให้เหลือการทำ Down-Sampling เพียง 1 ครั้ง นอกจากนี้ยังใช้วิธีการฝึกฝนแบบ Hybrid Loss โดยการรวมระหว่างวิธีคำนวณค่า Loss แบบ Dice Loss และ Focal Loss เข้าด้วยกัน

งานวิจัยนี้ได้ทำการฝึกฝนแบบจำลองจำนวน 300 รอบ (Epochs) และทำการทดสอบแบบจำลองกับชุดข้อมูล LUNA16 และ Tianchi พบร่วมแบบจำลองมีประสิทธิภาพในการแบ่งส่วนของกลีบปอดทั้ง 5 กลีบ ดังแสดงในตารางที่ 2.6 กล่าวคือเมื่อฝึกฝนแบบใช้ Dice Loss เพียงอย่างเดียวแบบจำลองมีค่า DSC อยู่ที่ร้อยละ 87.07 (LUNA16) และร้อยละ 88.30 (Tianchi) ซึ่งเมื่อฝึกฝนแบบ Hybrid Loss ระหว่าง Dice Loss ร่วมกับ Focal Loss มีค่า DSC อยู่ที่ร้อยละ 90.94 (LUNA16) และร้อยละ 92.25 (Tianchi) และแบบจำลองที่ฝึกฝนกับชุดข้อมูลที่ผ่านการครอบพื้นที่ปอดโดยอัลกอริทึม Convex Hull มีค่า DSC อยู่ที่ร้อยละ 91.48 (LUNA16) และร้อยละ 94.17 (Tianchi)

ตารางที่ 2.6 ค่า Dice Similarity Coefficient (DSC) ในการศึกษาของ Tang et al.

ชุดข้อมูลทดสอบ	Dice Loss (%)	+ Focal Loss (%)	+ Convex Hull (%)
LUNA16	87.07	90.94	91.48
Tianchi	88.30	92.25	94.17

2.3.5 Assessing Lobe-wise Burden of COVID-19 Infection in Computed Tomography of Lungs using Knowledge Fusion from Multiple Datasets

Visvanathan et al. 2021 [30] นำเสนอแบบจำลองสำหรับการทำนายพื้นที่กลีบปอด และรอยโรคแต่ละชนิด (GGO, Consolidation) ในกลุ่มผู้ป่วยโควิด-19 โดยใช้โครงสร้างแบบจำลองแบบ 2D CNN สำหรับการแบ่งส่วนภาพ (Segmentation Network) และแบบจำลองสำหรับการช่วยจำแนก (Auxiliary Classification Network) ซึ่งใช้สำหรับการจำแนกชนิดของภาพ Lung CT

ชุดข้อมูลที่ใช้ในการศึกษาของ Visvanathan et al. ได้นำข้อมูลภาพ Lung CT มาจากหลายแหล่งข้อมูล (Multiple Datasets) โดยมีทั้งหมด 5 ชุดดังต่อไปนี้

1. ชุดข้อมูลที่ 1 คือชุดข้อมูลภาพ Lung CT ที่มีการระบุกลีบปอด 5 กลีบ จำนวน 50 ชุด
2. ชุดข้อมูลที่ 2 (CNCB Dataset) มีจำนวนคนใช้ 150 ราย (750 ภาพ)
3. ชุดข้อมูลที่ 3 (MedSeg Dataset) มีจำนวนคนใช้ 9 ราย (829 ภาพ)
4. ชุดข้อมูลที่ 4 (Mosmed.ai Dataset) มีจำนวนคนใช้ 50 ราย (200 ภาพ) โดยแต่ละรายมีจำนวนภาพ Lung CT จำนวน 40 ภาพ
5. ชุดข้อมูลที่ 5 (COVID-19-CT-Seg Dataset) มีจำนวนภาพ Lung CT จำนวน 8 ชุด

การเตรียมข้อมูลนำภาพถ่ายรังสีคอมพิวเตอร์ปอดชนิดตัดขวาง (2D Axial) มาปรับให้มีช่วงสี Hounsfield Unit (HU) อยู่ในช่วง -1000 ถึง 1000 และทำการ Normalize ให้อยู่ในช่วง [0,1] จากนั้นปรับความละเอียดของภาพให้มีขนาดเท่ากับ 512×512 พิกเซล จากนั้นฝึกฝนแบบจำลองจำนวน 30 รอบ โดยใช้ Adam Optimizer และ Learning Rate เท่ากับ 0.00001 ผลการทดสอบการทำนายพื้นที่กลีบปอดมีค่า DSC อยู่ที่ร้อยละ 85.68 และผลการทดสอบการทำนายพื้นที่รอยโรคพบว่ามีค่า DSC อยู่ที่ร้อยละ 61.09

ตารางที่ 2.7: ตารางเปรียบเทียบประสิทธิภาพผลการศึกษาของงานวิจัยที่เกี่ยวข้อง

งานวิจัย	Data Volume	Objective	Preprocessing	Segmentation	Model	IoU	DSC
Xiao et al. 2020 [26]	888 ชุด โดยมีอยู่ในครั้ง 1,186 รอบครั้ง (Training: 70%, Testing: 20%, Verification: 10%)	จำแนกรายโรคตามเกณฑ์ปอดปกติ	แปลงภาพเป็นข้อมูลค่าแทนของภาพโดยใช้อูปแบบของ Voxeldiam (Voxelcoord, Voxeldiam) จากนั้นใช้ AugGAN Network เพื่อแก้ไขปัญหา Class Imbalance และทำการ Normalization	Lung, Lung Nodules	3D-Res2UNet (3D-ResNet, 3D-UNet)	-	95.30%
Qiblawey et al. 2021 [28]	Training 3 ชุด ชุด 1: ผู้ป่วย 20 ราย (3,520 ภาพ) ชุด 2: ผู้ป่วย 9 ราย (829 ภาพ) ชุด 3: คนปกติ 267 ภาพ Testing 46,411 ภาพ ผู้ป่วย 856 ราย คนปกติ 254 ราย	วิเคราะห์ระดับความรุนแรงของรอยโรคในnodulesหัวใจ	ไม่ได้มีการปรับค่า Hounsfield Unit เมื่อจัดเรียงข้อมูลเป็นไฟล์ NIFTI Format รวมถึงนี้จะแปลงเป็นไฟล์ PNG ขนาด 256 x 256 พิกเซล จากนั้นปรับสีภาพให้อยู่ในช่วง 0-255 และทำการเพิ่มความหลากหลายของภาพ (Augmentation)	Lung	DenseNet 161 + U-Net	95.10%	97.19%
Chen et al. 2020 [29]	Training LUNA16 Set: 40 ชุด Testing LUNA16 Set: 10 ชุด	เพื่อนำเสนอแบบจำลองสำหรับการแบ่งส่วนภาพเล็บปอด	ปรับสีภาพ CT Scan ให้มีช่วงค่า Hounsfield Unit อยู่ในช่วง [-1000,600] จากนั้นทำการ Normalize ให้ถูกอยู่ในช่วง [0,1] และใช้ธีม Global Position Reservation, Fissure-Aware Strategy	Lung Lobe	LobeNet (3D-UNet)	-	93.35%
Tang et al. 2019 [22]	Training LUNA16 Set: 40 ชุด Testing LUNA16 Set: 10 ชุด Tianchi Set: 10 ชุด	เพื่อแบ่งส่วนภาพกึ่งบล็อกจากภาพ CT Scan	ปรับสีภาพ CT Scan ให้มีช่วงค่า Hounsfield Unit อยู่ในช่วง [-1000,600] จากนั้นทำการ CT Image Binarize โดยใช้ OTSU Method, และครอบพื้นที่ปอดโดยใช้อัลกอริทึม Convex Hull (Kernel Size: 5x5)	Lung Lobe	V-Net (One Down-Sampling)	-	LUNA16 Set 91.48%
Visvanathan et al. 2021 [30]	ชุด 1: ภาพ Lung CT จำนวน 50 ชุด ชุด 2: ผู้ป่วย 150 ราย (750 ภาพ) ชุด 3: ผู้ป่วย 9 ราย (829 ภาพ) ชุด 4: ผู้ป่วย 50 ราย (200 ภาพ) ชุด 5: ภาพ Lung CT จำนวน 8 ชุด	เพื่อแบ่งส่วนภาพกึ่งบล็อกและรองรับการจัดเรียงในผู้ป่วยโดยใช้โอล์กอริทึม 9	นำภาพเดียวกันมาตัดเฉพาะช่วง (2D Axial) มาบันทึกเมื่อเป็นค่า Hounsfield Unit (HU) อยู่ในช่วง [-1000,1000] และทำการ Normalize ให้ถูกอยู่ในช่วง [0,1] จากนั้นแบ่งความละเอียดของภาพให้มีขนาดเท่ากับ 512 x 512 พิกเซล	Lung Lobe	2D CNN	-	85.68%
				Lung Lesion (GGO, Consolidation)	2D CNN	-	61.09%

รูปที่ 2.18: ตารางเปรียบเทียบประสิทธิภาพผลการศึกษาของงานวิจัยที่เกี่ยวข้อง

2.4 ภาษาคอมพิวเตอร์และเทคโนโลยี

2.4.1 ภาษาไพธอน (Python Programming Language: Python)

Python เป็นภาษาโปรแกรมคอมพิวเตอร์ระดับสูง (High-Level Programming Language) โดยเป็นภาษาที่ถูกออกแบบมาสำหรับมนุษย์ในการแปลงความคิดของการแก้ปัญหาอุปกรณ์มาเป็นลำดับขั้นตอนต่าง ๆ ที่ชัดเจนให้อยู่ในรูปแบบของชุดคำสั่ง (Source Code) และเป็นภาษาที่อ่านง่าย โดยตัดความซับซ้อนของโครงสร้างและไวยกรณ์ของภาษาออกไป Python มีการทำงานเป็นแบบการแปลงดูคำสั่งที่ลับบรรทัด (Python Interpreter) เพื่อป้อนเข้าสู่หน่วยประมวลผลให้คอมพิวเตอร์ทำงานตามที่ต้องการ [31]

2.4.2 LabelME

LabelME เป็นเครื่องมือสร้างคำอธิบายประกอบภาพกราฟิก (Image Annotation Tools) แบบ Open Source ซึ่งสามารถใส่คำอธิบายประกอบรูปภาพสำหรับการตรวจสอบจับวัตถุ (Detection) การแบ่งส่วน (Segmentation) และการจัดประเภท (Classification) นอกจากนี้ยังรองรับการใส่คำอธิบายประกอบวิดีโอ [32]

2.4.3 Google Colaboratory

Google Colaboratory คือ Jupyter Notebook ที่ทำงานอยู่บน Cloud โดยที่ไม่จำเป็นจะต้องติดตั้งโปรแกรมใด ๆ สามารถใช้งานได้ง่าย ๆ เพียงมีบัญชีไดร์ฟ (Google Drive) ก็ใช้งานได้ เพื่อทำให้สามารถจัดเก็บ Source Code ไว้บน Google Drive และจัดการไฟล์เดอร์ และไฟล์ต่าง ๆ ได้เหมือนกับเขียนโปรแกรมเครื่อง ซึ่งสามารถเรียกใช้กับเพื่อน ๆ ได้อีก ส่วนภาษาหลักที่ใช้เขียนจะเป็น Python สามารถเลือกรันได้ Python Version 2 หรือ Python Version 3 ขึ้นไป และมีหน่วยประมวลผลกราฟิกส์ (Graphics Processing Unit: GPU), หน่วยประมวลผลเครือข่ายประสิทธิภาพเทียม (Tensor Processing Unit: TPU) [33]

2.4.4 Sever(TensorFlow-Docker)

ในการฝึกฝนแบบจำลองกลีบปอดและรอยโรค แบบจำลองทั้งหมดถูกฝึกฝนผ่านเครื่องเซิร์ฟเวอร์ของทางมหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี (Intel (R) Xeon (R) Gold 6126 CPU @ 2.60GHz, 40 GB RAM, NVIDIA Tesla V100 SXM2 GPU)

2.4.5 Streamlit

Streamlit เป็น Open Source Library ของ Python ที่สามารถสร้างหน้าต่างโปรแกรมได้อย่างง่ายและยังสามารถประยุกต์สำหรับการเรียนรู้ของเครื่อง (Machine Learning) และวิทยาศาสตร์ข้อมูล (Data Science) [34]

2.4.6 Github

GitHub คือเว็บไซต์ที่มีลักษณะให้บริการบนคลาวด์ (Cloud-Based Service) ที่พัฒนาต่อมาจาก Git ซึ่งเป็นซอฟต์แวร์ควบคุม (Version Control) โดย Git เป็นซอฟต์แวร์ Open-Source พัฒนาโดย Linus Torvalds ในปี 2005 [35] ซึ่งซอฟต์แวร์นี้ช่วยให้นักพัฒนาจัดเก็บ Code และติดตามการเปลี่ยนแปลงเด็ดที่ถูกแก้ไขหรือเปลี่ยนแปลงจากนักพัฒนาคนอื่น ๆ ซึ่งซอฟต์แวร์ Version Control มีส่วนสำคัญมากที่จะช่วยลดความเสี่ยงในการสูญเสีย Code อีกทั้งช่วยให้นักพัฒนาจัดการ Code หรือไฟล์ได้สะดวกมากยิ่งขึ้น [36]

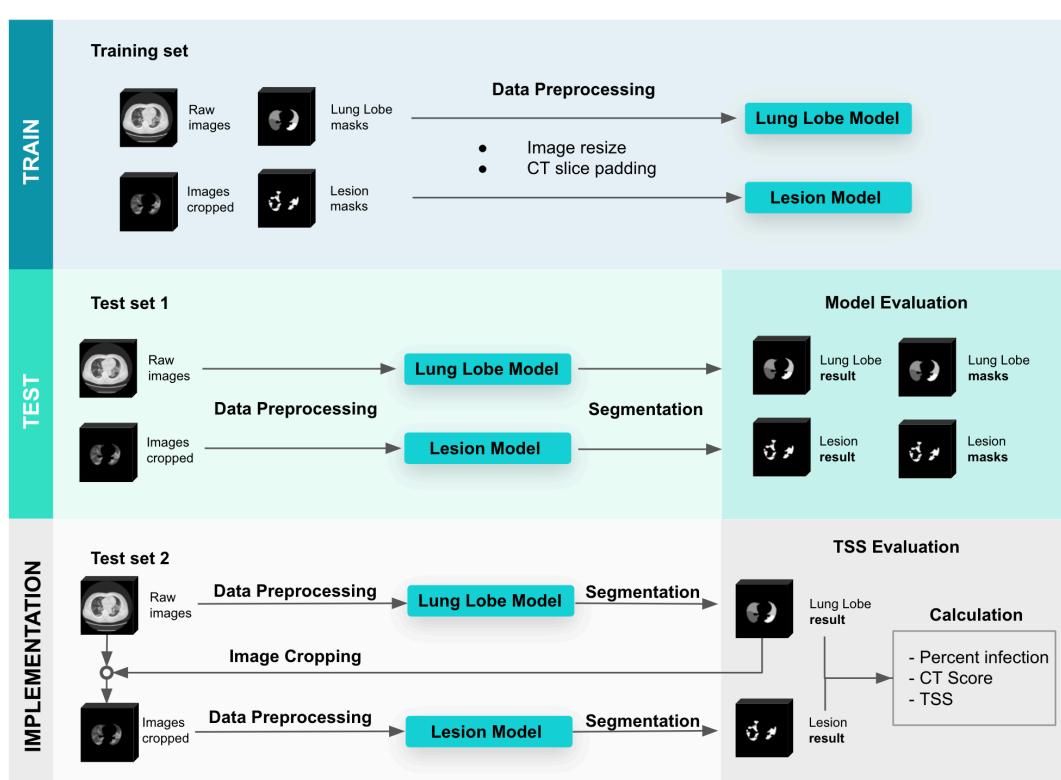
2.4.7 Git Large File Storage (LFS)

Git Large File Storage (LFS) คือการเก็บข้อมูลไฟล์ที่มีขนาดใหญ่ไว้ในอีเชิร์ฟเวอร์ และเก็บข้อมูลตำแหน่ง (Pointers) ของไฟล์ ดังกล่าวไว้บน Git ช่วยให้นักพัฒนาสามารถเก็บไฟล์ที่มีขนาดใหญ่อย่างเช่นภาพหรือวีดีโอไว้ใน Git Repository [37]

บทที่ 3 การออกแบบ และระบบวิจัย

3.1 ภาพรวมของโครงการ

โครงการนี้เป็นการศึกษาโดยใช้ภาพถ่ายรังสีคอมพิวเตอร์ปอดที่เป็นข้อมูลที่มีคุณภาพและได้ผ่านการทำเนินการเพื่อขออนุมัติจุลทรรษ การวิจัยในคนจากคณะกรรมการจุลทรรษการวิจัยในคนสถาบันวิจัยจุฬาภรณ์ ภาพรวมของโครงการประกอบด้วยขั้นตอนการทำเนินงาน ดังนี้ การเตรียมข้อมูล (Data Preparation) การพัฒนาแบบจำลอง (Model Development) การคำนวณเปอร์เซ็นต์การติดเชื้อ (Percentage of Infection) การคำนวณค่าระดับความรุนแรง Total Severity Score (TSS) การทำหน้าต่างผู้ใช้งาน (User Interface Development) โดยใช้ Open Source Python Library ที่ชื่อว่า Streamlit และการประเมินผล (Evaluation) ซึ่งประกอบไปด้วยการประเมินประสิทธิภาพแบบจำลอง และการประเมินผลการทำนายค่า TSS โดยค่าคณิตศาสตร์ทางสถิติ Correlation of Coefficient, R-Square (R^2)



รูปที่ 3.1: ภาพรวมของการดำเนินงาน

3.2 ชุดข้อมูล

โครงการนี้ใช้ชุดข้อมูลที่เป็นภาพถ่ายรังสีคอมพิวเตอร์ปอดชนิดภาพตัดขวาง (Axial Lung CT) โดยช่วงสีของภาพถ่ายรังสีคอมพิวเตอร์ จะมีค่า Hounsfield Unit (HU) อยู่ในช่วง -1500 ถึง -500 ซึ่งเป็นช่วงสีที่เหมาะสมแก่การดูรอยโรคในพื้นที่ปอด โดยชุดข้อมูลจะมาจากการติดเชื้อโคโรนาไวรัส COVID-19 ในโรงพยาบาลจุฬาภรณ์จำนวน 100 ราย โดยแบ่งเป็นผู้ป่วยโรคโควิด-19 ที่พบรอยโรคในปอดจำนวน 75 ราย และคนที่ไม่มีพบรอยโรคในปอดจำนวน 25 ราย โดยจำนวนภาพในแต่ละชุด (1 ราย) มีจำนวนภาพอยู่ระหว่าง 92 - 208 ภาพ ชุดข้อมูลดังกล่าวจะถูกแบ่งออกเป็น 3 ส่วนคือ

- “Training Set” ใช้สำหรับพัฒนาแบบจำลอง ประกอบด้วยจำนวน

ผู้ป่วยโรคโควิด-19 ที่ไม่มีพบรอยโรคในปอดจำนวน 8 ราย และคนที่พบรอยโรคในปอดจำนวน 24 ราย ชุดข้อมูลจะถูกใช้สำหรับ

Training 2,853 ภาพ (75%) และ Validation 899 ภาพ (25%)

2. “Test Set 1” ใช้สำหรับประเมินผลค่า DSC, IOU ดังนั้นชุดข้อมูลดังกล่าวจะต้องถูกระบุพื้นที่ร้อยโรคด้วย ประกอบด้วยจำนวนผู้ป่วยโรคโควิด-19 ที่ไม่พบรอยโรคในปอดจำนวน 2 ราย และคนที่พบรอยโรคในปอดจำนวน 6 ราย

3. “Test Set 2” ใช้สำหรับประเมินผลการทํานายค่า Total Severity Score (TSS) ของโปรแกรม ประกอบด้วยจำนวนผู้ป่วยโรคโควิด-19 ที่ไม่พบรอยโรคในปอดจำนวน 15 ราย และคนที่พบรอยโรคในปอดจำนวน 47 ราย

โครงการนี้ได้รับการอนุมัติจากคณะกรรมการจัดการวิจัยในคน สถาบันวิจัยพัฒน์ รหัสโครงการนวัตกรรม 167/2564

ตารางที่ 3.1 ตารางแสดงจำนวนข้อมูลในแต่ละประเภท

Dataset	ผู้ป่วยโรคโควิด-19	
	ไม่พบรอยโรค	พบรอยโรค
Train/Validation Set	8	24
Test Set 1	2	6
Test Set 2	15	47

ชุดข้อมูล Training Set ประกอบไปด้วยภาพถ่ายรังสีคอมพิวเตอร์ปอดของผู้ป่วยโรคโควิด-19 ที่ไม่พบรอยโรค และภาพถ่ายรังสีคอมพิวเตอร์ปอดที่พบรอยโรคแบ่งตามระดับความรุนแรงออกเป็น Mild, Moderate และ Severe อย่างละ 8 ราย ดังแสดงในตารางที่ 3.2

ตารางที่ 3.2 ตารางแสดงข้อมูลของชุดข้อมูล Training Set

Case Type	Number of Case	Total of Slice	Average Slice
No Lesion	8	985	123
Mild	8	907	113
Moderate	8	941	118
Severe	8	919	115

ชุดข้อมูล Test Set 1 ประกอบไปด้วยภาพถ่ายรังสีคอมพิวเตอร์ปอดของผู้ป่วยยืนยันโรคโควิด-19 ที่ไม่พบรอยโรค และภาพถ่ายรังสีคอมพิวเตอร์ปอดที่พบรอยโรคแบ่งตามระดับความรุนแรงออกเป็น Mild, Moderate และ Severe อย่างละ 2 ราย ดังแสดงในตารางที่ 3.3

ตารางที่ 3.3 ตารางแสดงข้อมูลของชุดข้อมูล Test Set 1

Case Type	Number of Case	Total of Slices	Average Slices
No Lesion	2	365	183
Mild	2	388	194
Moderate	2	260	130
Severe	2	301	151

ชุดข้อมูล Test Set 2 ประกอบไปด้วยภาพถ่ายรังสีคอมพิวเตอร์ปอดของผู้ป่วยยืนยันโรค โควิด-19 ที่ไม่พบรอยโรคจำนวน 15 ราย และภาพถ่ายรังสีคอมพิวเตอร์ปอดที่พบรอยโรคและแบ่งตามระดับความรุนแรงออกเป็น Mild จำนวน 15 ราย, Moderate จำนวน 26 ราย และ Severe จำนวน 6 ราย ดังแสดงในตารางที่ 3.4 และเนื่องจากสถานการณ์ในปัจจุบันประเทศไทยของประเทศไทยได้รับวัคซีนเป็นจำนวนมากแล้ว ทำให้ผู้ป่วยโรคโควิด-19 ในระดับความรุนแรง Severe มีจำนวนน้อย คงจะผู้ติดทำเงินได้นำภาพถ่ายรังสีคอมพิวเตอร์ปอดของผู้ป่วยโรคโควิดระดับ Severe จากชุดข้อมูล Test Set 1 จำนวน 2 ราย มาใช้ในการทดสอบค่า TSS จึงทำให้ชุดข้อมูล Test Set 1 และ Test Set 2 ใช้ชุดข้อมูลผู้ป่วยที่ซ้ำกันจำนวน 2 ราย

ตารางที่ 3.4 ตารางแสดงข้อมูลของชุดข้อมูล Test Set 2

Case Type	Number of Case	Total of Slices	Average Slices
No Lesion	15	1,953	131
Mild	15	2,008	134
Moderate	26	2,995	115
Severe	6	730	122

3.3 การเตรียมข้อมูล

ข้อมูลที่ได้จากการถ่ายภาพรังสีคอมพิวเตอร์ปอดนั้นจะอยู่ในสกุล Joint Photographic Experts Group (JPG) ความละเอียด 512 x 512 พิกเซล ซึ่งข้อมูลดังกล่าวจะถูกนำมาประมวลอย่างรวดเร็วโดยโปรแกรม LabelME โดยผลลัพธ์ที่ได้จะเป็นไฟล์ JavaScript Object Notation (JSON) ซึ่งการระบุรอยโรคจะถูกตรวจสอบโดยรังสีแพทย์ที่มีความเชี่ยวชาญในการแปลผลภาพ Lung CT จากนั้นนำไฟล์ JSON มาแปลงเป็นไฟล์ที่เหมาะสมต่อการฝึกฝนแบบจำลอง

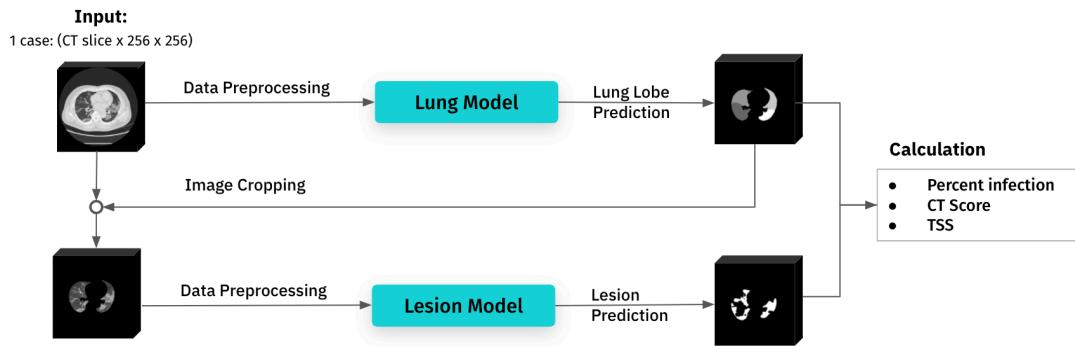


รูปที่ 3.2: การระบบดำเนินการอย่างรวดเร็วโดยใช้โปรแกรม LabelME

3.4 การพัฒนาแบบจำลอง

แบบจำลองที่ใช้ในโครงการนี้ ประกอบด้วย 2 แบบจำลองตามเป้าหมายหลักของการทำงาน ได้แก่ (1) การแบ่งส่วนกลีบปอด และ (2) การแบ่งส่วนรอยโรค ซึ่งทางคณะผู้จัดทำเลือกใช้โครงสร้างแบบจำลอง 3D-UNet ร่วมกับ DenseNet และ ResNet สืบเนื่องมาจาก การศึกษางานวิจัยที่เกี่ยวข้องจำนวนหนึ่งสามารถสรุปได้ว่าแบบจำลอง 3D-UNet ร่วมกับ DenseNet และ ResNet มีประสิทธิภาพในการ แบ่งส่วนภาพได้อย่างแม่นยำ ซึ่งโครงการศึกษาครั้งนี้ได้ใช้ API จากงานวิจัยของ Solovyev et al. 2022 [38] สำหรับการสร้าง แบบจำลอง Pre-Trained Model 3D-UNet

จากรูปที่ 3.3 จะแสดงให้เห็นถึงขั้นตอนการทำงานโดยรวม ผลลัพธ์ที่ได้จากการทำงานร่วมกันของแบบจำลองทั้งสองแบบจะแสดง เป็นภาพที่ได้รับการระบุชนิดของพื้นที่ในแต่ละพิกเซล ซึ่งข้อมูลดังกล่าวจะถูกนำไปคำนวณหาพื้นที่ร้อยละของรอยโรคในแต่ละกลีบปอด เพื่อใช้คำนวณหาค่า CT Score ซึ่งใช้ในการคำนวณค่า TSS สำหรับการวินิจฉัยความรุนแรงของพยาธิสภาพที่เกิดขึ้น



รูปที่ 3.3: แผนภาพการทำงานของแบบจำลอง

3.4.1 การเตรียมข้อมูลสำหรับการฝึกฝนและทดสอบแบบจำลอง (Data Preprocessing)

ในขั้นตอนการเตรียมข้อมูลนี้ เริ่มต้นจากการนำภาพถ่ายรังสีคอมพิวเตอร์ปอด และภาพที่ได้จากการเตรียมไฟล์ JSON (Label Mask) มาทำการปรับขนาดจาก 512×512 พิกเซล เป็น 256×256 พิกเซล เพื่อลดพื้นที่ในการใช้หน่วยความจำของ RAM โดยใช้ฟังก์ชัน `cv.resize()` [39] เป็นหนึ่งในโมดูลของ OpenCV ด้วยการทำ Interpolation แบบ **INTER_AREA** สำหรับการปรับขนาดของภาพด้านฉบับ และแบบ **INTER_NEAREST** สำหรับการปรับขนาด Label Mask เพื่อป้องกันไม่ให้ค่าที่ระบุอยู่ในแต่ละพิกเซลนั้นเปลี่ยนแปลงไป นอกจากนี้ เนื่องจากในโครงการนี้ใช้แบบจำลองที่มีขนาดการนำเข้า (Model Input Shape) คือ $128 \times 256 \times 256$ จึงต้องมีการปรับจำนวนภาพถ่ายรังสีคอมพิวเตอร์ปอดของชุดข้อมูลนี้ให้เท่ากันให้อยู่ในช่วง 128 ภาพ โดยแบ่งออกเป็น 3 กรณี ดังนี้

- หากชุดข้อมูลมีจำนวนภาพถ่ายรังสีคอมพิวเตอร์น้อยกว่าหรือเท่ากับ 128 ภาพ ($CT\ Slice \leq 128$) จะทำการเติม (Padding) เมตริกซ์ 0 ที่มีขนาด 256×256 เข้าไปให้ครบจำนวน 128 ภาพ
- หากชุดข้อมูลมีจำนวนภาพถ่ายรังสีคอมพิวเตอร์ระหว่าง 129 ภาพ ถึง 175 ภาพ ($128 < CT\ Slice \leq 175$) ระบบจะทำการเลือกภาพที่อยู่ช่วงตรงกลางจำนวน 128 ภาพ ในการฝึกฝนแบบจำลอง และในส่วนของการนำแบบจำลองไปใช้งานภาพช่วงด้านแล้ว ช่วงท้ายที่อยู่นอกช่วง 128 ภาพ จะถูกแสดงผลในรูปแบบเมตริกซ์ 0 ขนาด 256×256 เนื่องจากส่วนใหญ่ภาพส่วนนี้จะเป็นส่วนเดียวต้นและส่วนท้ายซึ่งไม่มีพื้นที่ปอดปรากฏ
- หากชุดข้อมูลมีจำนวนภาพถ่ายรังสีคอมพิวเตอร์มากกว่า 175 ภาพ ($CT\ Slice \geq 175$) ระบบจะทำการเลือกเฉพาะภาพที่มีลำดับเป็นเลขคี่ ซึ่งทำให้สามารถลดจำนวนภาพลงได้ครึ่งหนึ่ง และจากนั้นจะทำการเติม (Padding) เมตริกซ์ 0 ที่มีขนาด 256×256 เข้าไปให้ครบจำนวน 128 ภาพ เช่นเดียวกับกรณีที่ 1

สำหรับภาพที่ใช้ในการฝึกฝนแบบจำลองแบ่งส่วนรอยโรคจะทำการลบพื้นที่ปอดออก หรือการ Crop เอาเฉพาะพื้นที่ปอดโดยนำภาพถ่ายรังสีคอมพิวเตอร์ปอด Raw Image และ Label Mask ของกลีบปอดมาปรับให้เป็นค่า 0 (พื้นหลัง) และ 1 (ปอด) ซึ่งจะได้ภาพ Raw Image มีเฉพาะพื้นที่ปอด ในการฝึกฝนแบบจำลองแบ่งส่วนรอยโรค

ในการฝึกฝนแบบจำลอง คณะผู้จัดทำได้ออกการแบบทดสอบออกเป็นสองแบบหลักๆ ประกอบด้วยการฝึกฝนแบบจำลองด้วยภาพปกติ และภาพที่ผ่านการปรับแต่งด้วยวิธีการ Contrast Limited Adaptive Histogram Equalization (CLAHE) ซึ่งเป็นวิธีการหนึ่งในการปรับแต่งสีภาพให้คมชัดมากยิ่งขึ้นของ `opencv` [40] โดยคณะผู้จัดทำได้ทำการตั้งค่าพารามิเตอร์ของคำสั่งดังในตารางที่ 3.5

ตารางที่ 3.5 รายละเอียดพารามิเตอร์ของการปรับสีแบบ CLAHE

CLAHE Parameter	Value
clipLimit	3.0
tileGridSize	(8,8)

3.4.2 การปรับไฮเปอร์พารามิเตอร์ (Hyperparameter Tuning)

คณะผู้จัดทำได้ทำการปรับค่าพารามิเตอร์ เพื่อหาค่าที่เหมาะสมที่สุดในการตั้งค่าการฝึกแบบจำลองโดยในโครงการนี้ใช้ในโครงงานการศึกษาครั้งนี้คณะผู้จัดทำได้ทำการทดสอบเบลี่ยนค่าต่าง ๆ และในตารางที่ 3.6

ตารางที่ 3.6 รายละเอียดการปรับพารามิเตอร์

Parameter	Value
Loss Function	Dice Loss, Focal Loss, Focal Loss + Dice Loss
Regularizer	L1, L2 (Value Setting = [0.1, 0.01])
Dropout	0.2, 0.3, 0.4, 0.5
Activation Function	Sigmoid, Softmax

3.4.3 Lung Lobe Segmentation

แบบจำลองที่ใช้สำหรับการแบ่งส่วนกลีบปอดจะพัฒนาในรูปแบบ Multiclass Semantic Segmentation เนื่องจากในหนึ่งภาพจะประกอบด้วยปอดทั้งหมด 5 กลีบ โดย Mask ที่เตรียมสำหรับการฝึกแบบจำลองจะระบุเป็นค่า 0, 1, 2, 3, 4 และ 5 สำหรับ Background, Right Upper Lobe (RUL), Right Lower Lobe (RLL), Right Middle Lobe (RML), Left Upper Lobe (LUL), Left Lower Lobe (LLL) ตามลำดับ โดยในโครงการนี้ใช้แบบจำลองโครงสร้างแบบ 3D-UNet โดยมี Backbone เป็นแบบจำลอง DenseNet121, DenseNet169, DenseNet201, ResNet18, ResNet34, ResNet50, ResNet101 และ ResNet152 สำหรับการฝึกแบบจำลองแบ่งส่วนกลีบปอดได้นำเทคนิค Hybrid Loss ระหว่าง Focal Loss กับ Dice Loss มาใช้ในการฝึกแบบจำลอง โดยรายละเอียดพารามิเตอร์ต่าง ๆ ของแบบจำลองแสดงในตารางที่ 3.7

ตารางที่ 3.7 รายละเอียดพารามิเตอร์ของแบบจำลอง (Lung Lobe Model Training Parameters)

Training Parameters	Value
Activation Function	Softmax
Loss Function	Focal Loss + Dice Loss
Optimizer	Adam
Learning Rate	0.0001
Dropout Rate	0.2
Regularizer	L2 = 0.01
Batch Size	1
Max Epochs	200
Epochs Patience	20

3.4.4 Lesion Segmentation

แบบจำลองระบุรอยโรคจะพัฒนาในรูปแบบ Binary Semantic Segmentation ซึ่งผลลัพธ์จากแบบจำลองจะระบุเป็นค่า 1, 0 สำหรับรอยโรคและพื้นหลังตามลำดับ โดยข้อมูลที่ใช้สำหรับการฝึกแบบจำลองจะเป็นข้อมูลภาพที่มีการตัดส่วนนอกที่ไม่ใช่เนื้อปอดออกตั้งที่อยู่ในหัวข้อ 3.4.1 โดยในโครงการนี้ใช้แบบจำลองโครงสร้างแบบ 3D-UNet โดยมี Backbone เป็นแบบจำลอง DenseNet121, DenseNet169, DenseNet201, ResNet18, ResNet34, ResNet50, ResNet101, ResNet152 และมีรายละเอียดพารามิเตอร์ของแบบจำลองดังแสดงในตารางที่ 3.8

ตารางที่ 3.8 รายละเอียดพารามิเตอร์ของแบบจำลอง (Lesion Model Training Parameters)

Training Parameters	Value
Activation Function	Sigmoid
Loss Function	Focal Loss + Dice Loss
Optimizer	Adam
Learning Rate	0.0001
Dropout Rate	0.4
Regularizer	L2 = 0.01
Batch Size	1
Max Epochs	200
Epochs Patience	50

3.5 การคำนวณเปอร์เซ็นต์การติดเชื้อ (Percentage of Infection)

การคำนวณเปอร์เซ็นต์การติดเชื้อ Percentage of Infection (PI%) ในแต่ละกลีบปอดสามารถคำนวณจากการนำจำนวนพิกเซลของรอยโรคในแต่ละกลีบปอดหารด้วยจำนวนพิกเซลของกลีบปอดทั้งหมด โดยพิกเซลของรอยโรคที่นำมาคำนวณจะได้มาจากผลลัพธ์การแบ่งส่วนรอยโรคจากแบบจำลองและพิกเซลของกลีบปอดนั้นได้มาจากผลลัพธ์การแบ่งส่วนกลีบปอดโดยแบบจำลอง ซึ่งเป็นค่าที่ระบุขึ้นในแต่ละพิกเซลของภาพถ่ายรังสีคอมพิวเตอร์ปอด ดังนั้นการคำนวณเปอร์เซ็นต์การติดเชื้อสามารถเขียนเป็นสมการได้ดังต่อไปนี้

$$\text{Percentage of Lesion Area}_{lobe} = \frac{\text{Lesion Area (pixels)}}{\text{Lung Lobe Area (pixels)}} * 100 \quad (3.1)$$

การคำนวณเปอร์เซ็นต์การติดเชื้อของปอด Lung Involvement ซึ่งค่าดังกล่าวสามารถใช้บอกได้ว่าปอดนั้นติดเชื้อไปกี่เปอร์เซ็นต์ แล้ว โดยการคำนวณสามารถคำนวณได้จากจำนวนพิกเซลของรอยโรคทั้งหมดหารด้วยจำนวนพิกเซลของปอด (จำนวนพิกเซลของทุกกลีบปอดรวมกัน)

3.6 การคำนวณค่าระดับความรุนแรง Total Severity Score (TSS)

การคำนวณค่าระดับความรุนแรง Total Severity Score (TSS) คำนวณได้จากการรวมของคะแนน CT Score ของกลีบปอดทั้ง 5 กลีบ ซึ่งคะแนนดังกล่าวนั้นคิดจากเปอร์เซ็นต์การติดเชื้อ (PI%) อิงตามเกณฑ์ตามตารางที่ 2.1 หรือแสดงดังสมการต่อไปนี้

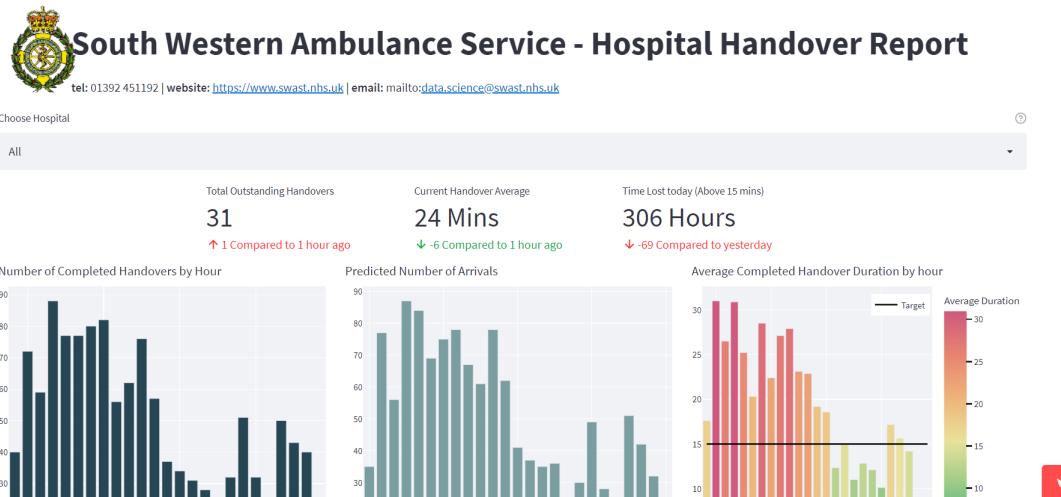
$$CT Score_{lobe} = \begin{cases} 0 & \text{if } \text{Percentage of Infection}_{lobe} = 0 \\ 1 & \text{if } \text{Percentage of Infection}_{lobe} > 0 \text{ and } \leq 5 \\ 2 & \text{if } \text{Percentage of Infection}_{lobe} > 5 \text{ and } \leq 25 \\ 3 & \text{if } \text{Percentage of Infection}_{lobe} > 25 \text{ and } \leq 50 \\ 4 & \text{if } \text{Percentage of Infection}_{lobe} > 50 \text{ and } \leq 75 \\ 5 & \text{if } \text{Percentage of Infection}_{lobe} > 75 \text{ and } \leq 100 \end{cases}$$

การจำแนกระดับความรุนแรงของผู้ป่วยโรคโควิด-19 สามารถจำแนกจากค่า TSS อิงตามเกณฑ์ตามตารางที่ 2.2 โดยการคำนวณค่า TSS สามารถเขียนเป็นสมการได้ดังต่อไปนี้

$$TSS = CT Score_{RUL} + CT Score_{RML} + CT Score_{RLL} + CT Score_{LUL} + CT Score_{LLL} \quad (3.2)$$

3.7 การสร้างหน้าต่างผู้ใช้งาน

คนละผู้จัดทำเลือกใช้ Streamlit เป็นเครื่องมือ (Library) ที่มีความสามารถในการจัดการหน้าต่างผู้ใช้งาน โดยที่เครื่องมือดังกล่าวมีการใช้งานกันอย่างแพร่หลาย และรองรับการทำงานด้วยภาษา Python ซึ่งเป็นภาษาหลักที่ทางคนละผู้จัดทำใช้งาน และยังสามารถนำแบบจำลองการเรียนรู้เชิงลึกมาประยุกต์เข้ากับหน้าต่างผู้ใช้งานได้



รูปที่ 3.4: ตัวอย่างหน้าต่างผู้ใช้งานที่สร้างโดย Streamlit Library
(ที่มา: <https://share.streamlit.io/matthewbrems/อ้างอิงถึง ณ วันที่ 14/03/2022>)

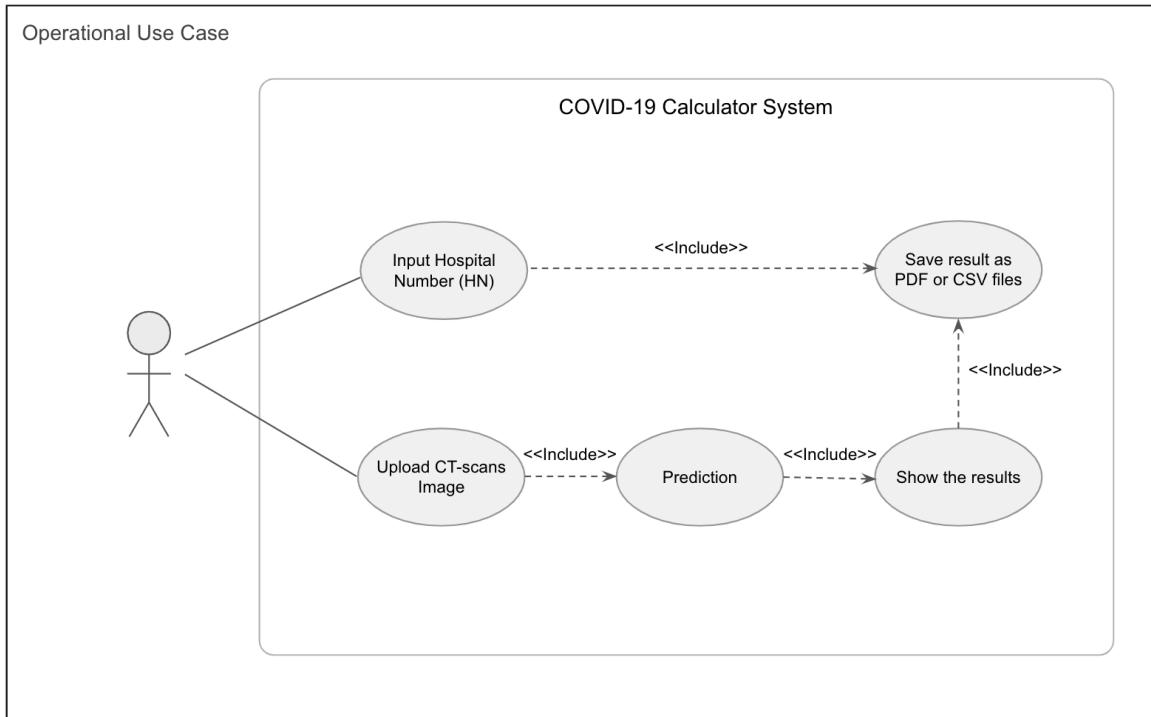
3.8 รายละเอียดเชิงเทคนิค

3.8.1 Requirements

- ผู้ใช้งานสามารถใส่หมายเลขประจำตัวผู้ป่วย (Hospital Number: HN)
- ผู้ใช้งานสามารถอัปโหลดชุดข้อมูลภาพ CT-Scan ของผู้ป่วย
- หน้าต่างผู้ใช้งานสามารถทำนายระดับความรุนแรงโรคโควิด-19 ของผู้ป่วย
- หน้าต่างผู้ใช้งานสามารถแสดงผลตารางทำนายเบอร์เข็นการติดเชื้อ (Percentage of Infection)
- หน้าต่างผู้ใช้งานสามารถแสดงผลคร่าระดับความรุนแรง Total Severity Score (TSS)
- หน้าต่างผู้ใช้งานสามารถแสดงผลคร่าระดับความรุนแรง 3 ระดับคือ Mild, Moderate และ Severe
- หน้าต่างผู้ใช้งานสามารถแสดงเบอร์เข็นต์การติดเชื้อของปอด (Lung Involvement)
- หน้าต่างผู้ใช้งานสามารถแสดงผลตัวเลขที่บ่งบอกว่าผู้ป่วยมีส่วนตัวที่ต้องดูแล

3.8.2 Use Case Diagram

1. ผู้ใช้งานสามารถใส่หมายเลขประจำตัวผู้ป่วย
2. ผู้ใช้งานสามารถอัปโหลดชุดภาพ CT-Scan ของผู้ป่วยยืนยันโควิด-19
3. ผู้ใช้งานสามารถกดทำนายผล
4. ผู้ใช้งานสามารถบันทึกผลการทำนายของผู้ป่วยยืนยันโควิด-19



รูปที่ 3.5: Use Case Diagram

3.8.3 Use Case Narrative

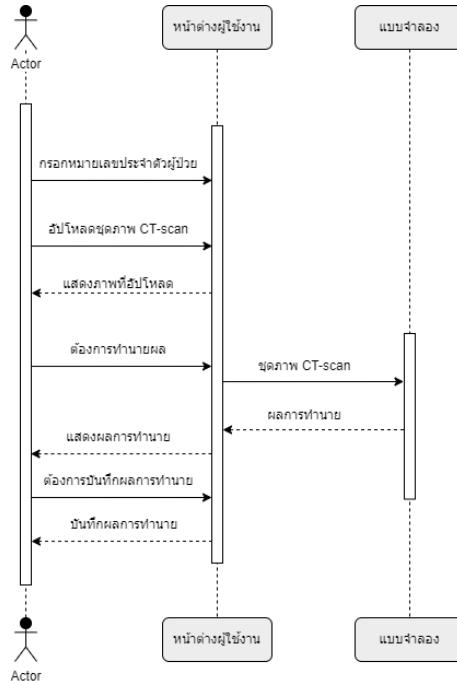
Scenario 1: การทำนายผลของผู้ป่วยยืนยันโรคโควิด-19

Actors: ผู้ใช้งาน

Goal: เพื่อให้ผู้ใช้งานสามารถทำนายผลของผู้ป่วยยืนยันโรคโควิด-19

Main Success Scenario:

1. ระบบแสดงหน้าต่างผู้ใช้งาน
2. ผู้ใช้งานกรอกหมายเลขอVERRIDE ประจำตัวผู้ป่วย และอัปโหลดชุดภาพ CT-Scan
3. ผู้ใช้งานต้องการทำนายผล
4. ระบบแสดงผลการทำนาย
5. ผู้ใช้งานบันทึกผลการทำนายได้สำเร็จ

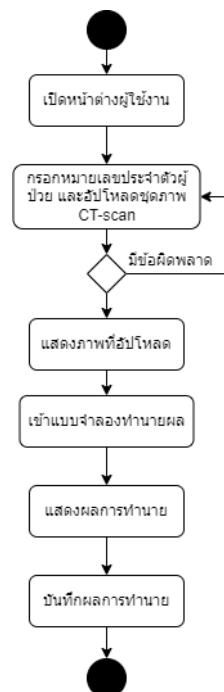


รูปที่ 3.6: Sequence Diagram ของการทำนายและบันทึกผลของผู้ป่วยโรค covid-19

3.8.4 Activity Diagram

3.8.4.1 การทำนายผลของผู้ป่วยยืนยันโรคโควิด-19

เมื่อผู้ใช้งานต้องการทำนายและบันทึกผลของผู้ป่วยยืนยันโรคโควิด-19 ผู้ใช้งานต้องเบิดหน้าต่างผู้ใช้งาน และกรอกหมายเลขอประจำตัวผู้ป่วย รวมถึงต้องอัปโหลดข้อมูล CT-Scan ของผู้ป่วยยืนยันโรคโควิด-19 หากไม่มีข้อผิดพลาดหน้าต่างผู้ใช้งานจะแสดงภาพที่ผู้ใช้งานบันทึกลงขึ้น หลังจากนั้นหน้าต่างผู้ใช้งานจะนำข้อมูลภาพเข้าแบบจำลองเพื่อทำการทำนายผล และแสดงผลทำนายให้กับผู้ใช้งาน และถ้าหากผู้ใช้งานต้องการบันทึกผลการทำนายก็สามารถบันทึกผลการทำนายเองได้



รูปที่ 3.7: Activity Diagram

3.9 การประเมินผล (Evaluation)

3.9.1 การประเมินผลแบบจำลอง

คณะกรรมการผู้จัดทำจะประเมินประสิทธิภาพของแบบจำลองในการประเมินความรุนแรงของพยาธิสภาพที่เกิดในปอดโดยการประเมินผลกับชุดข้อมูล Test Set 1 สำหรับการแบ่งส่วนกลีบปอด และพื้นที่รอยโรคโดยใช้ค่า Intersection over Union (IoU), Dice Similarity Coefficient (DSC), Accuracy, Precision, Sensitivity และ Specificity โดยค่าที่ใช้ในการตัดเลือกแบบจำลองจะใช้ค่า DSC เรียกว่า F1-score ซึ่งนิยมใช้ในหลายงานวิจัยที่เกี่ยวข้องกับการแบ่งส่วนภาพอย่างว่า F1-score ซึ่งนิยมใช้ในหลายงานวิจัยที่เกี่ยวข้องกับการแบ่งส่วนภาพ

3.9.2 การประเมินผลการคำนวณค่าระดับความรุนแรง (Total Severity Score)

คณะกรรมการผู้จัดทำจะประเมินผลการคำนวณค่า Total Severity Score (TSS) จากการทำนายผลของแบบจำลองผ่านทางหน้าต่างผู้ใช้งานเทียบกับค่า TSS ที่ได้จากการวินิจฉัยโดยรังสีแพทย์ ด้วยการคำนวณค่าคณิตศาสตร์ทางสถิติ Correlation of Coefficient, R-Square เพื่อศูนย์รวมความสัมพันธ์ของการคำนวณค่า TSS จากการทำนายโดยแบบจำลองและการวินิจฉัยโดยรังสีแพทย์

3.9.3 การประเมินผลโดยผู้ใช้งาน (User Evaluation)

การประเมินจากบุคคลภารณ์ทางการแพทย์ โดยรวมความพึงพอใจของภาพรวมหน้าต่างผู้ใช้งาน ประกอบไปด้วยความสวยงาม การใช้งาน ความสามารถของหน้าต่างผู้ใช้งาน และข้อเสนอแนะต่าง ๆ โดยนำมาทำการวิเคราะห์ รวมถึงประเมินหน้าต่างผู้ใช้งาน

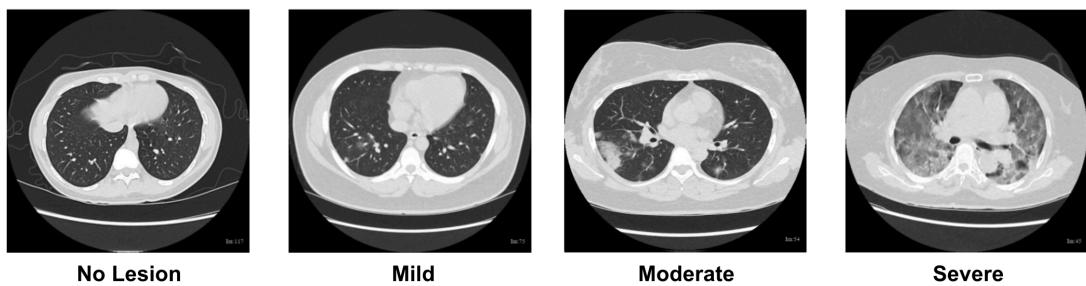
3.9.4 การประเมินผลหน้าต่างผู้ใช้งาน

การประเมินประสิทธิภาพของหน้าต่างผู้ใช้งานจากการทดลองในการทำนายผลกระทบระดับความรุนแรงของโรคโควิด-19 เพื่อตัดความรวดเร็วในการทำนาย และผลการทำนายของแบบจำลองว่ามีความแม่นยำมากน้อยเพียงใด

บทที่ 4 ผลการวิจัย และอภิปรายผล

4.1 ข้อมูลดิบ

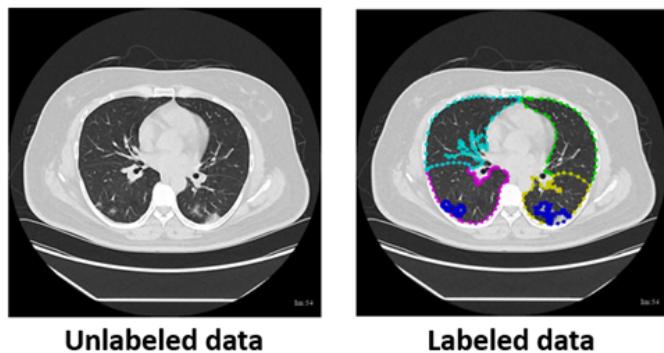
ชุดข้อมูล Training Set ประกอบด้วยภาพถ่ายรังสีคอมพิวเตอร์ปอดของผู้ป่วยติดเชื้อโควิด-19 จำนวน 32 ราย โดยแบ่งออกเป็น กลุ่มที่ไม่พบรอยโรคในปอดจำนวน 8 ราย (No Lesion) และกลุ่มที่พบรอยโรคจำนวน 24 ราย ซึ่งแบ่งตามระดับความรุนแรงออกเป็น Mild, Moderate และ Severe กลุ่มละ 8 ราย โดยชุดข้อมูลภาพถ่ายก่อตัวเป็นภาพในแกนตัดขวาง (Axial) โดยมีลักษณะข้อมูลเป็นไฟล์สกุล JPG ขนาด 512x512 พิกเซล รวมทั้งสิ้นจำนวน 3,752 ภาพ



รูปที่ 4.1: ตัวอย่างข้อมูลดิบ (Raw Data) ในประเภทของกลุ่มความรุนแรง

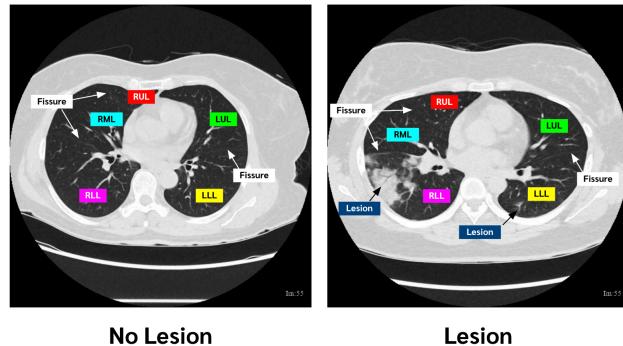
4.2 การเตรียมข้อมูล

คณะกรรมการจัดทำได้นำข้อมูลดิบมาระบุตำแหน่งด้วยโปรแกรม LabelME โดยการระบุเป็นตำแหน่งจุด (Polygon) ตามรูปร่างของกลีบปอดและรอยโรคตามตัวอย่างรูปที่ 4.2



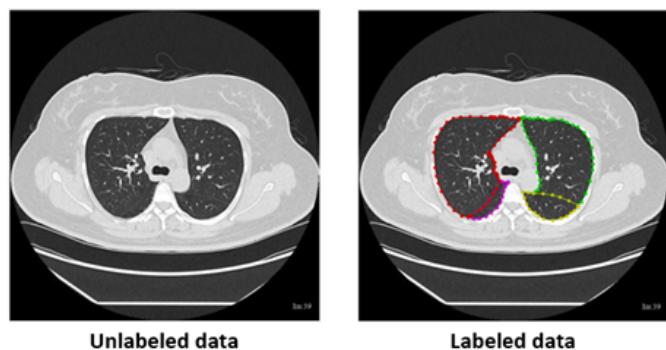
รูปที่ 4.2: ภาพเปรียบเทียบข้อมูลดิบและข้อมูลที่มีการระบุรายละเอียด

4.2.1 การระบุตำแหน่งกลีบปอดและรอยโรค



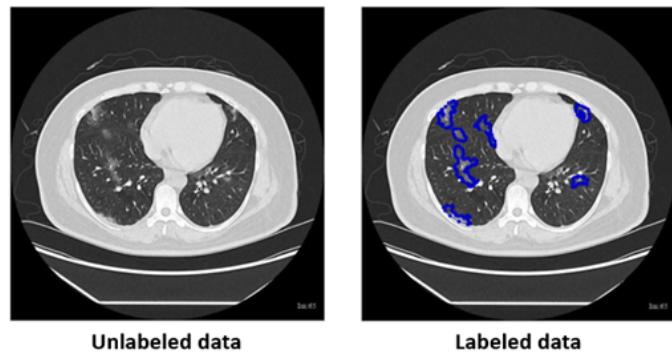
รูปที่ 4.3: ภาพวิภาคของภาพถ่ายรังสีคอมพิวเตอร์ปอดปกติ และปอดที่ติดเชื้อโควิด-19

การระบุพื้นที่แต่ละกลีบปอดสามารถสังเกตได้จากการอยู่แยกของกลีบปอด (Fissure) โดยปอดข้างขวาจะบรรยายแยก 2 รอย เนื่องจากปอดข้างขวามีจำนวนกลีบปอด 3 กลีบ 'ได้แก่' กลีบบน (Right Upper Lobe) กลีบกลาง (Right Middle Lobe) และกลีบล่าง (Right Lower Lobe) ในส่วนของปอดข้างซ้ายประกอบด้วย 2 กลีบ 'ได้แก่' กลีบบน (Left Upper Lobe) และกลีบล่าง (Left Lower Lobe) ดังนั้นจึงบรรยายแยก 1 รอย ซึ่งชื่อที่ใช้ในการระบุตำแหน่งมีดังนี้ RUL: Right Upper Lobe, RLL: Right Lower Lobe, RML: Right Middle Lobe, LUL: Left Upper Lobe และ LLL: Left Lower Lobe



รูปที่ 4.4: ภาพเปรียบเทียบก่อน-หลังการระบุพื้นที่กลีบปอด

ส่วนของพื้นที่ร้ายโรคใช้ชื่อในการระบุคือ Lesion โดยปกติแล้วลักษณะของภาพถ่ายรังสีคอมพิวเตอร์ปอดที่ไม่มีการติดเชื้อโควิด-19 จะมีลักษณะเป็นสีดำทึบหัวทั้งปอดและมีพื้นที่สีขาวเฉพาะบริเวณเส้นเลือดดังรูปที่ 4.4 ซึ่งสำหรับรอยโรคที่เกิดขึ้นจะสังเกตเห็นได้จากลักษณะที่เป็นสีขาวในเนื้อปอด โดยส่วนใหญ่แล้วจะบรรยายโรคชนิด Ground Glass Opacity และ Consolidation ดังรูปที่ 4.5



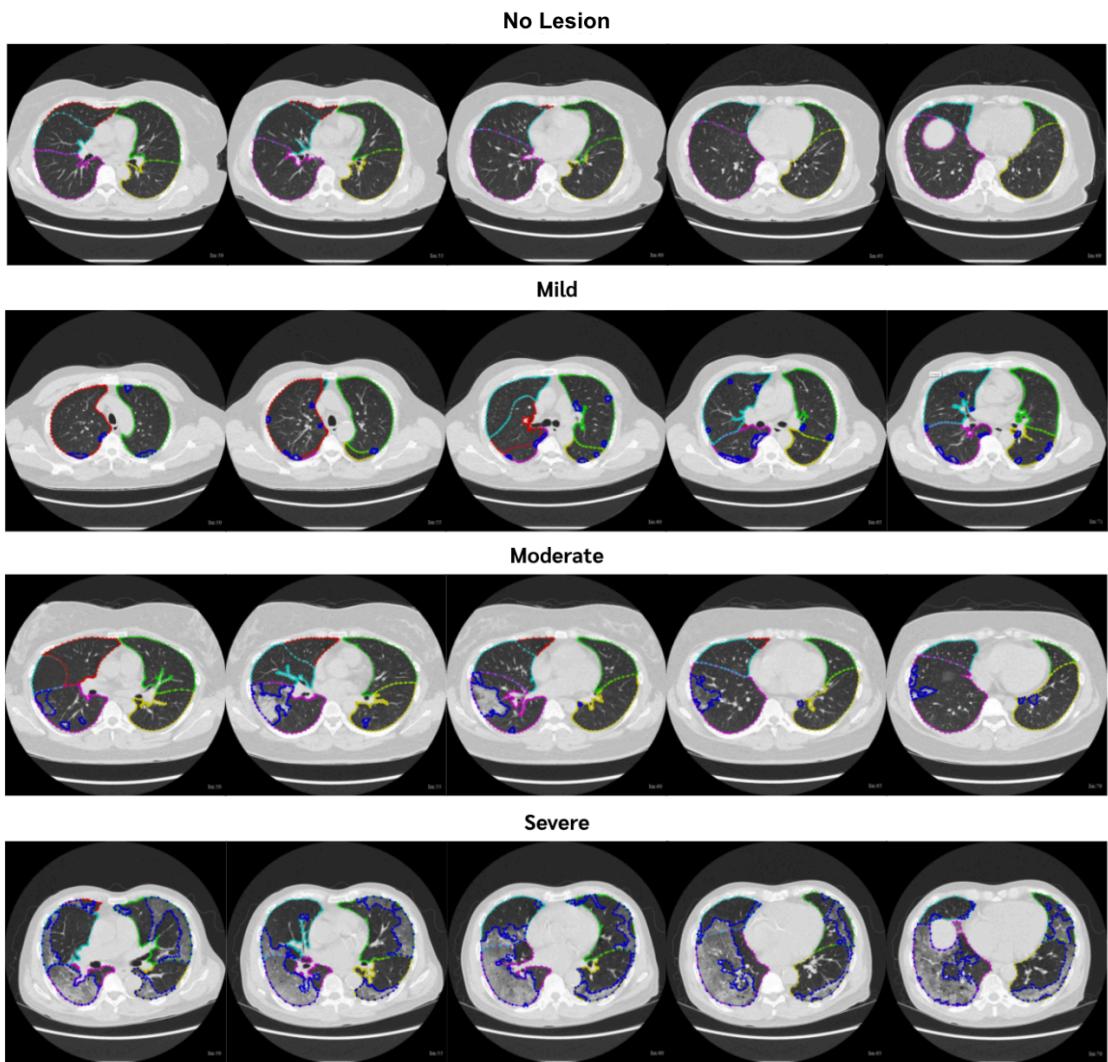
รูปที่ 4.5: ภาพเปรียบเทียบก่อน-หลังการระบุพื้นที่รอยโรค

4.2.2 ความแตกต่างของภาพถ่ายรังสีคอมพิวเตอร์ปอด

ภาพถ่ายรังสีคอมพิวเตอร์ปอดประกอบด้วยกลุ่มที่ไม่มีรอยโรค (No Lesion) และกลุ่มที่มีรอยโรคโดยถูกจำแนกระดับความรุนแรงออกเป็น 3 ประเภท คือ Mild, Moderate และ Severe ซึ่งประเภทของความรุนแรงนั้นมีการอ้างอิงมาจาก การวิจัยฉัยของรังสีแพทย์ ร่วมกับการคำนวณค่าความรุนแรง Total Severity Score (TSS) ของผู้ป่วยรายนั้น ๆ

จากที่ระบุไปข้างต้น (4.2.1) ปอดจะถูกจำแนกออกเป็น 5 กลีบ โดยแต่ละกลีบจะถูกคำนวณหาพื้นที่ว่าแต่ละปอดนั้นมีรอยโรคอยู่ในพื้นที่กลีบปอดนั้น ๆ เท่าใด (CT Score) และจึงนำผลลัพธ์มารวมกัน (TSS) โดยความรุนแรงของโรคโควิด-19 จะมีลักษณะดังนี้

1. กลุ่ม No Lesion พื้นที่ปอดจะมีลักษณะเป็นสีดำทึบทั้งปอด ไม่พบรอยโรค
2. กลุ่ม Mild พื้นที่ปอดส่วนใหญ่จะมีลักษณะเป็นสีดำทึบ พบรอยโรคเพียงเล็กน้อย โดยค่า TSS จะอยู่ในช่วง 1 ถึง 7
3. กลุ่ม Moderate ตำแหน่งของรอยโรคมีลักษณะกระจายตัว แต่ก็ไม่ได้พบร่องรอยโรคทั้งปอด โดยแต่ละรอยโรคจะมีขนาดใหญ่ขึ้น เมื่อเปรียบเทียบกับรอยโรคกลุ่ม Mild โดยค่า TSS อยู่ในช่วง 8 ถึง 17
4. กลุ่ม Severe พื้นที่ปอดส่วนใหญ่จะพบรอยโรคเกือบทั้งหมด โดยค่า TSS จะอยู่ในช่วง 18 ถึง 25



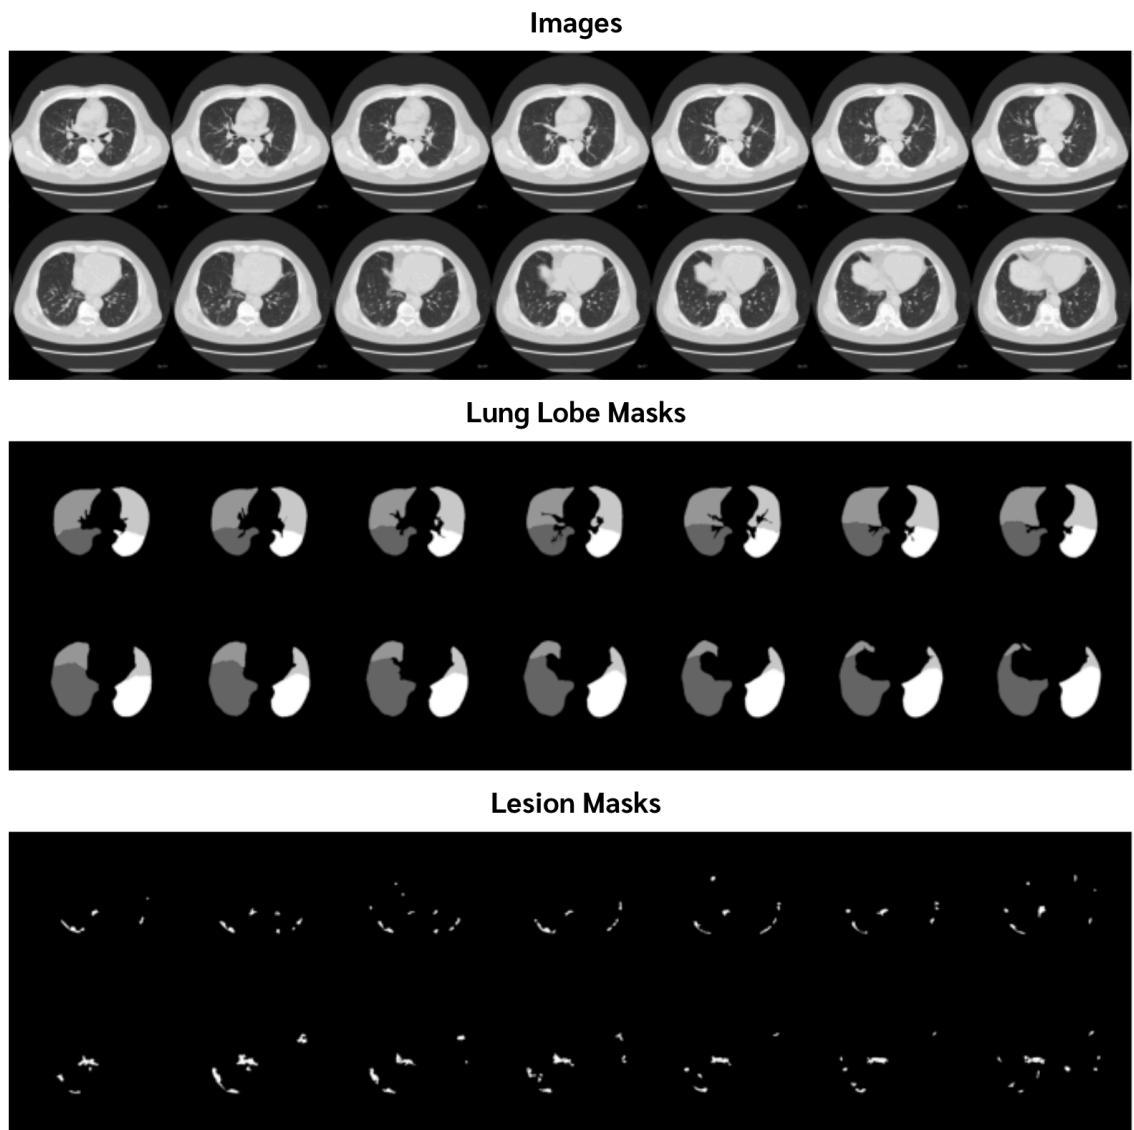
รูปที่ 4.6: ภาพที่ผ่านการระบุตำแหน่งกลีบปอดและรอยโรคในแต่ละประเภทความรุนแรง

4.2.3 การเตรียมไฟล์สำหรับการฝึกฝนแบบจำลอง

ผลลัพธ์จากการใส่คำอธิบายภาพด้วยโปรแกรม LabelME ให้ผลลัพธ์เป็นไฟล์ JSON ดังรูปที่ 4.7 ซึ่งไฟล์ดังกล่าวมีลักษณะของข้อมูลเป็น Dictionary โดย Keys ของ Dictionary ในข้อมูลจะถูกแบ่งออกเป็น Version, Flags, Shapes, ImagePath, ImageData, ImageHeight และ ImageWidth โดยไฟล์ JSON จะถูกนำมาแปลงให้อยู่ในรูปของเมทริกซ์ด้วย Library Numpy เพื่อเตรียมลักษณะของข้อมูลให้เหมาะสมกับการฝึกฝนแบบจำลอง เนื่องจากแบบจำลองจำเป็นต้องทราบข้อมูลว่าบริเวณใดในภาพเป็นพื้นที่ของปอดหรือรอยโรค ซึ่งเมื่อทำการระบุรายละเอียดของแต่ละตำแหน่งในภาพแล้วจะถูกแสดงดังรูปที่ 4.8

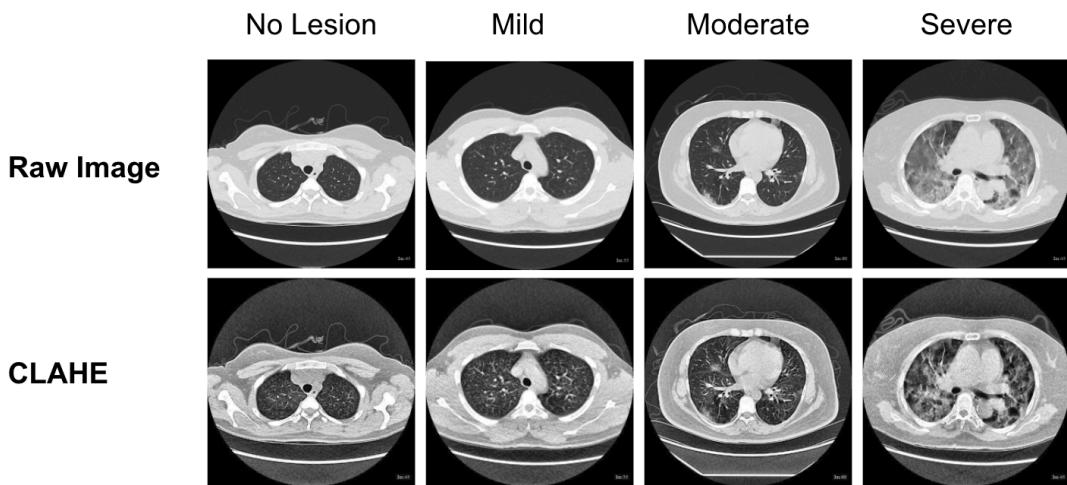
```
('Flags': {},
'ImageData': '9j/4AAQSkZjRgABAQAAAQABAAD/2wBDAgGBgycGBQjhBwcJCQjKDBQNDAzL
'ImageHeight': 512,
'ImagePath': 'image-0059.jpg',
'ImageWidth': 512,
'Shapes': [{"Flags": {},
'group_id': 1,
'label': 'RL',
'points': [[139.9503722084367, 332.5062034739454],
[147.89081885856078, 327.2952853598015],
[159.5533498759305, 321.83622828784115],
[176.17866004962778, 318.6104218362283]}]
```

รูปที่ 4.7: ตัวอย่างไฟล์ JSON ที่ได้จากการทำงานโปรแกรม LabelME



รูปที่ 4.8: ภาพของการเตรียมไฟล์ JSON บางส่วนของเคส Mild 04

ทั้งนี้คณานักจัดทำได้ทำการศึกษาเปรียบเทียบผลลัพธ์ระหว่างภาพถ่ายรังสีคอมพิวเตอร์ (CT-Scan) ที่ไม่ได้มีการปรับสี เทียบกับภาพที่ทำการปรับสีโดยใช้เทคนิค CLAHE ซึ่งภาพที่ได้รับการปรับสีนั้นสามารถเห็นรอยแยกของกลีบปอดและรอยโรคได้ชัดเจนมากขึ้น ดังตัวอย่างรูปที่ 4.9



รูปที่ 4.9: ตัวอย่างภาพต้นฉบับ (Raw Image) และภาพที่ผ่านการปรับสี (CLAHE)

4.3 การตรวจสอบผลการระบุตำแหน่งกลีบปอดและรอยโรค

ภาพที่ผ่านการระบุตำแหน่งกลีบปอดและรอยโรคจะถูกตรวจสอบความถูกต้องโดยรังสีแพทย์ ซึ่งรังสีแพทย์จะทำการตรวจสอบและแก้ไขข้อมูลหากมีการระบุตำแหน่งผิดพลาดผ่านการใช้งานโปรแกรม LabelME โดยข้อมูลได้ผ่านการตรวจสอบและยืนยันความถูกต้องแล้ว คิดเป็นจำนวนทั้งสิ้น 3,752 ภาพ หรือทั้งหมดของผู้ป่วยโควิด-19 จำนวน 32 ราย ของชุดข้อมูล Training Set และจำนวน 1,314 ภาพ หรือทั้งหมดของผู้ป่วยโควิด-19 จำนวน 8 ราย ของชุดข้อมูล Test Set 1

4.4 การพัฒนาแบบจำลอง

โครงงานนี้ได้ทำการศึกษาและพัฒนา 2 แบบจำลอง 'ได้แก่' Lung Lobe Model สำหรับการแบ่งส่วนกลีบปอด และ Lesion Model สำหรับการแบ่งส่วนรอยโรค โดยฝึกแบบจำลอง 3D-UNet โดยมี Backbone คือ DenseNet 3 แบบจำลอง และ ResNet 5 แบบจำลอง อีกทั้งยังได้ทดลองวิธีการปรับสีภาพโดยเบรียบเทียบระหว่างการใช้สีภาพต้นฉบับ (Raw Image) และวิธีปรับสีภาพโดยเทคนิค CLAHE เพื่อให้ภาพมีความชัดที่มากขึ้น ในส่วนการตั้งค่าสำหรับฝึกแบบจำลองได้ใช้ชุดข้อมูลที่แบ่งจากชุดข้อมูลฝึกฝนจำนวน 32 ราย โดยแบ่งออกมาใช้เป็น Validation Set จำนวน 8 ราย โดยผลการปรับไอล์เยอร์ฟารามิเตอร์ได้อธิบายในหัวข้อที่ 4.4.1 จากนั้นใช้ค่าที่ได้จากการปรับไอล์เยอร์ฟารามิเตอร์ในการตั้งค่าสำหรับการฝึกแบบจำลองซึ่งได้แสดงในตารางที่ 3.7, 3.8 สำหรับการฝึกแบบจำลองแบ่งส่วนกลีบปอด และแบบจำลองแบ่งส่วนรอยโรคตามลำดับ

การทดสอบแบบจำลองที่ได้จากการฝึกแบบจำลองที่ได้อธิบายในหัวข้อที่ 4.4.1 จำนวน 8 ราย โดยภาพจะได้รับการระบุพื้นที่กลีบปอดและรอยโรคในภาพและถูกตรวจสอบโดยรังสีแพทย์แล้ว โดยผลการทดสอบได้อธิบายในลำดับถัดไป

4.4.1 ผลการปรับไอล์เยอร์ฟารามิเตอร์ (Hyperparameter Tuning)

4.4.1.1 Loss Function

การปรับ Loss Function สำหรับการฝึกแบบจำลอง ในโครงงานการศึกษาครั้งนี้ได้ทดลองใช้ฟังก์ชัน Dice Loss, Focal Loss และ Dice Loss + Focal Loss ซึ่งคือการคำนวณค่า Loss ประเภทสม (Hybrid Loss) พบว่าการฝึกแบบจำลองโดยใช้ Dice Loss + Focal Loss จะได้แบบจำลองที่มีประสิทธิภาพที่ดีกว่าการใช้ฟังก์ชัน Dice Loss หรือ Focal Loss เพียงอย่างเดียว

ตารางที่ 4.1 ตารางเปรียบเทียบผลการปรับ Loss Function

Loss Function	IoU	DSC
Dice_Loss	87.05%	92.65%
Focal_Loss	82.32%	89.54%
Focal_Loss + Dice_Loss	87.14%	92.73%

4.4.1.2 Regularizer

การทำ Regularization สำหรับการเพิ่มประสิทธิภาพให้แบบจำลอง และลดปัญหา Overfitting ของแบบจำลอง ซึ่งคือปัญหาที่เกิดจากแบบจำลองเรียนรู้ชุดข้อมูลฝึกฝน (Train Set) มาจนเกินไป ส่งผลให้มีแบบจำลองทำนายชุดข้อมูลทดสอบ (Test Set) แล้วมีประสิทธิภาพที่ไม่ดี โครงการศึกษาครั้งนี้ได้ลองใช้ Regularizer คือ L1 และ L2 พบร่วมกันใช้ L2 ใน การฝึกฝนแบบจำลองได้แบบจำลองที่มีประสิทธิภาพมากกว่าการใช้ L1 และได้มีการปรับค่าที่ใช้ในการตั้งค่า L2 โดยทดลองใช้ค่าเท่ากับ 0.1 และ 0.01 พบร่วมกัน L2 Regularizer เท่ากับ 0.01 ให้ผลค่า DSC ต่ำกว่าการตั้งค่า L2 Regularizer เท่ากับ 0.1

ตารางที่ 4.2 ตารางเปรียบเทียบผลการปรับ Regularizer

Regularizer	IoU	DSC
L1	87.71%	93.06%
L2	87.88%	93.20%

ตารางที่ 4.3 ตารางเปรียบเทียบผลการตั้งค่า L2 Regularizer

Regularizer	Value	IoU	DSC
L2	0.1	88.44%	93.38%
L2	0.01	88.73%	93.59%

4.4.1.3 Dropout

โครงการศึกษาครั้งนี้ได้มีการเพิ่มค่า Dropout ซึ่งเป็นหนึ่งในวิธีการเพิ่มประสิทธิภาพให้แบบจำลอง และลดปัญหา Overfitting ของแบบจำลองเข้าเดียวกับการทำ Regularization สำหรับแบบจำลองแบ่งส่วนกลีบปอดได้ทดลองค่า Dropout คือ 0.2, 0.3 และ 0.4 พบร่วมกัน 0.2 จะได้แบบจำลองแบ่งส่วนกลีบปอดที่มีประสิทธิภาพที่สุด และแบบจำลองแบ่งส่วนรอยโรคได้ทดลองค่า Dropout คือ 0.2, 0.3, 0.4 และ 0.5 พบร่วมกัน 0.4 จะได้แบบจำลองแบ่งส่วนรอยโรคที่มีประสิทธิภาพที่สุด

ตารางที่ 4.4 ตารางเปรียบเทียบการปรับค่า Dropout ของแบบจำลองแบ่งส่วนกลีบปอด

Dropout	IoU	DSC
0.2	89.52%	92.18%
0.3	89.37%	92.04%
0.4	87.54%	90.40%

ตารางที่ 4.5 ตารางเปรียบเทียบการปรับค่า Dropout ของแบบจำลองแบ่งส่วนรอยโรค

Dropout	IoU	DSC
0.2	76.88%	81.68%
0.3	74.71%	79.68%
0.4	79.35%	84.03%
0.5	74.78%	79.34%

4.4.2 ผลการทดสอบแบบจำลองสำหรับการแบ่งส่วนกลีบปอต

การทดสอบแบบจำลองสำหรับการแบ่งส่วนกลีบปอตจะแบ่งเป็นการทดสอบกับภาพถ่ายรังสีคอมพิวเตอร์ต้นฉบับสำหรับแบบจำลองที่ฝึกฝนกับภาพต้นฉบับ และภาพถ่ายรังสีคอมพิวเตอร์ปอดที่ใช้วิธีปรับสีภาพ CLAHE สำหรับแบบจำลองที่ฝึกฝนกับภาพที่ผ่านการปรับสีภาพ CLAHE โดยแบบจำลองได้ผ่านการฝึกฝนตามการตั้งค่าพารามิเตอร์ที่ได้ผ่านการคัดเลือกค่าที่เหมาะสมสำหรับการฝึกฝนซึ่งได้อธิบายไว้ในหัวข้อที่ 4.4.1 ได้ทำการทดสอบแบบจำลองกับชุดข้อมูล Test Set 1 โดยผลการทดสอบแสดงในตารางที่ 4.6, 4.7 พบว่าแบบจำลองที่ทดสอบกับภาพถ่ายรังสีคอมพิวเตอร์ต้นฉบับมีประสิทธิภาพในการแบ่งส่วนกลีบปอดมากที่สุดคือแบบจำลอง 3D-UNet ร่วมกับ DenseNet169 โดยมีค่า IoU เท่ากับ 90.44%, DSC เท่ากับ 92.89%, Accuracy เท่ากับ 98.49%, Precision เท่ากับ 94.18%, Sensitivity เท่ากับ 95.52% และ Specificity เท่ากับ 98.49%

ตารางที่ 4.6 ผลการทดสอบแบบจำลองกับชุดข้อมูล Test Set 1 โดยใช้ภาพต้นฉบับ Raw Image

Model	Backbone	IoU	DSC	Accuracy	Precision	Sensitivity	Specificity
3D-UNet	DenseNet121	89.36%	91.85%	98.46%	94.00%	94.67%	98.48%
3D-UNet	DenseNet169	90.44%	92.89%	98.49%	94.18%	95.52%	98.49%
3D-UNet	DenseNet201	89.58%	92.11%	98.47%	94.15%	94.77%	98.50%
3D-UNet	ResNet18	88.24%	90.88%	98.43%	93.55%	94.11%	98.48%
3D-UNet	ResNet34	88.53%	91.11%	98.45%	93.82%	93.94%	98.50%
3D-UNet	ResNet50	88.70%	91.44%	98.45%	93.80%	94.18%	98.49%
3D-UNet	ResNet101	87.92%	90.68%	98.45%	93.89%	93.23%	98.50%
3D-UNet	ResNet152	88.30%	91.01%	98.45%	93.69%	93.83%	98.50%

ตารางที่ 4.7 ผลการทดสอบแบบจำลองกับชุดข้อมูล Test Set 1 โดยใช้วิธีปรับสีภาพ CLAHE

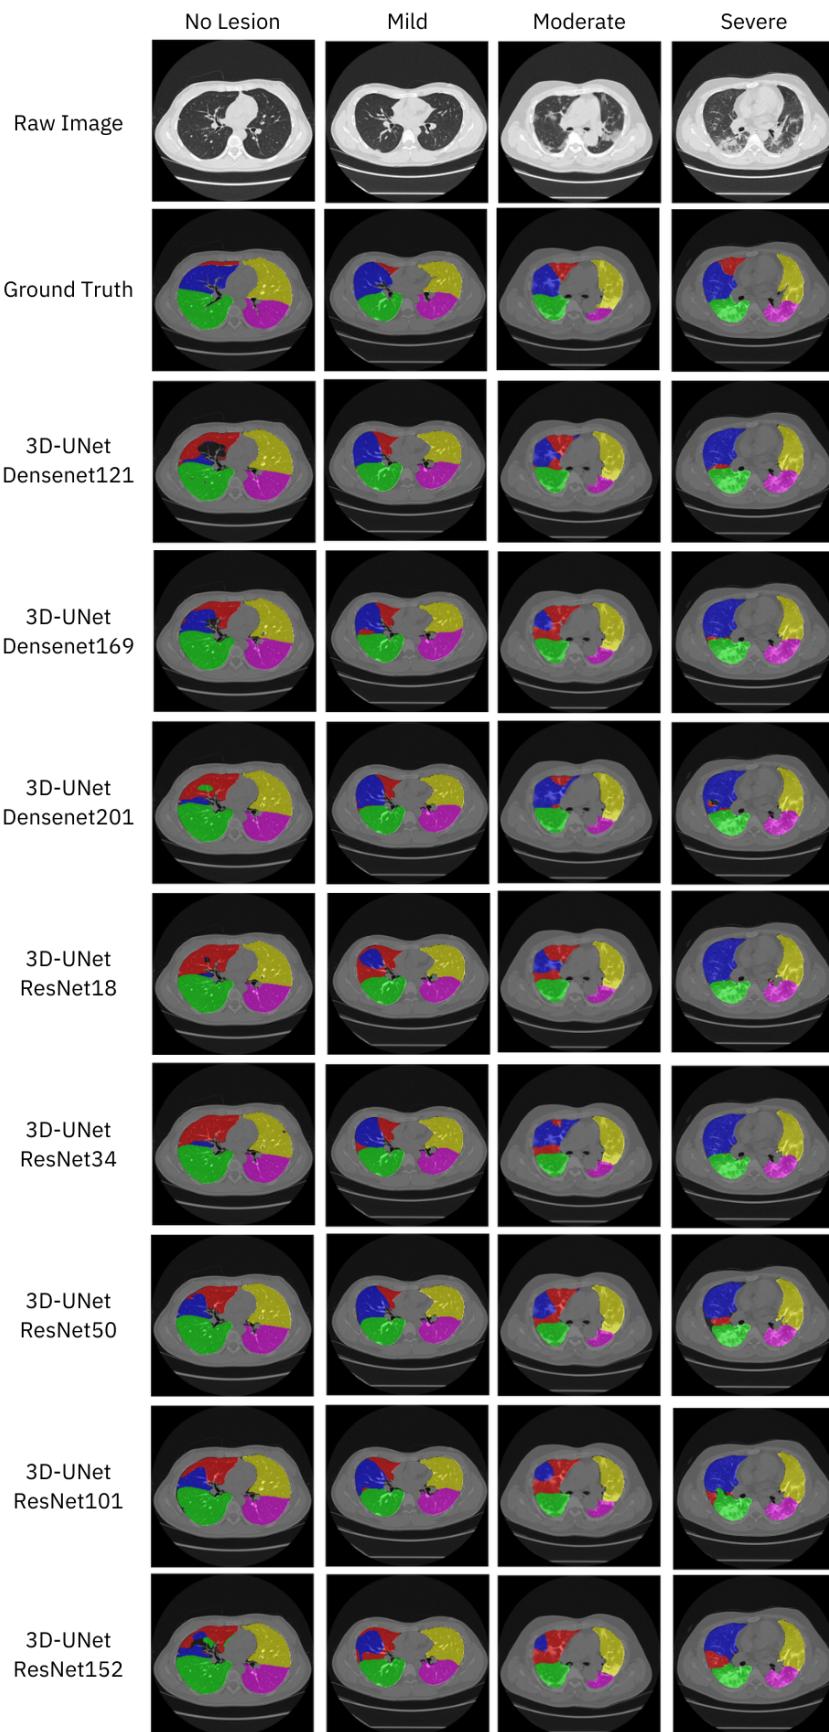
Model	Backbone	IoU	DSC	Accuracy	Precision	Sensitivity	Specificity
3D-UNet	DenseNet121	87.49%	90.25%	98.45%	93.02%	93.62%	98.51%
3D-UNet	DenseNet169	88.75%	91.50%	98.46%	94.58%	93.50%	98.51%
3D-UNet	DenseNet201	87.48%	90.29%	98.44%	93.40%	93.24%	98.50%
3D-UNet	ResNet18	86.34%	89.37%	98.41%	93.14%	92.42%	98.51%
3D-UNet	ResNet34	86.61%	89.54%	98.42%	92.78%	92.92%	98.49%
3D-UNet	ResNet50	86.52%	89.62%	98.43%	93.27%	92.37%	98.51%
3D-UNet	ResNet101	86.20%	89.07%	98.43%	90.55%	94.76%	98.47%
3D-UNet	ResNet152	83.17%	86.03%	98.45%	88.72%	93.55%	98.50%

จากผลการทดสอบในตารางที่ 4.6, 4.7 จะพบว่าการฝึกฝนแบบจำลองด้วยภาพถ่ายรังสีคอมพิวเตอร์ต้นฉบับจะให้ผลลัพธ์การแบ่งส่วนกลีบปอดได้ดีกว่าการใช้ภาพถ่ายรังสีคอมพิวเตอร์ที่ได้รับการปรับสีแบบ CLAHE โดยภาพตัวอย่างการแบ่งส่วนกลีบปอดของแต่ละแบบจำลองที่ฝึกฝนกับภาพต้นฉบับได้แสดงดังรูปที่ 4.10 และแบบจำลองที่ฝึกฝนกับภาพที่ใช้วิธีปรับสีภาพ CLAHE แสดงดังรูปที่ 4.11 โดยภาพตัวอย่างผลลัพธ์ 4.10 และ 4.11 จะเป็นภาพถ่ายรังสีคอมพิวเตอร์ซึ่งบ่งบอกถึงความข้องปอด ซึ่งช่วงภาพดังกล่าวจะแสดงกลีบปอดครบถ้วน 5 กลีบ โดยปอดข้างขวาและข้างซ้ายได้ใช้สีในการแสดงผลคือ กลีบบนขวา RUL (สีแดง), กลีบกลางขวา RML (สีเข้มเงิน), กลีบล่างขวา RLL (สีเขียว), กลีบบนซ้าย LUL (สีเหลือง) และ กลีบล่างซ้าย LLL (สีชมพู) โดยเมื่อพิจารณาภาพผลลัพธ์การแบ่งส่วนภาพในกลุ่มผู้ป่วยไม่มีรอยโรค (No Lesion) ของแบบจำลอง 3D-UNet + DenseNet169 ซึ่งเป็นแบบจำลองที่มีผลประสิทธิภาพดี DSC ดีที่สุด พบว่าแบบจำลองที่ฝึกฝนกับภาพต้นฉบับให้ผลลัพธ์ที่แม่นยำกว่าแบบจำลองที่ฝึกฝนกับภาพที่ปรับแบบ CLAHE โดยสามารถสังเกตได้จากปอดกลีบกลางขวา RML (สีเข้มเงิน) แสดงในภาพที่ 4.11 แบบจำลองแบ่งส่วนภาพผิดเบื้องหลังและปอดกลีบบนขวา RUL (สีแดง) ซึ่งเมื่อเปรียบเทียบกับภาพที่ 4.10 แบบจำลองที่ฝึกฝนกับภาพต้นฉบับสามารถแบ่งส่วนปอดกลีบกลางขวา RML (สีเข้มเงิน) ได้แม่นยำมากกว่า

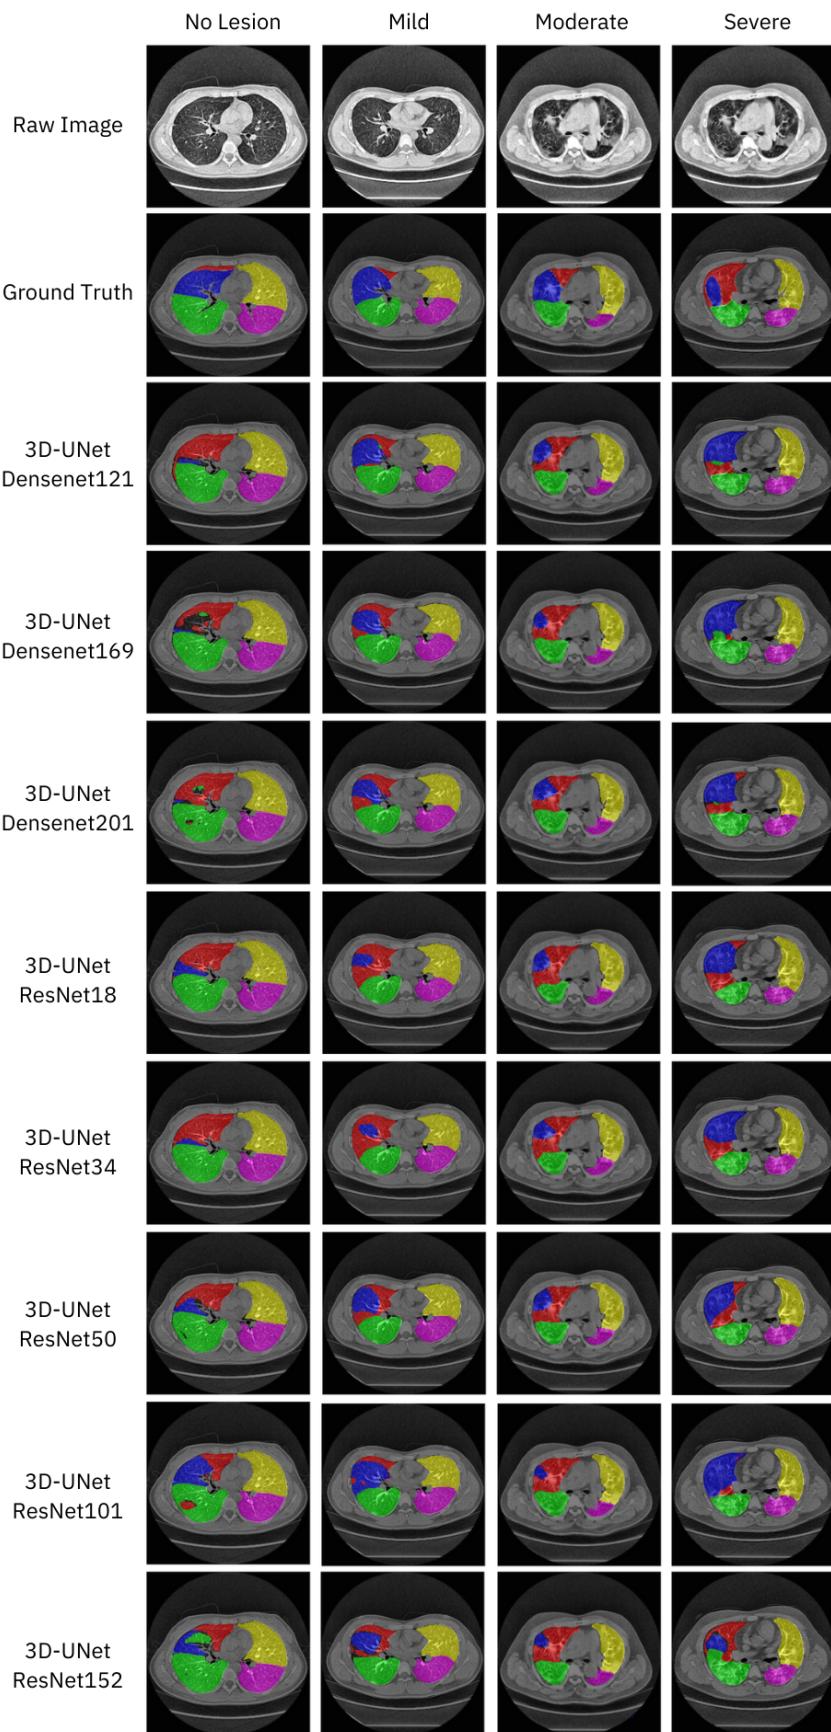
เมื่อนำผลการทดสอบการแบ่งส่วนกลีบปอดของแบบจำลอง 3D-UNet + DenseNet169 ที่ฝึกฝนกับภาพต้นฉบับมาแจกแจงค่า DSC ดังแสดงในตารางที่ 4.8 แสดงให้เห็นว่าแบบจำลองแบ่งส่วนกลีบปอดของกลุ่มผู้ป่วยที่มีระดับความรุนแรงระดับ Mild ได้ดีกว่าระดับความรุนแรงอื่นๆ และจากภาพที่ 4.10 แสดงให้เห็นว่าแบบจำลองสามารถแบ่งส่วนกลีบปอดข้างซ้ายได้ดีกว่ากลีบปอดข้างขวาอย่างชัดเจน เนื่องจากภายในของปอดข้างขวาบ้านี้มีกลีบปอด 3 กลีบ ซึ่งในช่วงของการประมวลของกลีบปอดขวากลาง (RML) จะแทรกตัวระหว่างกลีบปอดขวาบน (RUL) และ กลีบปอดขวาล่าง (RLL) ส่งผลให้ยากต่อการวิเคราะห์ตำแหน่งที่ถูกต้องของแบบจำลอง

ตารางที่ 4.8 ผลการแบ่งแยกกลีบปอดของแบบจำลอง 3D-UNet + DenseNet169 กับชุดข้อมูล Test Set 1 ในแต่ละระดับความรุนแรงของโรค

Severity Type	DSC					
	RUL	RML	RLL	LUL	LLL	Average
No Lesion	86.47%	91.79%	94.45%	90.78%	96.48%	91.99%
Mild	90.51%	88.40%	89.61%	93.24%	92.83%	90.92%
Moderate	93.04%	95.10%	95.27%	93.21%	93.61%	94.05%
Severe	93.75%	94.96%	93.24%	96.20%	94.87%	94.60%



รูปที่ 4.10: ภาพตัวอย่างผลการแบ่งส่วนกลีบปอดของแต่ละแบบจำลองกับภาพต้นฉบับ



รูปที่ 4.11: ภาพตัวอย่างผลการแบ่งส่วนกลีบปอดของแต่ละแบบจำลองกับภาพปรับสีแบบ CLAHE

4.4.3 ผลการทดสอบแบบจำลองสำหรับการแบ่งส่วนรอยโรค

ผลการทดสอบแบบจำลองสำหรับการแบ่งส่วนรอยโรคกับชุดข้อมูล Test Set 1 ซึ่งเป็นชุดข้อมูลที่ผ่านการระบุพื้นที่ในภาพ (Image Annotation) โดยจะแบ่งเป็นการทดสอบกับภาพถ่ายรังสีคอมพิวเตอร์ต้นฉบับ และภาพถ่ายรังสีคอมพิวเตอร์ที่ใช้วิธีปรับสีภาพ CLAHE โดยผลการทดสอบแสดงในตารางที่ 4.9, 4.10 พบว่าแบบจำลองที่ทดสอบกับภาพที่ใช้วิธีปรับสีภาพ CLAHE มีประสิทธิภาพในการแบ่งส่วนรอยโรคมากที่สุดคือแบบจำลอง 3D-UNet ร่วมกับ DenseNet169 โดยมีค่า IoU เท่ากับ 79.61%, DSC เท่ากับ 84.22%, Accuracy เท่ากับ 98.86%, Precision เท่ากับ 86.70%, Sensitivity เท่ากับ 89.07% และ Specificity เท่ากับ 98.91% ซึ่งภาพด้วยวิธีการแบ่งส่วนรอยโรคของแต่ละแบบจำลองที่ทดสอบกับภาพถ่ายรังสีคอมพิวเตอร์แสดงดังรูปที่ 4.11

แบบจำลองที่แสดงในตารางที่ 4.9, 4.10 ได้ผ่านขั้นตอนการคัดเลือกพารามิเตอร์ที่ดีที่สุด ซึ่งໄใช้เปอร์พารามิเตอร์ได้ทำการปรับตามตารางที่ 3.6 โดยผลการปรับได้อธิบายไว้ก่อนหน้านี้ในหัวข้อที่ 4.4.1 ซึ่งผลลัพธ์ดังกล่าวได้ถูกนำมาใช้ในการตั้งค่าแสดงในตารางที่ 3.8 สำหรับการฝึกฝนแบบจำลองแบ่งส่วนรอยโรค

ตารางที่ 4.9 ผลการทดสอบแบบจำลองกับชุดข้อมูล Test Set 1 โดยใช้ภาพต้นฉบับ Raw Image

Model	Backbone	IoU	DSC	Accuracy	Precision	Sensitivity	Specificity
3D-UNet	DenseNet121	72.74%	78.22%	98.73%	78.49%	93.37%	98.75%
3D-UNet	DenseNet169	76.07%	81.23%	98.73%	78.49%	93.37%	98.75%
3D-UNet	DenseNet201	79.35%	84.03%	98.81%	84.52%	92.02%	98.85%
3D-UNet	ResNet18	73.99%	78.49%	98.41%	77.72%	93.52%	98.42%
3D-UNet	ResNet34	72.34%	76.92%	98.57%	75.55%	94.33%	98.56%
3D-UNet	ResNet50	75.89%	80.52%	98.51%	79.13%	94.24%	98.48%
3D-UNet	ResNet101	72.02%	76.29%	98.34%	76.30%	92.87%	98.33%
3D-UNet	ResNet152	67.84%	72.46%	98.62%	71.59%	93.51%	98.64%

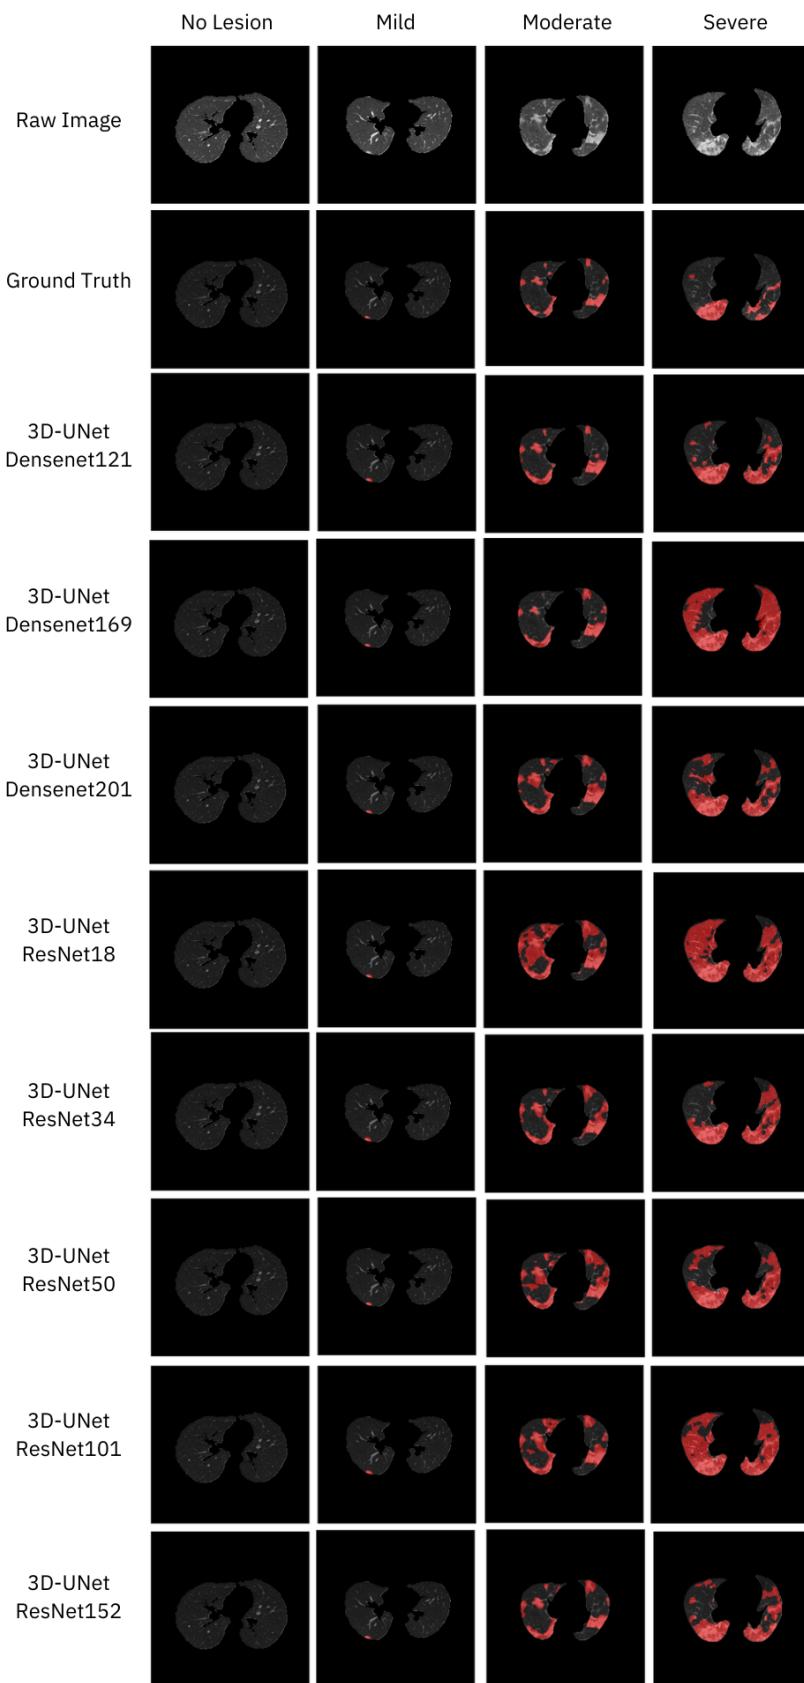
ตารางที่ 4.10 ผลการทดสอบแบบจำลองกับชุดข้อมูล Test Set 1 โดยใช้วิธีปรับสีภาพ CLAHE

Model	Backbone	IoU	DSC	Accuracy	Precision	Sensitivity	Specificity
3D-UNet	DenseNet121	66.72%	71.44%	95.16%	98.86%	86.70%	89.07%
3D-UNet	DenseNet169	79.61%	84.22%	98.86%	86.70%	89.07%	98.91%
3D-UNet	DenseNet201	73.01%	77.75%	98.48%	76.64%	93.91%	98.49%
3D-UNet	ResNet18	64.32%	68.67%	98.08%	67.83%	93.72%	98.05%
3D-UNet	ResNet34	68.63%	73.26%	98.35%	72.06%	94.37%	98.33%
3D-UNet	ResNet50	68.41%	73.24%	98.19%	71.80%	93.91%	98.13%
3D-UNet	ResNet101	78.59%	83.45%	98.95%	85.57%	89.23%	99.05%
3D-UNet	ResNet152	76.57%	81.05%	98.69%	82.61%	90.38%	98.72%

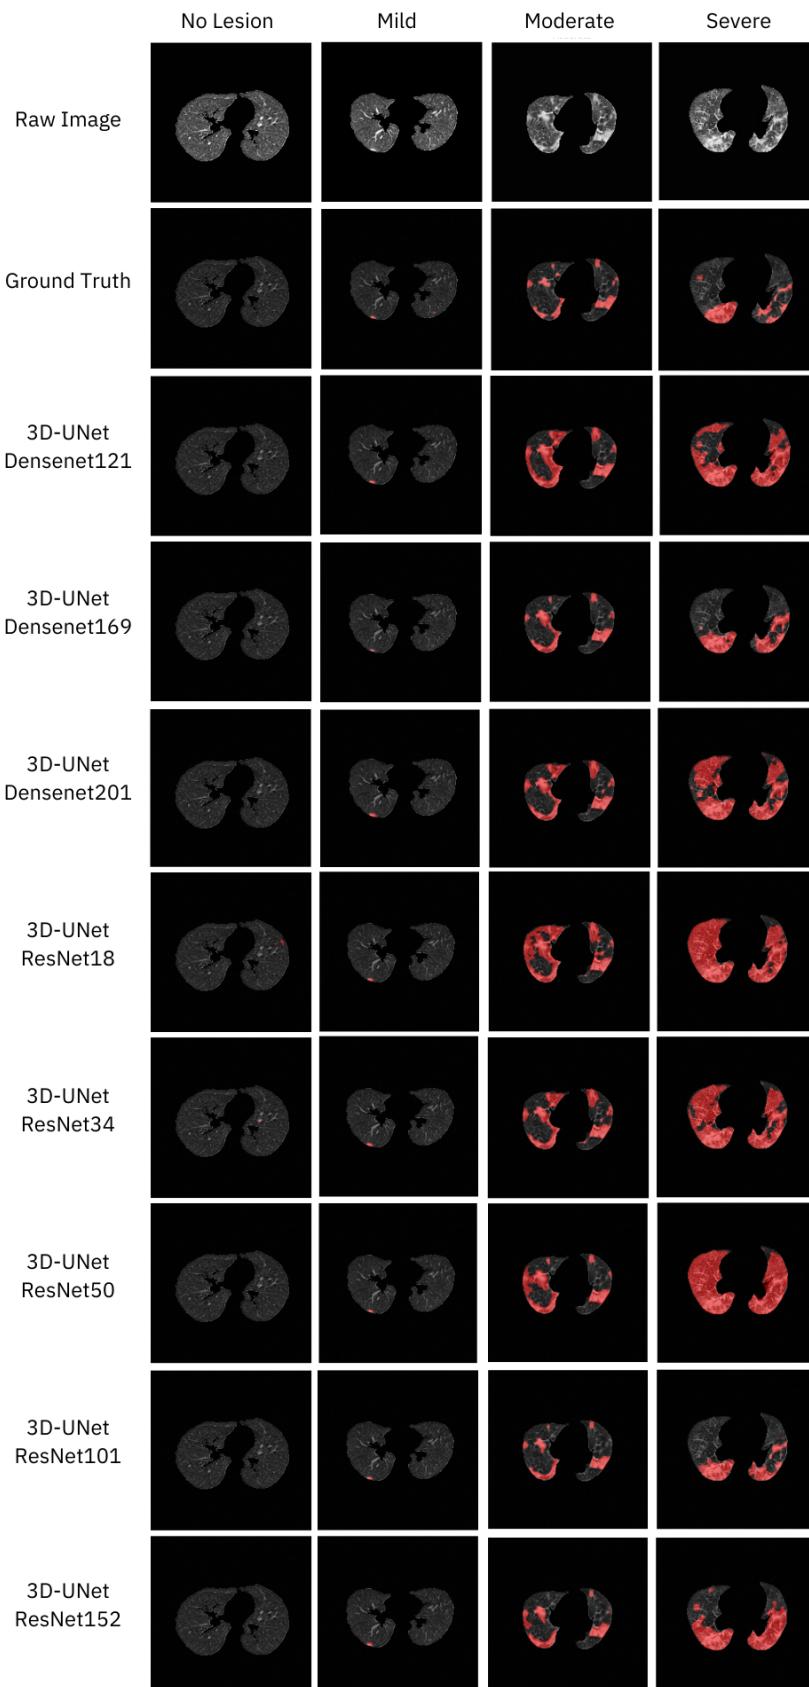
จากผลการทดสอบในตารางที่ 4.9, 4.10 จะพบว่าการใช้ภาพถ่ายรังสีคอมพิวเตอร์ที่ใช้วิธีปรับสีภาพ CLAHE ฝึกฝนแบบจำลองมีแนวโน้มที่จะให้ผลลัพธ์การแบ่งส่วนรอยโรคได้ดีกว่าภาพถ่ายรังสีคอมพิวเตอร์ต้นฉบับที่ไม่ได้ปรับสี และเมื่อนำผลลัพธ์การแบ่งส่วนรอยโรคของแบบจำลอง 3D-UNet + DenseNet169 ซึ่งเป็นแบบจำลองที่สามารถแบ่งส่วนรอยโรคของผู้ป่วยโรคโควิด-19 ได้ดีที่สุดแจกแจงในตารางที่ 4.11 และรูปที่ 4.13 แสดงให้เห็นว่าสามารถระบุรอยโรคได้แม่นยำสำหรับผู้ป่วยโควิด-19 ที่ไม่พบรอยโรค และระดับความรุนแรง Severe ในขณะเดียวกันแบบจำลองค่อนข้างที่จะระบุตำแหน่งได้ผิดพลาดสำหรับผู้ป่วยโควิด-19 ในระดับความรุนแรง Mild และ Moderate ซึ่งจากการศึกษาพบว่าแบบจำลองมักจะระบุรอยโรคเกินกว่าที่ควรจะเป็นดังรูปที่ 4.13 ส่งผลให้ผลลัพธ์การประเมินผลสำหรับผู้ป่วยโควิด-19 ระดับดังกล่าวค่อนข้างแยกกันกลุ่มที่ไม่พบรอยโรค และระดับความรุนแรง Severe ดังตารางที่ 4.11

ตารางที่ 4.11 ผลการทํานายพื้นที่รอยโรคของแบบจำลอง 3D-UNet + DenseNet169 กับชุดข้อมูล Test Set 1 แต่ละระดับความรุนแรงของโรค

Case Type	DSC
No Lesion	100%
Mild	76.61%
Moderate	74.96%
Severe	85.31%



รูปที่ 4.12: ภาพตัวอย่างผลการแบ่งส่วนรอยโรคของแต่ละแบบจำลองกับภาพต้นฉบับ



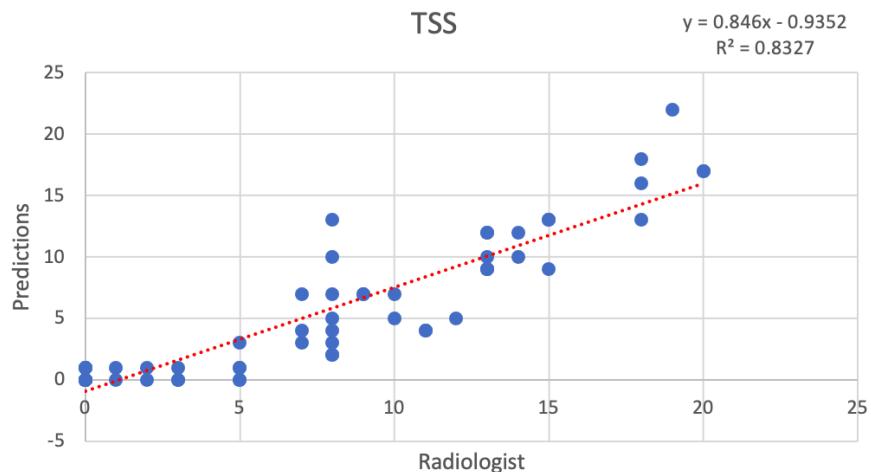
รูปที่ 4.13: ภาพตัวอย่างผลการแบ่งส่วนรอยโรคของแต่ละแบบจำลองกับภาพปรับสีแบบ CLAHE

4.5 ผลการทดสอบการคำนวณค่าระดับความรุนแรง Total Severity Score (TSS)

จากการทดสอบการทำงานโดยรวมของแบบจำลองกับชุดข้อมูลภาพถ่ายรังสีคอมพิวเตอร์ปอดของผู้ป่วยโรคโควิด-19 (Test Set 2) จำนวน 62 ราย แสดงตัวตารางที่ 4.12 และรูปที่ 4.14 พบว่าผลลัพธ์ของการทำงานค่า TSS มีแนวโน้มในทิศทางที่สอดคล้องกับข้อมูลจริงในทิศทางเดียวกัน เห็นได้จากผลลัพธ์ทางสถิติที่สอดคล้องกันระหว่างค่า Correlation of Coefficient เท่ากับ 0.9125 และค่า coefficient R Square เท่ากับ 0.8327

ตารางที่ 4.12 ผลการวิเคราะห์ค่าทางสถิติ (Regression Statistic)

Regression Statistics	
Correlation of Coefficient	0.9125
R Square	0.8327
Adjusted R Square	0.8299
Standard Error	2.5629
Observations	62



รูปที่ 4.14: ภาพแผนภูมิจุดแสดงการกระจายตัวของค่า TSS ระหว่างค่าที่ประเมินโดยรังสีแพทย์ (Radiologist) และค่าที่ได้จากการคำนวณโดยแบบจำลอง (Predictions)

4.6 อภิปรายผล

4.6.1 อภิปรายผลแบบจำลองแบ่งแยกกลุ่บปอด

เมื่อเปรียบเทียบประสิทธิภาพแบบจำลองแบ่งส่วนกลุ่บปอดกับงานวิจัยที่เกี่ยวข้องแสดงในรูปที่ 4.15 พบร่วมกันว่าแบบจำลองในการศึกษาของ Tang et al. มีค่า DSC เท่ากับ 91.48% (LUNA16 Set) และ 94.17% (Tianchi Set) และแบบจำลองในการศึกษาของ Chen et al. มีค่า DSC เท่ากับ 93.35% ซึ่งแบบจำลองของทั้งสองการศึกษานั้นมีประสิทธิภาพในการแบ่งส่วนกลุ่บปอดดีกว่าแบบจำลองของเรามาก อย่างไรก็ตามชุดข้อมูลทดสอบของทั้งสองการศึกษานั้นเป็นชุดข้อมูลภาพถ่ายรังสีคอมพิวเตอร์ปอดที่ไม่มีรอยโรค โดยมีจำนวนชุดข้อมูลสำหรับฝึกฝนแบบจำลองจำนวนคนให้ 40 ราย ขณะที่โครงงานนี้ใช้ชุดข้อมูลฝึกฝนมีจำนวนคนให้ 8 ราย (Train: 6, Validation: 2) ซึ่งเมื่อเปรียบเทียบประสิทธิภาพในการแบ่งส่วนกลุ่บปอดในผู้ป่วยที่ไม่มีรอยโรค แบบจำลองของโครงงานนี้ 3D-UNet + DenseNet169 จะมีค่า DSC เท่ากับ 91.99% แสดงในตารางที่ 4.8 ซึ่งใกล้เคียงกับการศึกษาของ Tang et al. แต่ยังมีประสิทธิภาพน้อยกว่าการศึกษาของ Chen et al. เพียงเล็กน้อย

สำหรับการศึกษาของ Visvanathan et al. ได้ใช้ชุดข้อมูลภาพถ่ายรังสีคอมพิวเตอร์ปอดที่ประกอบด้วยภาพที่มีรอยโรคและไม่มีรอยโรค โดยพบว่าแบบจำลองมีประสิทธิภาพในการแบ่งส่วนกลุ่บปอดที่ค่า DSC เท่ากับ 85.68% ซึ่งเมื่อเทียบกับประสิทธิภาพแบบ

จำลองของโครงงานนี้ แบบจำลองสามารถแบ่งส่วนกลีบปอดในภาพมีร้อยโรคและไม่มีร้อยโรคค่า DSC เท่ากับ 92.89% แสดงให้เห็นว่า แบบจำลองมีประสิทธิภาพที่เพียงพอสำหรับการแบ่งส่วนกลีบปอดของผู้ป่วยโรคโควิด-19

Lung Lobe Segmentation Model

งานวิจัย	Data Volume	Preprocessing	Model	Backbone	DSC
Tang et al. 2019	Training LUNA16 Set: 40 CT Scans Testing LUNA16 Set: 10 CT Scans Tianchi Set: 10 CT Scans	ใช้ภาพ Axial, Coronal, Sagittal view ปรับสีภาพ CT Scan ให้เข้ากับ Hounsfield Unit อยู่ในช่วง [-1000,600] จากนั้นทำการ CT Image Binarize โดยใช้ OTSU Method, Dilation (5x5 kernel) และรอบพื้นที่ปอด โดยใช้ลักษณะร่องรอย Convex hull	V-Net	-	LUNA16 Test Set 91.48%
					Tianchi Test Set 94.17%
Chen et al. 2020	Training LUNA16 Set: 40 CT Scans Testing LUNA16 Set: 10 CT Scans	ปรับสีภาพ CT Scan ให้เข้ากับ Hounsfield Unit อยู่ในช่วง [-1000,600] จากนั้นทำการ normalize ให้อยู่ในช่วง [0,1] และใช้วิธีการ global position reservation, fissure-aware strategy	LobeNet (3D-UNet)	-	93.35%
Visvanathan et al. 2021	ชุด 1: ภาพ Lung CT จำนวน 50 ชุด ชุด 2: ผู้ป่วย 150 ราย (750 ภาพ) ชุด 3: ผู้ป่วย 9 ราย (829 ภาพ) ชุด 4: ผู้ป่วย 50 ราย (200 ภาพ) ชุด 5: ภาพ Lung CT จำนวน 8 ชุด	นำภาพถ่ายรังสีชนิดภาพตัดขวาง (2D Axial) มาปรับให้มีช่วงสี Hounsfield Unit (HU) อยู่ในช่วง [-1000,1000] ผู้ใช้ทำการ Normalize ให้อยู่ในช่วง [0,1] จากนั้นปรับความละเอียดของภาพให้มีขนาดเท่ากับ 512 x 512 พิกเซล	CNN	-	85.68%
Our	Training/val: 32 cases Testing: 8 cases	ใช้ภาพ Axial view โดยปอดมีระดับความรุนแรงของร้อยโรคโควิด-19 ระดับคือ normal, mild, moderate, severe จากนั้นนำภาพ CT scan มาบีบขนาด 512x512 พิกเซล ลงเหลือ 256x256 พิกเซล และฝึกแบบจำลองแบบ 3D โดยใช้ input shape คือ 128x256x256	3D-UNet	DenseNet 169	92.89%

รูปที่ 4.15: ตารางเปรียบเทียบประสิทธิภาพแบบจำลองแบ่งส่วนกลีบปอดของโครงงานนี้กับงานวิจัยที่เกี่ยวข้อง

4.6.2 อภิปรายผลแบบจำลองทำนายพื้นที่ร้อยโรค

เมื่อเปรียบเทียบประสิทธิภาพแบบจำลองแบ่งส่วนร้อยโรคของคณะผู้จัดทำกับงานวิจัยที่เกี่ยวข้องแสดงในรูปที่ 4.16 พบร้าในการศึกษาของ Xiao et al. มีค่า DSC เท่ากับ 95.30% (3D-Res2UNet) ซึ่งงานวิจัยดังกล่าวได้มีส่วนหนึ่งที่ใช้แบบจำลองเดียวกันคือ 3D-UNet มีค่า DSC เท่ากับ 89.12% และการศึกษาแบบจำลองในการศึกษาของ Qiblawey et al. มีค่า DSC เท่ากับ 94.13% (FPN + DenseNet201) จากผลลัพธ์จะเห็นได้ว่าทั้งสองงานวิจัยมีผลลัพธ์การแบ่งส่วนร้อยโรคได้ดีกว่าแบบจำลองของคณะผู้จัดทำ ซึ่งสาเหตุแรกสืบเนื่องมาจากจำนวนข้อมูลที่ใช้ในการฝึกฝนมีจำนวนต่างกันจำนวนมาก ยกตัวอย่างเช่นงานวิจัยของ Qiblawey et al. ได้มีการทำ Augmentation ข้อมูลอีกกว่า 11,820 ภาพ รวมข้อมูลทั้งสิ้นเป็น 15,698 ภาพที่ใช้สำหรับขั้นตอนการฝึกฝนแบบจำลอง ในขณะที่แบบจำลองของคณะผู้จัดทำใช้ข้อมูลเพียง 3,752 ภาพเท่านั้น สาเหตุที่สองคือความแตกต่างของข้อมูลที่ใช้ในการวิเคราะห์ผลลัพธ์ ในสองงานวิจัยข้างต้นไม่ได้ระบุรายละเอียดของข้อมูลอย่างชัดเจนว่าชุดข้อมูลดังกล่าวมีการแบ่งประเภทของความรุนแรงอย่างเท่าๆ กัน ในขณะที่แบบจำลองของคณะผู้จัดทำมีการประมวลผลด้วยข้อมูลจากระดับความรุนแรงของโรคเท่ากันๆ กันเว้น Testset 2 ที่มีระดับความรุนแรงของโรคประเภท Moderate เเย่องกว่าปกติและ Severe น้อยกว่าปกติเมื่อเทียบกับจำนวนข้อมูลในกลุ่มที่ไม่มีร้อยโรค และกลุ่มที่มีร้อยโรค ความรุนแรง Mild ที่เท่ากัน ซึ่งผลลัพธ์จากการวิเคราะห์แบบจำลองร่วมกันกับงานวิจัยที่ได้ทำการศึกษาให้แนวโน้มในข้อคิดเห็นที่เหมือนกันว่า แบบจำลองสามารถแบ่งส่วนร้อยโรคผู้ป่วยโควิด-19 ในกลุ่มที่ไม่มีร้อยโรค และผู้ป่วยที่มีร้อยโรค Severe ได้อย่างแม่นยำ ในขณะที่การแบ่งส่วนร้อยโรคผู้ป่วยโควิด-19 ระดับ Mild และ Moderate จะมีความผิดพลาดเยอะกว่า แต่อย่างไรก็ตามความคลาดเคลื่อนของการทำนายจะไม่ผิดพลาดน้อยกว่าหรือมากกว่าระดับความรุนแรงนั้น ๆ 1 ระดับ

Lesion Segmentation Model

งานวิจัย	Data Volume	Preprocessing	Model	Backbone	DSC
Xiao et al. 2020	888 ชุด โดยมีร้อยละรวม 1186 ของโอด (Training: 70%, Testing: 20%, Verification: 10%)	แปลงภาพเป็นข้อมูลค่าแท่งของภาพโดยให้ ออยูเมตตาเพรชอง (Voxelcoord, Voxelidiam) จากนั้นใช้ AugGAN Network เพื่อแก้ไขปัญหา Class Imbalance และ ท่าการ Normalization	3D-Res2UNet	-	95.30%
Qiblawey et al. 2021	Training 3 ชุด ชุด 1: ผู้ป่วย 20 ราย (3,520 ภาพ) ชุด 2: ผู้ป่วย 9 ราย (829 ภาพ) ชุด 3: คนปกติ 267 ภาพ Testing 46,411 ภาพ ผู้ป่วย 856 ราย คนปกติ 254 ราย	ไม่ได้มีการปรับรับค่า Hounsfield Unit เนื่องจาก ชุดข้อมูลเป็นไฟล์ NIfTi Format งานนี้จึงใช้ แบล็อกเรนเดอร์นิ่ง Format เป็นไฟล์ PNG ขนาด 256 x 256 พิกเซล จากนั้นปรับสีภาพให้ ออยูเมตตา 0-255 และท่าการเพิ่มความหลากหลายของภาพ (Augmentation)	FPN	DenseNet 201	94.13%
Our	Training/val: 32 cases Testing: 8 cases	ใช้ภาพ Axial view โดยป้องกันเรื่องดับความ รุนแรงของรอยโรคไว้ด้วย 4 ระดับคือ normal, mild, moderate, severe จากนั้นนำภาพ CT scan มาปรับขนาดจาก 512x512 พิกเซล ลงเหลือ 256x256 พิกเซล และฝึกฝนแบบเครื่องเรียน 3D โดยใช้ input shape คือ 128x256x256 และนำไปปรับภาพ ด้วยวิธีการ CLAHE	3D-UNet	DenseNet 169	84.22%

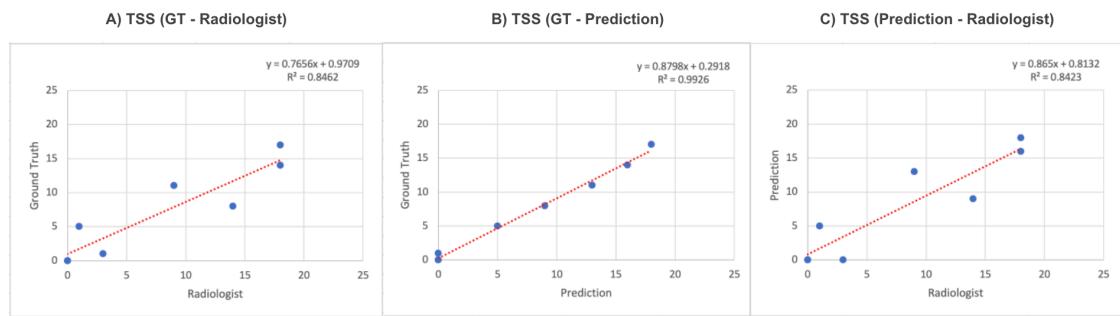
รูปที่ 4.16: ตารางเปรียบเทียบประสิทธิภาพแบบจำลองแบ่งส่วนรอยโรคของโครงงานนี้กับงานวิจัยที่เกี่ยวข้อง

4.6.3 อภิปรายผลการคำนวณค่าระดับความรุนแรง Total Severity Score (TSS)

เมื่อนำชุดข้อมูล Test Set 1 ซึ่งเป็นชุดข้อมูลภาพถ่ายรังสีคอมพิวเตอร์ปอดที่ได้รับการระบุพื้นที่กลับปอดและรอยโรค โดยชุดข้อมูลนี้ได้ผ่านการตรวจสอบโดยรังสีแพทย์เรียบร้อยแล้ว คณิตศาสตร์จัดทำจึงนำมาใช้เป็น Ground Truth (GT) สำหรับการคำนวณค่า TSS โดยรังสีแพทย์แนะนำให้ทำการเรียงลำดับค่า TSS ของห้อง 3 วิธีคือ TSS (Radiologist) คือค่า TSS ที่ได้จากการวินิจฉัยโดยรังสีแพทย์ TSS (GT) คือค่า TSS ที่ได้จากการคำนวณ Ground Truth มาใช้ในการคำนวณและ TSS (Prediction) คือค่า TSS ที่ได้จากการคำนวณผลลัพธ์จากการทำนายโดยแบบจำลองมาใช้ในการคำนวณ โดยผลการวิเคราะห์แสดงในตารางที่ 4.13 และรูปที่ 4.17 พบว่าค่า TSS (Prediction) ที่ได้จากการคำนวณจากผลลัพธ์ที่แบบจำลองทำงานนั้นมีความสัมพันธ์บวกค่า TSS (GT) โดยมีค่า R Square เท่ากับ 0.9926 ขณะที่เมื่อเทียบระหว่างค่า TSS (GT) และ TSS (Radiologist) มีค่า R Square เท่ากับ 0.8462 แสดงให้เห็นว่าแบบจำลองนั้นมีความแม่นยำกว่าการสังเกตด้วยตาเปล่าเมื่อเทียบกับค่า TSS (GT)

ตารางที่ 4.13 ผลการวิเคราะห์ค่าทางสถิติ (Regression Statistic) ของค่า TSS ของทั้ง 3 วิธี

Regression Statistics	GT - Radiologist	GT - Prediction	Prediction - Radiologist
Correlation of Coefficient	0.9199	0.9963	0.9177
R Square	0.8462	0.9926	0.8423
Adjusted R Square	0.8205	0.9914	0.8160
Standard Error	2.7917	0.6109	3.3968
Observations	8	8	8

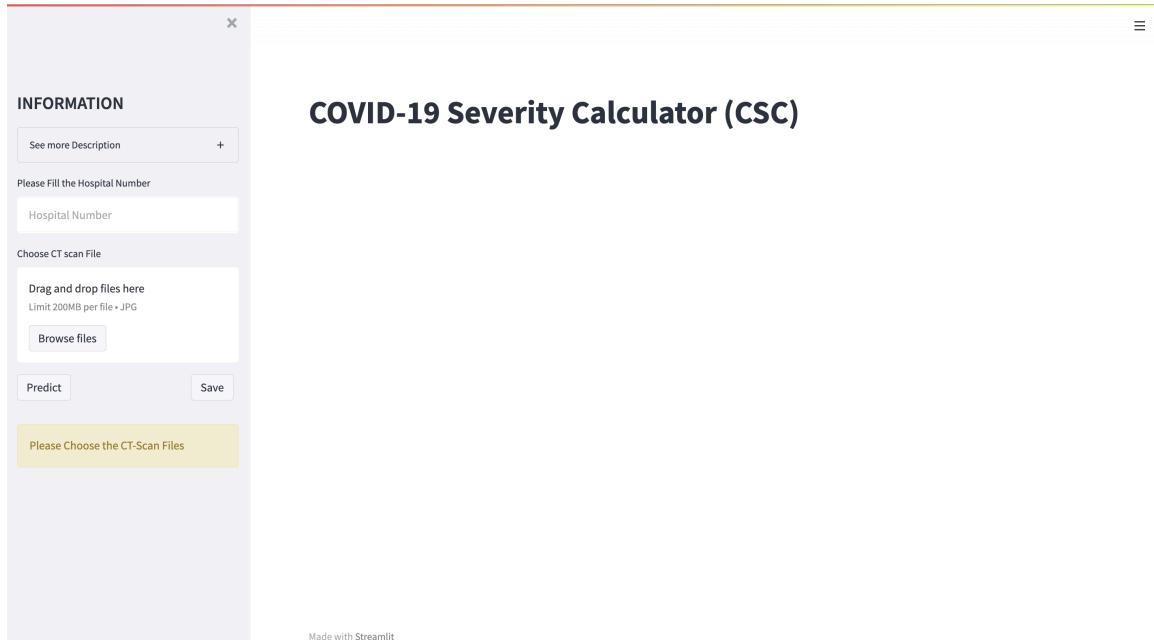


รูปที่ 4.17: ภาพแผนภูมิจุดแสดงการกระจายตัวของค่า TSS (A) คือค่า TSS (GT) เทียบกับค่า TSS (Radiologist), (B) คือค่า TSS (GT) เทียบกับ TSS (Prediction) และ (C) คือค่า TSS (Prediction) เทียบกับ TSS (Radiologist)

4.7 หน้าต่างผู้ใช้งาน

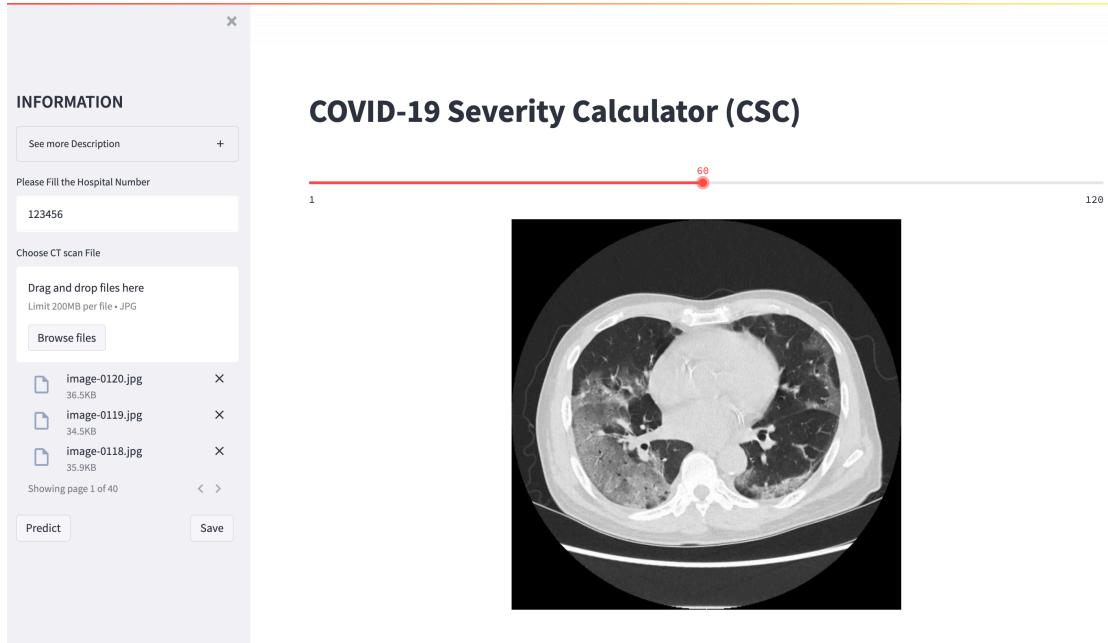
ทางคณะผู้ดัดทำได้ใช้ Streamlit ในสร้างหน้าต่างผู้ใช้งานโดยนำแบบจำลองสำหรับการแบ่งแยกกลีบปอดและแบบจำลองสำหรับการทำนายพื้นที่รอยโรคที่ติดสุ่มรวมประมวลผล และนำเสนอผลลัพธ์อุปกรณ์ทางหน้าต่างผู้ใช้งานเพื่อให้ผู้ใช้งานสามารถเข้าถึงเข้าถึงระบบได้อย่างง่ายดาย

หน้าต่างผู้ใช้งานนี้สามารถทำนายระดับความรุนแรงของผู้ป่วยในยืนโนโวติด-19 ว่าอยู่ในระดับ Mild, Moderate หรือ Severe



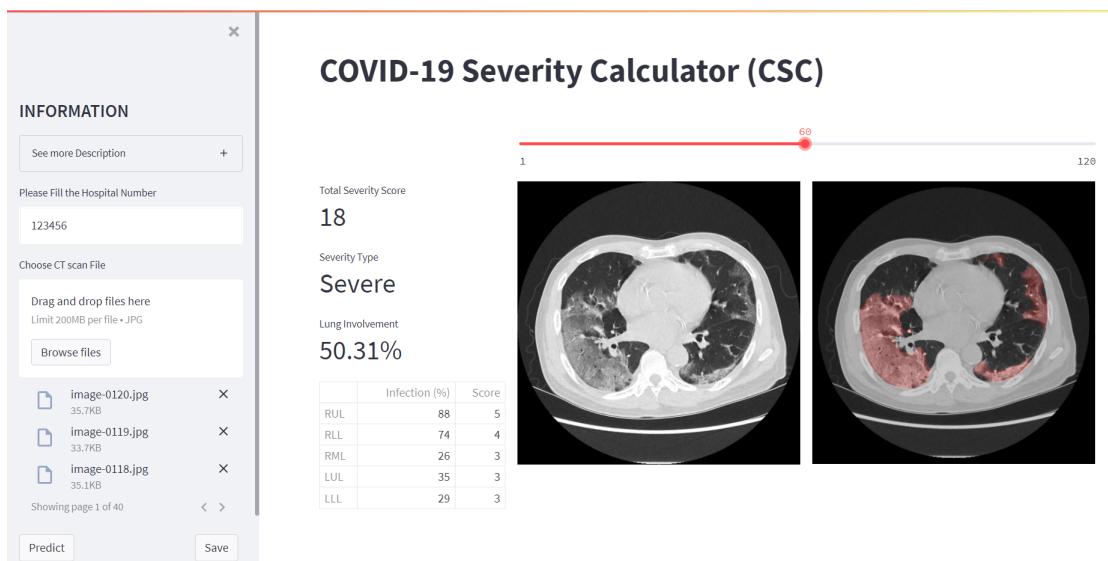
รูปที่ 4.18: หน้าต่างผู้ใช้งาน

โดยหน้าต่างผู้ใช้งานแบ่งออกเป็น 2 ส่วนดังรูปที่ 4.18 คือ ส่วนด้านซ้าย (Side Bar) เป็นส่วนสำหรับนำเข้าข้อมูล ซึ่งสามารถนำเข้าข้อมูลได้ 2 ช่องคือ หมายเลขประจำตัวผู้ป่วย (Hospital Number: HN) และชุดภาพถ่ายรังสีคอมพิวเตอร์ปอดผู้ป่วยโควิด-19 (Lung CT-scans) ด้วยสกุลไฟล์ JPG และส่วนด้านขวา (Page) เป็นส่วนสำหรับนำเสนอบล็อกที่ตั้งก่อนการวินิเคราะห์ และหลังการวินิเคราะห์ ดังรูปที่ 4.19



รูปที่ 4.19: หน้าต่างผู้ใช้งานขณะนำข้อมูลเข้า

เมื่อชุดภาพที่นำเข้าได้ถูกการประมวลผลจากแบบจำลองหั้งสองแล้วหน้าต่างผู้ใช้งานจะนำเสนอผลการคำนวณว่าชุดภาพของผู้ป่วยโรคโควิด-19 อยู่ในความรุนแรงระดับ Mild, Moderate หรือ Severe และหน้าต่างผู้ใช้งานจะแสดงค่าระดับความรุนแรง TSS ของชุดภาพถ่ายสีคอมพิวเตอร์ และแสดงค่าเบอร์เรื่องราวติดเชื้อทั้งปอด (Lung Involvement) พร้อมตารางค่า PI กับค่า CT Score ของแต่ละกลีบปอด รวมถึงหน้าต่างผู้ใช้งานยังแสดงภาพที่บ่งบอกตำแหน่งของรอยโรคที่ทำนายได้จากชุดภาพถ่ายสีคอมพิวเตอร์ของผู้ป่วยที่ร่วงสีแพทเทอร์อ็อกโหลดเข้าไปในหน้าต่างผู้ใช้งานดังรูปที่ 4.20



รูปที่ 4.20: หน้าต่างผู้ใช้งานแสดงผลการวิเคราะห์ชุดภาพ CT Scans

ทั้งนี้หน้าต่างผู้ใช้งานสามารถเลือกดาวน์โหลด (Download) รายงานผลการคำนวณของผู้ป่วยโควิด-19 ในรูปแบบไฟล์ Portable Document Format (PDF) ดังรูปที่ 4.21 หรือไฟล์ Comma-Separated Value (CSV) ดังรูปที่ 4.22 ที่สามารถเปิดในโปรแกรม Microsoft Excel ได้ดังรูปที่ 4.23

COVID-19 Patient's Information

Date: May-16-2022 Time:16.31.07

Hospital Number (HN): 123456

Total Severity Type (TSS): 18

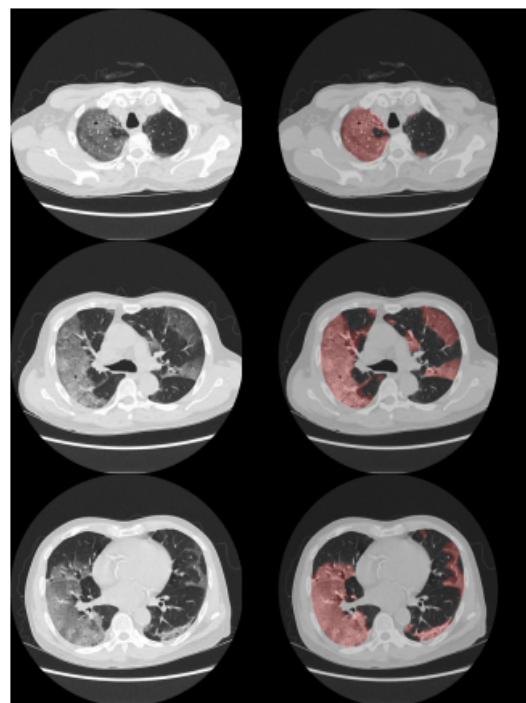
Severity Type: Severe

Lung Involvement: 50.31%

Percentage of Infection Table

Lobe	Percentage of Infection	Score
Right Upper Lobe (RUL)	88	5
Right Lower Lobe (RLL)	74	4
Right Middle Lobe (RML)	26	3
Left Upper Lobe (LUL)	35	3
Left Lower Lobe (LLL)	29	3

Example Lung Image



รูปที่ 4.21: ตัวอย่างรูปแบบไฟล์ PDF ของผู้ป่วยโควิด-19

,Right Upper Lobe (RUL),Right Lower Lobe (RLL),Right Middle Lobe (RML),Left Upper Lobe (LUL),Left Lower Lobe (LLL)
 Percent Infection (PI%),88,74,26,35,29
 Score,5,4,3,3,3

รูปที่ 4.22: ตัวอย่างรูปแบบไฟล์ CSV

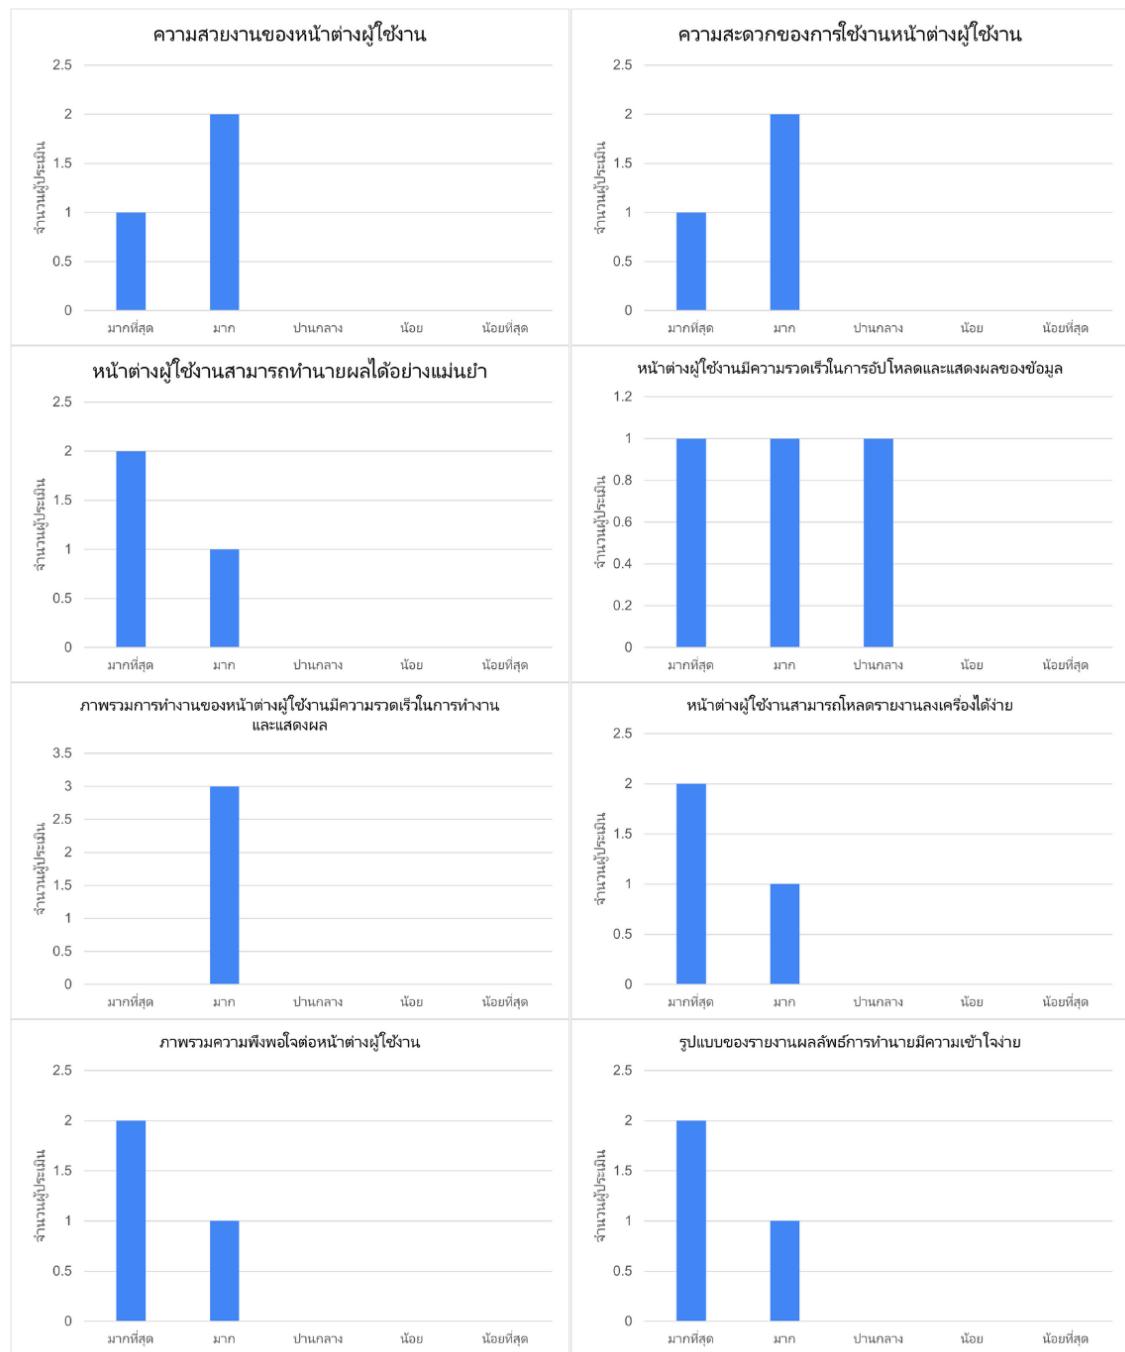
	Right Upper Lobe (RUL)	Right Lower Lobe (RLL)	Right Middle Lobe (RML)	Left Upper Lobe (LUL)	Left Lower Lobe (LLL)
Percent In	0	0	0	0	2
Score	0	0	0	0	1

รูปที่ 4.23: ตัวอย่างรูปแบบไฟล์ CSV ที่เปิดใน Microsoft Excel

คณะผู้จัดทำได้อัปโหลดไฟล์ Source Code ของโครงการนี้ใน Github สามารถเข้าถึงได้ที่ (<https://github.com/hds-69/csc-app>) โดยไฟล์ข้อมูลประกอบไปด้วยไฟล์หน้าต่างผู้ใช้งาน ซึ่งจะเป็นไฟล์ประเภท Python (app.py, function.py) ไฟล์ไลบรารี (Library) ที่จำเป็นต้องติดตั้งก่อนการใช้งาน (requirements.txt, packages.txt) และไฟล์แบบจำลองทั้ง 2 แบบจำลอง เป็นไฟล์ประเภท HDF5 (Lung_Model5.h5, Lesion_Model143.h5) โดยไฟล์แบบจำลองจะถูกอัปโหลดโดย Git LFS ซึ่งจะช่วยให้สามารถอัปโหลดไฟล์ ที่มีขนาดเกิน 100 Mb ขึ้น Git Repository ได้

4.8 ผลการประเมินหน้าต่างผู้ใช้งาน

คณะผู้จัดทำได้ให้บุคลากรนักทางการแพทย์จำนวน 3 คน ซึ่งประกอบไปด้วยรังสีแพทย์ 2 คน และอาจารย์ Medical Imaging Engineering Lecturer ในการทดลองใช้ และประเมินความพึงพอใจของหน้าต่างผู้ใช้งาน รวมถึงรวบรวมข้อมูลเสนอแนะสำหรับการพัฒนาหน้าต่างผู้ใช้งาน โดยผลการประเมินความพึงพอใจหน้าต่างผู้ใช้งานแสดงในรูปที่ 4.24 สามารถสรุปผลได้ว่าหน้าต่างผู้ใช้งานมีความพึงพอใจหน้าต่างผู้ใช้งานในระดับมาก ถึงมากที่สุด ทั้งความสวยงาม ความสะดวกในการใช้งาน ความสามารถของหน้าต่างผู้ใช้งาน และภาพรวมของหน้าต่างผู้ใช้งาน



รูปที่ 4.24: ผลการประเมินหน้าต่างผู้ใช้งานในด้านต่าง ๆ

บทที่ 5 สรุปผลการดำเนินงาน

5.1 สรุปการดำเนินงาน

โครงการนี้ได้ใช้เทคโนโลยีการเรียนรู้เชิงลึก (Deep learning) โดยใช้แบบจำลอง 3D-UNet ร่วมกับแบบจำลองที่ผ่านการฝึกฝนแล้วอย่าง DenseNet โดยใช้ชุดข้อมูลภาพถ่ายรังสีคอมพิวเตอร์ปอดของคนไข้โรคโควิด-19 จำนวน 24 ราย สำหรับการฝึกฝนแบบจำลองชุดข้อมูลสำหรับปรับพารามิเตอร์จำนวน 8 ราย และชุดข้อมูลที่ทดสอบแบบจำลองจำนวน 8 ราย ผลศึกษาพบว่าแบบจำลองที่ดีที่สุดสำหรับการแบ่งส่วนกลีบปอดคือแบบจำลอง 3D-UNet ร่วมกับ DenseNet169 โดยมีค่า Dice Similarity Coefficient (DSC) 92.89% และผลการทดลองที่ดีที่สุดสำหรับแบบจำลองแบ่งส่วนรอยโรคพบว่าได้ค่า DSC 86.35% โดยใช้แบบจำลอง 3D-UNet ร่วมกับ DenseNet169 โดยแบบจำลองที่นำเสนอนำมาสามารถแบ่งส่วนกลีบปอดได้อย่างแม่นยำในขณะที่แบบจำลองแบ่งส่วนรอยโรคยังมีความผิดพลาดอยู่ โดยเฉพาะรอยโรคในกลุ่มผู้ป่วยที่มีระดับความรุนแรงประเพณี Mild และ Moderate เมื่อนำแบบจำลองมาประยุกต์ใช้ในการแบ่งส่วนกลีบปอด และแบ่งส่วนรอยโรค โดยใช้ชุดข้อมูลภาพถ่ายรังสีคอมพิวเตอร์ของผู้ป่วยจำนวน 62 ราย และนำผลลัพธ์ที่ได้จากแบบจำลองมาคำนวณค่าระดับความรุนแรงของผู้ป่วยโควิด-19 Total Severity Score (TSS) เพรียบเทียบค่า TSS ที่ได้จากการวินิจฉัยโดยรังสีแพทย์พบว่ามีความสัมพันธ์กันที่ค่าสัมประสิทธิ์สหสัมพันธ์ (Correlation of Coefficient; r) เท่ากับ 0.9125 และ R Square เท่ากับ 0.8327

5.2 ปัญหาที่พบและการแก้ไข

5.2.1 การเตรียมข้อมูล (Data Preparation)

การเตรียมภาพถ่ายรังสีคอมพิวเตอร์ปอดที่ผ่านการระบุรายละเอียดใช้ระยะเวลามากเกินกว่าที่กำหนดไว้ ทำให้ต้องขยายระยะเวลาในการเตรียมข้อมูลมากขึ้น และเนื่องจากสถานการณ์ปัจจุบัน ประเทศไทยเริ่มได้รับการฉีดวัคซีนอย่างทั่วถึงมากขึ้นส่งผลให้ระดับความรุนแรงของโรคลดน้อยลง ข้อมูลผู้ป่วยโควิด-19 ประเภท Severe ใน Test Set 2 จึงมีจำนวนน้อย ทางคณะผู้จัดทำจึงนำข้อมูลผู้ป่วยโควิด-19 ประเภท Severe จาก Test Set 1 บางส่วนมาวิเคราะห์ในส่วน Test Set 2 ด้วย

5.2.2 การฝึกฝนแบบจำลอง (Model Training)

เนื่องจากโครงการนี้ใช้เทคนิคการแบ่งส่วนภาพ (Semantic Segmentation) เพื่อแบ่งส่วนกลีบปอดและรอยโรคในภาพถ่ายรังสีคอมพิวเตอร์ปอดของผู้ป่วยโควิด-19 โดยจำเป็นต้องใช้ทรัพยากรสำหรับการฝึกฝนแบบจำลองจำนวนมาก ซึ่งการใช้ Google colab นั้นไม่เพียงพอค่อนข้างจะทำจึงแก้ปัญหาโดยการเปลี่ยนมาใช้ Server ของภาควิชานการฝึกฝนแบบจำลองแทน

แบบจำลอง 3D-UNet มีข้อจำกัดในการรับข้อมูลเป็นรูปแบบสามมิติ ซึ่งจำนวนภาพโดยรวมของผู้ป่วยแต่ละคนมีความแตกต่างกัน ทำให้คณะผู้จัดทำจำเป็นต้องกำหนดจำนวนภาพถ่ายรังสีคอมพิวเตอร์ที่รับได้ต่อการทำนาย 1 รอบ คือจำนวน 128 ภาพ ซึ่งปัญหาดังกล่าวได้รับการแก้ไขโดยการปรับเพิ่มค่าจำนวนภาพตั้งแต่ 3.4.1 ทำให้สามารถรับจำนวนภาพสูงสุดได้ที่ 256 ภาพต่อคนที่ 1 ราย

5.2.3 หน้าต่างผู้ใช้งาน (User Interface)

ในการสร้างหน้าต่างผู้ใช้งานทางคณะผู้จัดทำได้ใช้เครื่องที่ชื่อว่า Streamlit โดยในโครงการนี้ทางคณะผู้จัดทำพบเจอบัญชาหลักคือ การวาง Layout โครงสร้าง Streamlit จะวางตำแหน่งต่อ กันในแนวดัง ซึ่งถ้าต้องการวาง Layout ในแนวนอนต้องทำการแบ่งพื้นที่ออกเป็นจำนวน Columns ทำให้รูปแบบโครงสร้างของหน้าต่างผู้ใช้งานมีความจำกัดในการออกแบบ และการวาง Layout ทำให้การออกแบบโครงสร้างหน้าต่างผู้ใช้งานในตอนแรกมีความซับซ้อน ส่งผลให้ผู้ใช้งานไม่สามารถเข้าใจการทำงานได้โดยง่าย ทางคณะผู้จัดทำจึงออกแบบหน้าต่างผู้ใช้งานในรูปแบบใหม่เพื่อตอบสนองความต้องการของผู้ใช้งาน และนอกจากนั้นหน้าต่างผู้ใช้งานได้นำแบบจำลองทั้ง 2 แบบจำลองมาร่วมประมวลผลในการทำงานผลทำให้เวลาในการทำงานลดลงหน้าต่างผู้ใช้งานใช้ระยะเวลานาน ทางคณะผู้จัดทำจึงลดระยะเวลาด้วยการใช้เครื่องมือที่ชื่อว่า Numba Library ซึ่งจะนำ GPU ของเครื่องมาช่วยในการประมวลผล

5.3 แนวทางการพัฒนา

5.3.1 ชุดข้อมูล

โครงการศึกษาครั้งนี้คัดทำมีชุดข้อมูลทั้ง 3 ชุด คือ Training Set มีจำนวนภาพ 3,752 ภาพ, Test Set 1 มีจำนวนภาพ 1,314 ภาพ และ Test Set 2 มีจำนวนภาพ 7,686 ภาพ ซึ่งในแต่ละชุดข้อมูลจะแบ่งออกเป็นกลุ่มที่ไม่พบรอยโรคและกลุ่มที่มีรีดับความรุนแรง Mild, Moderate และ Severe ทำให้คัดทำอย่างเพิ่มจำนวนภาพที่ใช้ในการฝึกฝนแบบจำลองเพิ่มมากขึ้น ไม่ว่าจะเป็นภาพที่ได้จากโรงพยาบาลแห่งอื่น หรือแหล่งข้อมูลที่เปิดเป็นสาธารณะต่าง ๆ เพื่อเพิ่มประสิทธิภาพในการฝึกฝนของแบบจำลอง

5.3.2 แนวทางการพัฒนาแบบจำลอง

คณะผู้จัดทำมีแนวคิดที่จะขยายขนาดของภาพจาก 256×256 พิกเซล เป็น 512×512 พิกเซล โดยการขยายขนาดของข้อมูลคาดว่าจะสามารถแก้ไขปัญหาความผิดพลาดในการแบ่งส่วนรอยโรคขนาดเล็กได้ รวมถึงขั้นตอนการเพิ่มจำนวนของข้อมูลด้วยการทำหักข้อมูลเพิ่มดังความเห็นในข้อที่ 5.3.1 และวิธีการ Augmentation ซึ่งข้อมูลที่เพิ่มขึ้นส่งผลให้ใช้ทรัพยากรคอมพิวเตอร์ที่มากขึ้นเช่นกัน ดังนั้นถ้าหากมีข้อจำกัดดังกล่าวส่งผลให้ไม่สามารถใช้แบบจำลองรูปแบบ 3D-UNet ได้ ทางคณะผู้จัดทำมีความคิดเห็นว่าควรใช้แบบจำลองที่ให้ประสิทธิภาพรองลงมาอย่าง UNet เพื่อเพิ่มความสามารถในการฝึกฝนกับจำนวนข้อมูลที่มากขึ้น และในส่วนของแบบจำลองแบ่งส่วนกลีบปอดคณะผู้จัดทำมีแนวคิดที่จะเพิ่มส่วนการเรียนรู้ร้อยแยกของกลีบปอด (Fissure) เพื่อให้แบบจำลองแบ่งส่วนกลีบปอดได้แม่นยำยิ่งขึ้น

5.3.3 แนวทางการพัฒนาหน้าต่างผู้ใช้งาน

โครงการศึกษาครั้งนี้คัดทำได้ใช้ Streamlit ในการสร้างหน้าต่างผู้ใช้งานเพียงเครื่องมือเดียว ทำให้การออกแบบ และคุณสมบัติ (Feature) หน้าต่างผู้ใช้งานมีข้อจำกัด คณะผู้จัดทำอย่างเสนอให้เลือกใช้เครื่องมือสำหรับการสร้างหน้าต่างผู้ใช้งานอื่น ๆ เช่นมาร์ต์เพื่อเพิ่มความยืดหยุ่นในการออกแบบ และการสร้าง Feature ต่าง ๆ ดังนี้

- การแสดงผลตามหน้าจอในรูปแบบ 3 มิติ ทั้งในหน้าต่างผู้ใช้งานและรายงาน
- หน้าต่างผู้ใช้งานที่สามารถเลือกภาษาที่สามารถแสดงได้ตามความต้องการของผู้ใช้งาน
- หน้าต่างผู้ใช้งานมีการเชื่อมฐานข้อมูล
- หน้าต่างผู้ใช้งานสามารถบันทึกผลการทำงาน และเลือกดูผลการทำงานในฐานข้อมูล
- หน้าต่างผู้ใช้งานสามารถเชื่อมเข้าระบบ Picture Archiving and Communication System (PACS) ที่เป็นระบบกลางในการจัดการรับส่งข้อมูลภาพทางการแพทย์
- หน้าต่างผู้ใช้งานสามารถรับการอัปโหลดชุดภาพทั้ง 3 แกน แกนตัดขวาง (Axial) แกนแบ่งซ้าย-ขวา (Coronal) และแกนแบ่งหน้า-หลัง (Sagittal)
- หน้าต่างผู้ใช้งานสามารถบอชันดิของรอยโรคได้ รวมถึงทำลายร่องรอยโรค

แนวทางการพัฒนาเพื่อเพิ่มความเร็วในการทำงานของแบบจำลองที่คณะผู้จัดทำเล็งเห็นว่าสามารถทำได้คือการอัปโหลดแบบจำลองขึ้นระบบคลาวด์ (Cloud) ซึ่งสามารถเลือกเครื่องที่มี GPU ซึ่งจะช่วยให้แบบจำลองทำงานอย่างผลลัพธ์ได้รวดเร็วยิ่งขึ้น อีกทั้งเมื่ออัปโหลดหน้าต่างผู้ใช้งานขึ้นระบบคลาวด์ จะสามารถช่วยเพิ่มความสะดวกในเข้าถึงและใช้งานของรังสีแพทย์ได้มากยิ่งขึ้น

หนังสืออ้างอิง

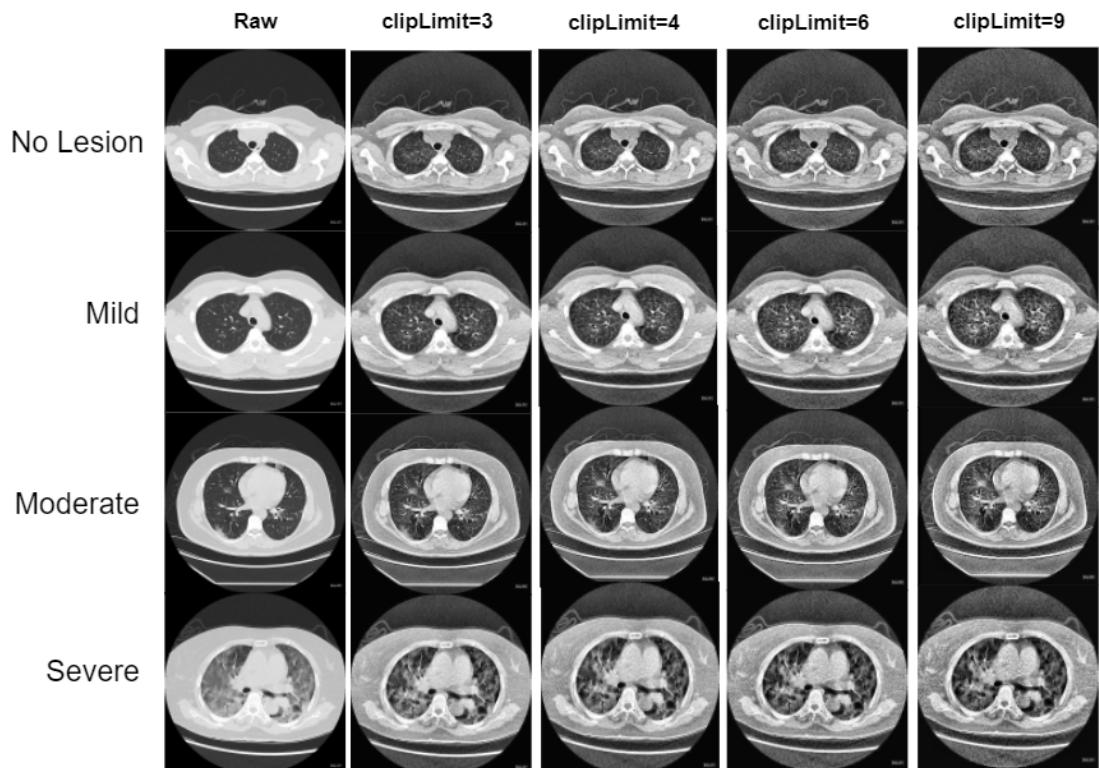
1. กรมควบคุมโรค, "Corona Virus Disease (COVID-19)," <https://ddc.moph.go.th/viralpneumonia/eng/index.php>.
2. พรรณี แสงแก้ว Phannee Saengkaew, มนัสวี เลาภิช Manasavee Lohvithee, and ทวีป แสงแห่งธรรม Taweeap Sanghangthum, 2020, "การถ่ายภาพเอกซเรย์คอมพิวเตอร์เพื่อการวินิจฉัยโรคระบาดโควิด-19," **Thai Journal of Physics**, vol. 37, no. 2, pp. 45–59, 2020.
3. กรมการแพทย์, 'โควิด-19 กรมการแพทย์,' <https://covid19.dms.go.th/>.
4. Feng Pan, Tianhe Ye, Peng Sun, Shan Gui, Bo Liang, Lingli Li, Dandan Zheng, Jiazheng Wang, Richard L. Hesketh, Lian Yang, and Chuansheng Zheng, 2020, "Time Course of Lung Changes at Chest CT during Recovery from Coronavirus Disease 2019 (COVID-19)," **Radiology**, vol. 295, no. 3, pp. 715–721, June 2020.
5. Marco Francone, Franco Iafrate, Giorgio Maria Masci, Simona Coco, Francesco Cilia, Lucia Manganaro, Valeria Panebianco, Chiara Andreoli, Maria Chiara Colaiacomo, Maria Antonella Zingaropoli, Maria Rosa Ciardi, Claudio Maria Mastroianni, Francesco Pugliese, Francesco Alessandri, Ombretta Turriziani, Paolo Ricci, and Carlo Catalano, 2020, "Chest CT score in COVID-19 patients: correlation with disease severity and short-term prognosis," **European Radiology**, vol. 30, no. 12, pp. 6808–6817, July 2020.
6. Xiaojun Guan, Liding Yao, Yanbin Tan, Zhujing Shen, Hanpeng Zheng, Haisheng Zhou, Yuantong Gao, Yongchou Li, Wenbin Ji, Huangqi Zhang, Jun Wang, Minming Zhang, and Xiaojun Xu, 2021, "Quantitative and semi-quantitative CT assessments of lung lesion burden in COVID-19 pneumonia," **Scientific Reports**, vol. 11, no. 1, Mar. 2021.
7. ศาสตราจารย์คลินิกเกียรติคุณ นายแพทย์ พนัส เนลิมและยากร, 2017, "ปอด: กายวิภาคปอด (Lung anatomy) / สรีรวิทยาของปอด (Lung physiology)," <https://haamor.com/>, Accessed: 2022-3-21.
8. spacehealth, "ระบบทางเดินหายใจ," <http://spacehealth.co/organ>, Accessed: 2022-3-21.
9. Jeremy Jordan, 2018, "An overview of semantic image segmentation," <https://www.jeremyjordan.me/semantic-segmentation/>, Accessed: 2022-3-21.
10. ชิตพงษ์ กิตตินราดร, "Neural Network Algorithm," <https://guopai.github.io/ml-blog14.html>, Accessed: 2022-3-21.
11. Arden Dertat, 2017, "Applied Deep Learning - Part 4: Convolutional neural networks," <https://towardsdatascience.com/applied-deep-learning-part-4-convolutional-neural-networks-584bc134c1e2>, Accessed: 2022-3-21.
12. Evan Shelhamer, Jonathan Long, and Trevor Darrell, 2017, "Fully convolutional networks for semantic segmentation," **IEEE Trans. Pattern Anal. Mach. Intell.**, vol. 39, no. 4, pp. 640–651, 2017.
13. Olaf Ronneberger, Philipp Fischer, and Thomas Brox, 2015, "U-Net: Convolutional Networks for Biomedical Image Segmentation," in **Lecture Notes in Computer Science**, pp. 234–241. Springer International Publishing, Cham.
14. 2019, "U-net: Convolutional networks for biomedical Image Segmentation," <http://bigdataexperience.org/u-net-convolutional-networks-biomedical-image-segmentation>, Accessed: 2022-3-21.
15. Özgün Çiçek, Ahmed Abdulkadir, Soeren S Lienkamp, Thomas Brox, and Olaf Ronneberger, 2016, "3D U-net: Learning dense volumetric segmentation from sparse annotation," in **Medical Image Computing and Computer-Assisted Intervention -- MICCAI 2016**, pp. 424–432. Springer International Publishing, Cham.
16. Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun, 2015, "Deep residual learning for image recognition," 2015.
17. Gao Huang, Zhuang Liu, Laurens Van Der Maaten, and Kilian Q Weinberger, 2017, "Densely connected convolutional networks," in **2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)**. 2017, IEEE.
18. "DenseNet," <https://paperswithcode.com/method/densenet>, Accessed: 2022-3-21.
19. Keras Team, "DenseNet," <https://keras.io/api/applications/densenet/>.
20. Shruti Jadon, 2020, "A survey of loss functions for semantic segmentation," 2020.
21. Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollar, 2020, "Focal Loss for dense object detection," **IEEE Trans. Pattern Anal. Mach. Intell.**, vol. 42, no. 2, pp. 318–327, 2020.

22. Hao Tang, Chupeng Zhang, and Xiaohui Xie, 2019, "Automatic pulmonary lobe segmentation using deep learning," in **2019 IEEE 16th International Symposium on Biomedical Imaging (ISBI 2019)**. 2019, IEEE.
23. Ekin Tiu, 2019, "Metrics to Evaluate your Semantic Segmentation Model," <https://towardsdatascience.com/metrics-to-evaluate-your-semantic-segmentation-model-6bcb99639aa2>, Accessed: 2022-3-21.
24. Steven Nickolas, 2021, "What do correlation coefficients positive, negative, and zero mean?," <https://www.investopedia.com/ask/answers/032515/what-does-it-mean-if-correlation-coefficient-positive-negative-or-zero.asp>, Accessed: 2022-5-22.
25. Jason Fernando, 2022, "R-Squared," <https://www.investopedia.com/terms/r/r-squared.asp>, Accessed: 2022-3-21.
26. Zhitao Xiao, Bowen Liu, Lei Geng, Fang Zhang, and Yanbei Liu, 2020, "Segmentation of lung nodules using improved 3D-UNet neural network," **Symmetry (Basel)**, vol. 12, no. 11, pp. 1787, 2020.
27. Awais Mansoor, Ulas Bagci, Ziyue Xu, Brent Foster, Kenneth N Olivier, Jason M Elinoff, Anthony F Suffredini, Jayaram K Udupa, and Daniel J Mollura, 2014, "A generic approach to pathological lung segmentation," **IEEE Trans. Med. Imaging**, vol. 33, no. 12, pp. 2293–2310, 2014.
28. Yazan Qiblawey, Anas Tahir, Muhammad E H Chowdhury, Amith Khandakar, Serkan Kiranyaz, Tawsifur Rahman, Nabil Ibtehaz, Sakib Mahmud, Somaya Al Maadeed, Farayi Musharavati, and Mohamed Arselene Ayari, 2021, "Detection and severity classification of COVID-19 in CT images using deep learning," **Diagnostics (Basel)**, vol. 11, no. 5, pp. 893, 2021.
29. Mingjian Chen, Yun Gu, Yulei Qin, Hao Zheng, and Jie Yang, "Lobenet: A global position reservation and fissure-aware convolutional neural network for pulmonary lobe segmentation," https://geronsushi.github.io/lung_files/lobeseg_final.pdf, Accessed: 2022-3-21.
30. Mahalakshumi Visvanathan, Velmurugan Balasubramanian, Rachana Sathish, Suhasini Balasubramaniam, and Debdoot Sheet, 2021, "Assessing lobe-wise burden of COVID-19 infection in computed tomography of lungs using knowledge fusion from multiple datasets," **Annu Int Conf IEEE Eng Med Biol Soc**, vol. 2021, pp. 3961–3964, 2021.
31. 9Expert Training, "ภาษาโปรแกรม Python คืออะไร," <https://www.9experttraining.com/articles/python-คืออะไร>.
32. Bryan C. Russell, Antonio Torralba, Kevin P. Murphy, and William T. Freeman, 2008, "LabelMe: A database and web-based tool for image annotation," **International journal of computer vision**, vol. 77, no. 1–3, pp. 157–173, 2008.
33. Ekaba Bisong, 2019, **Google Colaboratory**, p. 59–64, Apress.
34. "Streamlit documentation," <https://docs.streamlit.io/>, Accessed: 2022-3-21.
35. 2018, "What is GitHub? A beginner's introduction to GitHub," <https://kinsta.com/knowledgebase/what-is-github/>, Accessed: 2022-5-22.
36. "Git guides," .
37. "Git Large File Storage," .
38. Roman Solovyev, Alexandr A Kalinin, and Tatiana Gabruseva, 2022, "3D convolutional neural networks for stalled brain capillary detection," **Comput. Biol. Med.**, vol. 141, no. 105089, pp. 105089, 2022.
39. "OpenCV: Geometric Transformations of Images," https://docs.opencv.org/4.x/da/d6e/tutorial_py_geometric_transformations.html, Accessed: 2022-3-21.
40. "OpenCV: Histograms - 2: Histogram equalization," https://docs.opencv.org/4.x/d5/daf/tutorial_py_histogram_equalization.html, Accessed: 2022-5-22.

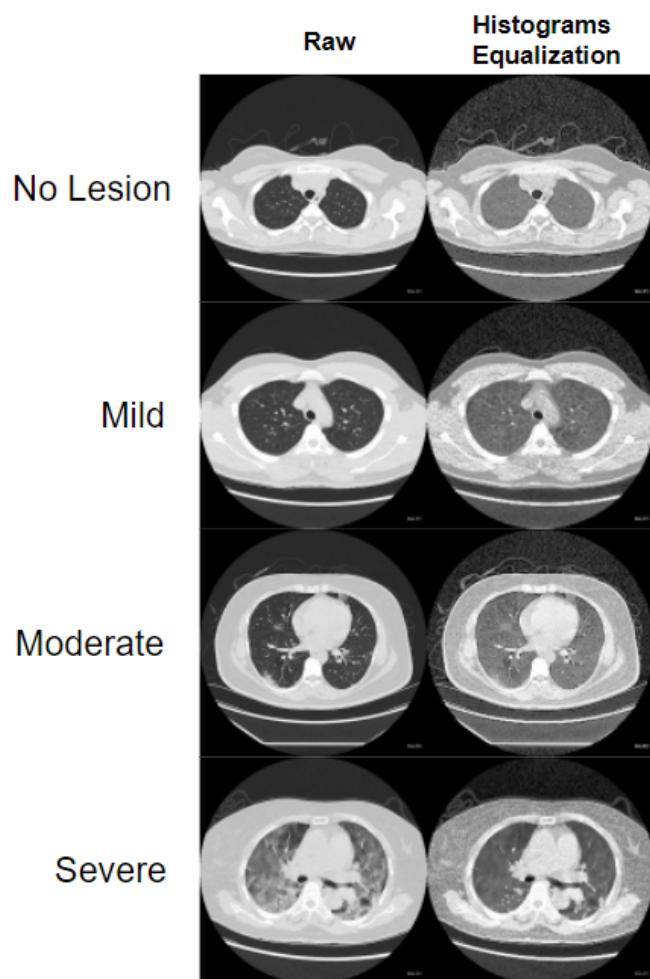
ภาคผนวก A

การปรับสีภาพ (Image Color Adjustment)

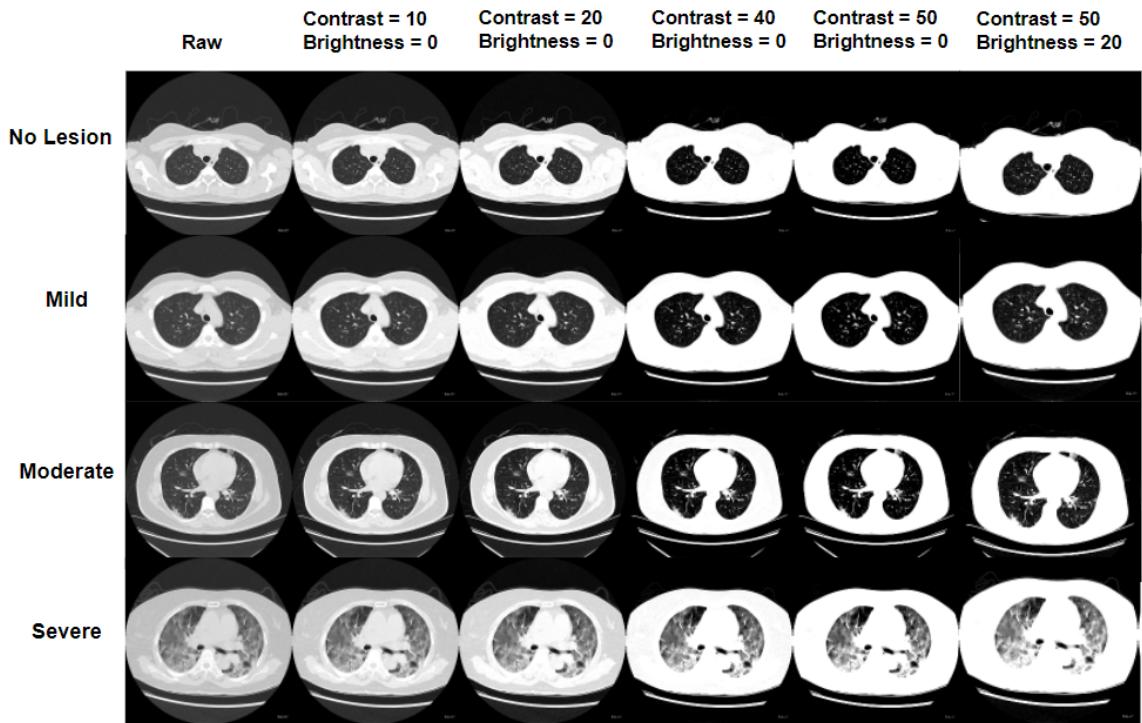
จากข้อสรุปในขั้นตอนการปรับสีภาพด้วยวิธีการ Contrast Limited AHE (CLAHE) ดังตารางที่ 3.5 ทางคณะผู้จัดทำได้เปรียบเทียบวิธีการปรับสีภาพวิธีการอื่นๆ เช่น Histograms Equalization ซึ่งเป็นหนึ่งในฟังก์ชันของ OpenCV และการปรับสีภาพโดยการปรับค่า Contrast และ Brightness จากการเปรียบเทียบผลลัพธ์การปรับสีภาพทั้ง 3 วิธี ทางคณะผู้จัดทำได้ข้อสรุปว่าการปรับสีภาพแบบ CLAHE เหมาะสมนำไปทดลองฝึกฝนแบบจำลองมากที่สุด โดยตัวอย่างการปรับสีที่ได้นำไปทดลองฝึกฝนแบบจำลองแสดงดังรูปที่ A.1-3



รูปที่ A.1: ภาพเปรียบเทียบการปรับสีภาพด้วยวิธีการ CLAHE (OpenCV)



รูปที่ A.2: ภาพเปรียบเทียบการปรับสีภาพด้วยวิธีการ Histograms Equalization (OpenCV)



รูปที่ A.3: ภาพเปรียบเทียบการปรับสีภาพด้วยวิธีการปรับ Contrast และ Brightness

Usability Test

คำถามสำหรับการประเมินหน้าต่างผู้ใช้งาน โดยมีช่วงคะแนนตั้งแต่มากที่สุดไปจนถึงน้อยที่สุด โดยมีคำถามดังตารางที่ A.2

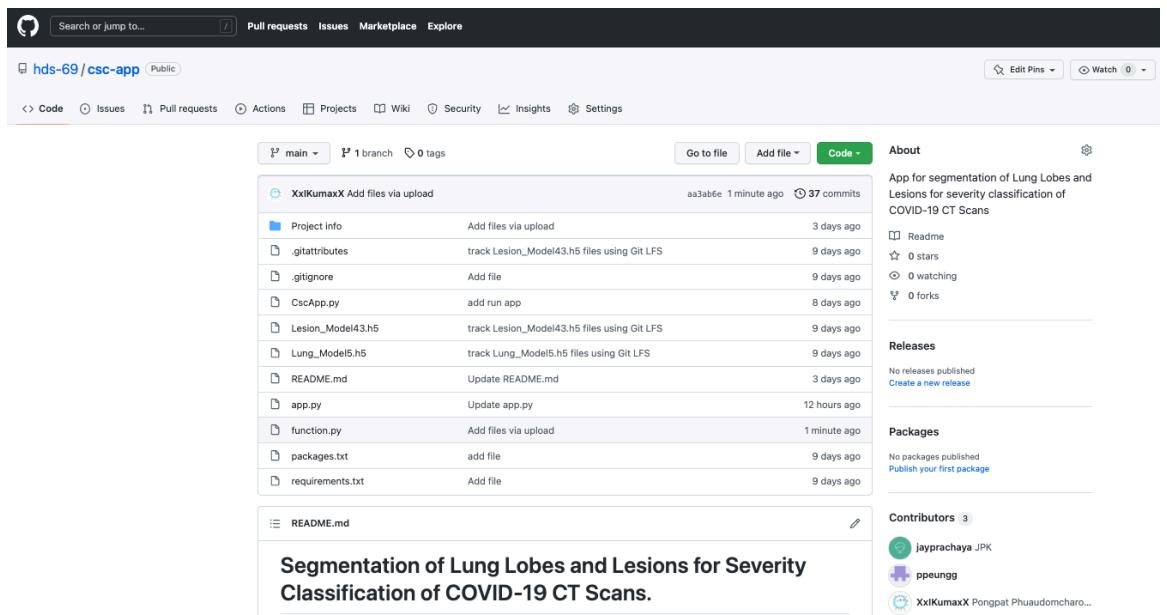
ตารางที่ A.1 คำถามสำหรับการประเมินหน้าต่างผู้ใช้งาน

คำถาม	มากที่สุด	มาก	ปานกลาง	น้อย	น้อยที่สุด
ความสวยงามของหน้าต่างผู้ใช้งาน					
ความสะดวกของการใช้งานหน้าต่างผู้ใช้งาน					
หน้าต่างผู้ใช้งานสามารถทำงานผลได้อย่างแม่นยำ					
หน้าต่างผู้ใช้งานมีความรวดเร็วในการอัปโหลด และแสดงผลของข้อมูล					
ภาพรวมการทำงานของหน้าต่างผู้ใช้งานมีความรวดเร็วในการทำงานและแสดงผล					
หน้าต่างผู้ใช้งานสามารถถอดความโน๊ตเครื่องได้ง่าย					
รูปแบบของรายงานผลลัพธ์การทำนายมีความเข้าใจง่าย					
ภาพรวมความพึงพอใจต่อหน้าต่างผู้ใช้งาน					

ภาคผนวก B

Source Code

คณะผู้จัดทำได้อัปโหลดไฟล์ Source Code ของโครงการนี้ใน Github สามารถเข้าถึงได้ที่ (<https://github.com/hds-69/csc-app>) โดยไฟล์ข้อมูลประกอบไปด้วยไฟล์หน้าต่างผู้ใช้งาน ซึ่งจะเป็นไฟล์ประเภท Python (app.py, function.py) ไฟล์ไลบรารี (Library) ที่จำเป็นต้องติดตั้งก่อนการใช้งาน (requirements.txt, packages.txt) และไฟล์แบบจำลองห้อง 2 แบบจำลอง เป็นไฟล์ประเภท HDF5 (Lung_Model5.h5, Lesion_Model43.h5) โดยไฟล์แบบจำลองจะถูกอัปโหลดโดย Git LFS ซึ่งจะช่วยให้สามารถอัปโหลดไฟล์ที่มีขนาดเกิน 100 Mb ขึ้น Git repository ได้



รูปที่ B.4: หน้าเว็บไซต์แสดงไฟล์ Source Code ของโครงการ